



저작자표시-비영리-변경금지 2.0 대한민국

이용자는 아래의 조건을 따르는 경우에 한하여 자유롭게

- 이 저작물을 복제, 배포, 전송, 전시, 공연 및 방송할 수 있습니다.

다음과 같은 조건을 따라야 합니다:



저작자표시. 귀하는 원저작자를 표시하여야 합니다.



비영리. 귀하는 이 저작물을 영리 목적으로 이용할 수 없습니다.



변경금지. 귀하는 이 저작물을 개작, 변형 또는 가공할 수 없습니다.

- 귀하는, 이 저작물의 재이용이나 배포의 경우, 이 저작물에 적용된 이용허락조건을 명확하게 나타내어야 합니다.
- 저작권자로부터 별도의 허가를 받으면 이러한 조건들은 적용되지 않습니다.

저작권법에 따른 이용자의 권리는 위의 내용에 의하여 영향을 받지 않습니다.

이것은 [이용허락규약\(Legal Code\)](#)을 이해하기 쉽게 요약한 것입니다.

[Disclaimer](#)

석사학위 청구논문

지도교수 김 민 경

GARCH와 LSTM 모델을 이용한 수입육 가격 변동성 예측력 비교

2020년 8월

건국대학교 대학원
축산경영·유통경제학과
김 경 진

GARCH와 LSTM 모델을 이용한 수입육 가격 변동성 예측력 비교

Analysis of the Predicted Volatility of
Imported Meat Price based on GARCH and LSTM

이 논문을 경영학 석사학위 청구논문으로 제출합니다.

2020년 4월

건국대학교 대학원
축산경영·유통경제학과
김 경 진

김경진의 경영학 석사학위 청구논문을 인준함.

심사위원장 _____ (인)

심사위원 _____ (인)

심사위원 _____ (인)

2020년 6월

건국대학교 대학원

목차

표 목차	iii
그림 목차	v
국문초록	vi
제1장 서론	1
제1절 연구 배경 및 필요성	1
제2절 연구 구성	5
제2장 선행 연구	6
제1절 가격 변동성 예측	6
제2절 인공지능망	7
제3절 수입 축산물 현황	10
제3장 분석 모형	19
제1절 수입수요함수	19
제2절 GARCH Model	21
1. GARCH Model	21
2. Multivariate GARCH Model	23
제3절 인공지능망 모형	27
1. 다층 퍼셉트론 인공지능망(Multi-Perceptron Neural Network)	27
2. 순환신경망(Recurrent Neural Network, RNN)	29
3. LSTM(Long Short Term Memory)	31
4. GARCH-LSTM 결합 모형	33
5. 인공지능망 구성	34
제4절 검증 방법	36
1. 손실 함수(Loss Function)	36
2. Diebold & Mariano 검정	37

제4장 실증 분석	38
제1절 분석 자료	38
제2절 기초 통계	39
1. 단위근 검정	43
2. ARCH-LM 검정	45
제3절 다변량 모형 추정 결과	47
1. 일별 가격 자료 분석	47
2. 월별 가격 자료 분석	52
제4절 다변량 모형 추정 결과	57
제5절 모형 간의 예측력 비교	63
제5장 요약 및 결론	66
참고문헌	68
ABSTRACT	77

표 목차

<표 2-1> 연도별 수입 유형별 쇠고기 수입량	12
<표 2-2> 연도별 원산지별 냉동 쇠고기 수입량	13
<표 2-3> 연도별 부위별 쇠고기 수입량	14
<표 2-4> 연도별 수입 유형별 돼지고기 수입량	14
<표 2-5> 연도별 부위별 돼지고기 수입량	15
<표 4-1> 일별 분석 자료의 기초 통계량	39
<표 4-2> 월별 분석 자료의 기초 통계량	41
<표 4-3> 미국산 갈비와 설명 변수 간의 상관관계	42
<표 4-4> 수입 삼겹살과 설명 변수 간의 상관관계	43
<표 4-5> 일별 가격 변동률에 대한 단위근 검정 결과	44
<표 4-6> 월별 가격변화율에 대한 단위근 검정 결과	45
<표 4-7> 수입 축산물 가격 변동성의 ARCH-LM 검정	46
<표 4-8> 일별 가격 변동성의 GARCH(1,1) 모형 추정 결과	48
<표 4-9> 단변량 미국산 갈비 일별 가격 변동성 예측 결과	49
<표 4-10> 단변량 수입 삼겹살 일별 가격 변동성 예측 결과	50
<표 4-11> 단변량 미국산 갈비 일별 가격 변동성 예측 비교	51
<표 4-12> 단변량 수입 삼겹살 일별 가격 변동성 예측 비교	51
<표 4-13> 수입 축산물 가격 변동성의 GARCH(1,1) 모형 추정 결과	53
<표 4-14> 단변량 미국산 갈비 월별 가격 변동성 예측 결과	54
<표 4-15> 단변량 수입 삼겹살 월별 가격 변동성 예측 결과	55
<표 4-16> 단변량 미국산 갈비 월별 가격 변동성 예측 비교	56
<표 4-17> 단변량 수입 삼겹살 월별 가격 변동성 예측 비교	56
<표 4-18> 수입 축산물 가격 변동성의 DCC-GARCH(1,1) 모형 추정 결과	58
<표 4-19> 다변량 미국산 갈비 월별 가격 변동성 예측 결과	59

<표 4-20> 다변량 수입 삼겹살 월별 가격 변동성 예측 결과	60
<표 4-21> 다변량 수입 갈비 월별 가격 변동성 예측 비교	62
<표 4-22> 다변량 수입 삼겹살 월별 가격 변동성 예측 비교	62
<표 4-23> 수입 축산물 가격 변동성 예측력 비교	63
<표 4-24> 미국산 갈비 가격 변동성 예측력 비교	64
<표 4-25> 수입 삼겹살 가격 변동성 예측력 비교	65

그림 목차

<그림 2-1> 연도별 축산물 1인당 소비량	10
<그림 2-2> 연도별 축산물 수입량	11
<그림 2-3> 월별 한우 갈비 소비자 가격 추이	16
<그림 2-4> 월별 국내산 삼겹살 소비자 가격 추이	16
<그림 2-5> 월별 미국산 갈비 소비자 가격 추이	17
<그림 2-6> 월별 수입 삼겹살 소비자 가격 추이	18
<그림 3-1> 인공신경망의 기본 구조	28
<그림 3-2> 순환신경망(RNN) 모식도	30
<그림 3-3> Long Short Term Memory(LSTM)의 모식도	33
<그림 4-1> 단변량 미국산 갈비 일별 가격 변동성 예측 비교	49
<그림 4-2> 단변량 수입 삼겹살 일별 가격 변동성 예측 비교	50
<그림 4-3> 단변량 미국산 갈비 월별 가격 변동성 예측 비교	54
<그림 4-4> 단변량 미국산 갈비 월별 가격 변동성 예측 비교	55
<그림 4-5> 다변량 미국산 갈비 월별 가격 변동성 예측 결과	60
<그림 4-6> 다변량 수입 삼겹살 월별 가격 변동성 예측 결과	61

국문초록

GARCH와 LSTM 모델을 이용한 수입육 가격 변동성 예측력 비교

우리나라에서 축산물은 매년 소비량이 늘어나 중요한 식품 자원으로 자리매김하고 있다. 동시에 수입 축산물에 대한 수요의 증가로 인해 매년 수입량의 증가하며, 수입 축산물은 국내산 축산물의 자리를 빠른 속도로 대체해 나가고 있다. 수입 축산물의 가격 변동이 국내산 축산물의 가격에도 영향을 미치기 때문에, 수입 축산물 가격 변동성을 예측하는 것은 국내 축산업에 중요한 역할을 한다.

본 연구는 수입 축산물 중 미국산 갈비와 수입 삼겹살의 소비자 가격을 선택하여 분석하였다. 미국산 갈비와 수입 삼겹살을 기존의 시계열 모형은 GARCH 모형과 DCC-GARCH 모형을 이용하여 예측하였다. 더불어 딥러닝, 머신 러닝 등으로 인해 주목받고 있는 인공지능망, 특히 시계열 분석에 적합한 LSTM 모형을 이용하여 변동성을 예측하였으며, LSTM 모형과 GARCH 모형을 결합한 GARCH-LSTM 통합모형을 이용하여 변동성을 예측하여 GARCH 모형과 예측 정확도를 비교하였다. 분석에 있어 월별과 일별 자료를 같은 기간으로 사용하였으며, 가격 변동성 자료를 이용한 단변량적 접근 방법과 수입 축산물 수입에 영향을 미치는 설명 변수, 국내산 삼겹살 가격, 수입 축산물 수입량, 선행종합지수, 원·달러 환율을 추가하여 분석한 다변량적 접근 방법을 이용하여 분석하였다.

분석 결과는 다음과 같다.

첫째, 일별 가격 자료를 이용한 미국산 갈비와 수입 삼겹살 GARCH 모형 분석 결과는 과거 전반의 영향이 가격 변동성에 영향을 미치는 GARCH 효과가 있는 것으로 나타났다.

둘째, 일별 가격 자료를 이용하여 미국산 갈비와 수입 삼겹살 변동성 예측 모형의 예측력을 비교한 결과, LSTM 모형이 GARCH 모형보다 더 높은 정확도를 보였다.

셋째, 단변량적 접근 방법을 통해 월별 가격 자료를 이용한 미국산 갈비와 수입 삼겹살의 GARCH 모형 분석 결과, 미국산 갈비에서는 가격의 변동이 직전 시점에 영향이 현재 시점에도 미치는 ARCH 효과와 가격 변동이 과거 전반에 영향을 받는 GARCH 효과가 모두 나타났으나, 수입 삼겹살에서는 GARCH 효과만 나타났다.

넷째, 단변량적 접근 방법을 통해 월별 가격 자료를 이용한 미국산 갈비와 수입 삼겹살의 가격 변동성을 예측한 결과 LSTM 모형이 GARCH 모형보다 더 높은 정확도를 보였다.

다섯째, 다변량적 접근 방법을 통하여 월별 가격 자료를 이용한 미국산 갈비와 수입 삼겹살의 DCC-GARCH 모형을 분석한 결과 미국산 갈비와 수입 삼겹살에서 ARCH 효과와 GARCH 효과 모두 있는 것으로 나타났다.

여섯째, DCC-GARCH 모형과 LSTM 모형, GARCH-LSTM 통합모형을 이용하여 예측력을 비교한 결과 GARCH-LSTM 통합모형이 예측력이 가장 높았으며, LSTM 모형과 DCC-GARCH 모형을 순으로 예측력이 높았다.

본 연구는 LSTM 모형이 GARCH 모형보다 높은 정확도를 보였으며, GARCH-LSTM 통합모형이 단일 모형보다 높은 예측력을 보였다. 더불어 일별 가격 변동성을 예측한 결과에서 정확도가 월별 가격 변동성을 예측한 결과보다 정확도가 높았으며, 단변량적 접근 방법보다 다변량적 접근 방법이 높은 정확도를 보인 것으로 나타났다.

주제어 : 수입 축산물, 인공신경망, GARCH 모형, LSTM 모형, GARCH-LSTM 통합모형

제1장 서론

제1절 연구 배경 및 필요성

우리나라는 소득의 증가, 식생활의 서구화 등의 영향을 받아 축산물의 소비량이 꾸준히 증가하여, 축산물 1인당 소비량은 2018년 기준 총 53.9kg에 이르렀으며, 이는 2010년 기준 38.8kg 대비 38.9% 수준이다. 축산물 시장 개방 이후 수입량은 계속 증가하였고 2019년 426,626톤을 기록하였으며, 2009년부터 연평균 7.23% 증가하였다. 자급률은 이와 반대로 2003년 기준 70.8%였던 것에 비해 2019년 60.3%로 10.5%p 감소하였다. 이를 통해 수입 축산물이 국내산 축산물을 대체하고 있음을 알 수 있다.

현재 축산물 시장에서 한우의 가격 강세, 대형유통업체의 수입육 전문 매장 확대, 수입육 취급 전문 프랜차이즈 증가, 가정 간편식(HMR)과 식자재 등 가공 시장 확대에 따라 수입육의 수요가 확대되고 있다. 국내 축산물 생산량의 증가에도 불구하고, 가공품의 판매가 증가하면서 상대적으로 값이 낮은 수입육 사용 역시 증가한 것으로 판단되며, 수입육의 수요는 계속해서 증가할 것으로 예상된다¹⁾.

국내 축산물의 가격은 국내 시장 뿐 아니라 해외 시장의 변화를 반영하는데, 권용덕(2008)은 쇠고기 시장에서 국제 시장과 국내 소매시장의 시장통합 현상을 검토하여 시장 개방으로 인한 국제 가격이 국내 쇠고기 시장에 영향을 미쳤음을 증명하였다. 더불어 장재봉 외(2017)는 국제 축산물 가격이 국내에 유통되고 있는 축산물 가격에 미친 영향을 분석하였다. 조재환(2011)은 역준이상수요체계를 분석한 결과, 수입 쇠고기 수입량이 증가할 때, 한우 저급육(3등급)과 육우 고기 가격이 감소하는 반면, 국내산 고급육(1+, 1, 2등급)에서는 가격이 증가하는 것으로 나타났다. 이는 저급육 수요가 수입육과 국내산 고급육으로 이동하는 것을 의미하며, 수입이 개방되었을 때, 고급육보다 국내산 저급육의 수요가 수입육으로 대체됨을 의미한다. 이형우(2016)은 VECM 모형을 통해 한우 가격이 호주산 쇠고기보다 미국산 쇠고기 가격과

1) 한육우·돼지·젖소 수급 동향과 전망, 한국농촌경제연구원, 2019

밀접한 관계가 있음을 보여주었다. 이 외에도 이계임·최지현(2000), 김혜영·김태균(2003) 등의 연구에서 국내산 축산물과 수입 축산물 사이의 대체성 및 수요 구조를 분석하였다. 이들 연구에서 밝혀진 것처럼 수입 축산물 시장과 국내산 축산물 시장은 국내 시장에서 서로 경쟁하는 구조를 보이므로, 수입 축산물 가격에 대한 논의가 필요하다. 특히 축산물 가격은 변동성이 크기 때문에 수입가격 변동성 예측을 통해 우리나라 축산물 시장에 미친 파급효과를 가늠해 볼 수 있다. 따라서 수입 축산물의 가격 변동성을 예측은 국내 축산물의 수급 및 합리적인 의사결정을 실행할 수 있는 좋은 지표가 될 수 있다.

축산물 가격은 주기변동이 심하고 등락 폭이 커서 시장의 불안정성이 크다는 특징을 갖는다(이병기, 2001). 가격 변동성에 대한 예측은 시장의 불확실성을 관리할 수 있다는 측면에서 매우 중요하다. 가격의 변동성은 불확실성을 의미하며, 이에 따른 위험을 의미하기도 한다(박병기 외, 2014). 따라서 변동성을 예측하는 것은 가격 위험에 대응할 수 있는 신호가 될 수 있으며, 이 신호에 따라 의사결정자는 위험을 관리할 수 있다. 축산물의 가격 변동성 예측은 소비자의 수요 변화를 파악할 수 있으며, 축산업과 관련된 생산자들의 경영 전략을 수립하는데 좋은 지표가 될 것이며, 이를 통해 축산물의 수급을 예측하는 과정에서 활용할 수 있다.

국내의 축산물 가격 변동성에 관한 연구로는 이병기(2001)에서 돼지가격의 변동에 미치는 요인을 분석하였으며, 강태훈(2007)은 국내의 쇠고기, 돼지고기, 닭고기, 계란 가격을 이용하여 가격 변동성을 파악하였다. 윤병삼(2008)은 돼지고기와 쇠고기의 일일 지육 경락가격을 이용하여 변동성을 분석하여 변동에 영향을 주는 요인을 분석하였으며, 이 외에도 축산물의 가격의 변동성 예측, 가격 변동성에 미치는 요인 등을 분석한 연구들이 이루어지고 있다(Apergis and Rezitis, 2003; 유한수, 2010; 이춘수·양승룡, 2013; 서대교·신종협, 2014). 그러나 시장에 영향을 미치는 요인들이 다양해지고, 복잡해짐에 따라서 기존의 시계열 모형을 이용한 가격 예측은 정확성에서 많은 한계를 보였다. 기존의 시계열 모형은 시장의 현상을 통계적 논리를 바탕으로 설명해왔으며, 여러 연구를 통하여 발전해왔다. 그러나 시장 변수들은 백색소음(white noise)에 대한 문제 등 예측에 대한 정확성 문제가 발생하면서 이를 보완하기 위한 노력이 요구되고 있다(노태협 외, 2005).

최근 딥러닝의 발전과 함께 위와 같은 전통적 시계열 분석의 단점을 보완하기 위하여, 인공신경망 등 인공지능 기법을 이용한 시계열 예측에 관한 연구가 많이 진행되고 있다(Kawashima et al., 1995; Zhang, 2003; Zou et al., 2007; Faruk, 2010; Nilashi et al., 2012). 인공신경망은 인간의 신경계의 뉴런을 통한 학습 메커니즘을 수학적 방법을 통하여 모방하여 실시하는 기계적 학습방법 중 하나이다.

인공신경망은 기존의 시계열 모형에서의 독립변수와 같은 입력 변수가 불완전하고 변동 폭이 넓은 경우에도 해석이 가능하며, 자료의 분량이 적거나 불규칙한 경우에도 반복 학습을 통하여 실측치와 예측치 간의 차이를 줄여갈 수 있는 장점이 있다(심재현 외, 2007). 기존의 시계열 모형은 변수들의 선형 관계를 가정하고 있으나, 인공신경망 모형은 비모수적으로 추정하며, 분석 과정에서 오차를 수정하는 능력이 있기 때문에, 기존의 시계열 분석 방법을 통한 가격 변동성 예측보다 정확한 예측이 가능한 것으로 알려져 있다(Hamid, 2014). 이러한 장점을 토대로 인공신경망을 이용한 여러 가격 변동성 예측에 관한 연구가 진행되었으며, 기존의 시계열 분석 방법보다 향상된 결과를 보였다. (Ormoneit and Neuneier, 1996; Gonzalez Miranda and Burgess, 1997; Hamid and Iqbal, 2004). ARIMA, EWMA, GARCH 모형과 같은 기존 시계열 분석과 인공신경망을 결합한 통합모형의 정확도를 분석하는 연구 역시 다수 진행되었다(Donaldson and Kamstra, 1997; Zhang et al., 2001; Zhang, 2003; Meissner and Kawano, 2001; Ghuassi et al., 2005; Roh, 2007; 노태협, 2005).

신경망을 이용한 시계열 분석 초기에는 순방향 신경망(feedforward neural network)를 이용한 연구가 주를 이루었다. 이후 추정 과정에서 오차를 수정하여 정확성을 높이는 역전파 신경망(back-propagation neural network), 순환 신경망(recurrent neural network)을 이용한 연구가 많았으나, 추정 과정에서 기울기가 소실되거나 큰 값으로 발산하는 현상이 발생하여 분석이 불가능한 경우가 발생(Hochreiter 외, 1997)하면서 이러한 문제점을 해결하기 위해 LSTM(Long Short Term Memory) 모형이 개발되었다. LSTM은 모형 추정 시 특정 조건을 추가하여 문제점을 해결하는 방식으로 최근에는 LSTM을 이용한 연구들이 진행되고 있다(Chen, 2015; Siامي-Namini, 2018; 정성호 외, 2018; 이낙영 외, 2019). 특히 시계열 모형의 장점을 취하기 위해 GARCH 모형과 같은 시계열 모형과 결합된 LSTM 모형을 이용한 연구가 진행되었으며,

향상된 예측 결과를 보여주었다(Kim and Won, 2018).

본 연구에서는 이러한 흐름에 따라서 LSTM 모델을 이용하여, 국내에 가장 많이 수입되는 미국산 갈비, 수입 삼겹살의 소비자 가격의 변동성을 일별 자료와 월별 자료, 단변량적 접근과 다변량적 접근 방법으로 구분하여 예측·비교하였다. 앞에서 언급한 바와 같이 인공신경망을 이용한 시계열 분석은 금융 분야에서 많이 이루어졌는데, 일별 자료와 월별 자료를 주로 분석하는 축산물과는 달리 금융 시계열은 시간별, 일별 자료를 이용하여 신경망 분석하였다. Pradhan and Kumar(2010), Zhang et al.에 따르면 인공신경망은 분석 대상의 자료 주기는 연구 결과에 영향을 미칠 뿐 아니라 분석 자료의 발표 주기로 인한 자료의 존재 여부를 고려하여, 본 연구는 일별 자료와 월별 자료를 구분하여 분석·비교하고자 한다. 또한, 설명변수를 통해 시장 상황을 반영한 추정을 통하여 인공신경망에 대한 단변량적 접근 방법과 다변량적 접근 방법 사이의 예측력을 비교하고자 한다. 이를 통해 수입 축산물 시장의 불확실성을 관리할 수 있는 기초 자료를 제공하고자 한다. 특히 본 연구에서는 GARCH 모형, LSTM 모형, 그리고 이 두 모형이 결합된 GARCH-LSTM 모형을 추정하고 그 예측력을 비교하여 추정 방법에 따라 가격 변동성 예측 결과를 비교해보고자 한다.

제2절 연구 구성

본 연구는 총 5장으로 구성되어 있으며 각 장의 내용은 다음과 같다. 제1장은 서론으로 연구 배경 및 필요성, 연구의 목적을 통해 수입 축산물의 가격 변동성 예측에 대한 필요성 및 방향을 제시하였으며, 제2장은 가격 변동성 및 인공신경망에 관한 선행 연구를 살펴보았다. 제3장은 산업 현황으로 국내에서 축산물의 중요성과 수입 축산물의 가격 및 수입량 변화 등을 파악하고자 한다. 제4장은 연구 모형으로 연구에 사용된 GARCH 모형과 인공신경망 모형, 특히 LSTM 모형에 대해 살펴보았다. 제4장은 실증 분석으로 분석에 앞선 자료에 대한 기초적인 분석을 실시하였으며, 분석 모형을 이용하여 추정된 결과를 해석하고 가격 변동성 예측 결과를 확인하였다. 마지막으로 제5장은 분석 결과를 토대로 결과 요약, 한계점 및 의의를 제시하였다.

제2장 선행 연구

제1절 가격 변동성 예측

가격 변동성에 대한 예측은 위험을 관리하는 분야에서 유용하게 활발하게 연구되고 있다(Christoffersen, 1998). 가격 변동성 예측에 관한 연구는 가격 변동에 따라 민감하게 반응하는 금융 관련 분야에서 다양한 연구 방법으로 이루어지고 있다.

금융에 대한 분석은 국내·외로 Brandt and Jones(2006), 황성원·류혁선(2011), 김상환(2015) 등의 연구가 진행되었다. Brandt and Jones(2006)은 EGARCH 모형에 S&P 500 지수의 일일 최고, 최저 가격 자료 등을 이용하여 주익 수익률을 예측하였다. Brandt and Jones(2006)은 multi-factor EGARCH 모형을 통해 변동성을 예측하였으며, 해당 모형을 통해 1년간의 변동성을 예측할 수 있음을 입증하였다.

국내에서는 황성원·류혁선(2011)과 류두진(2012)은 GARCH 모형을 이용하여, 각각 KOSPI 200의 변동성과 S&P 500의 변동성을 예측하였다. 황성원·류혁선(2011)은 단순 이동 평균법(simple moving average), GARCH 모형과 국면전환 GARCH 모형을 이용하여 KOSPI 200을 예측한 결과 1일과 5일 변동성 예측에 국면전환 GARCH 모형(regime-switching GARCH)이 가장 높은 예측력을 보였으며, 류두진(2012)은 Risk-Metrics 접근법과 미국 변동성 지수(VIX), GARCH 계열의 모형의 S&P 500지수의 변동성 예측을 분석한 결과, GARCH 계열 모형, 특히 EGARCH와 GJR-GARCH 모형의 예측력이 우수함을 입증하였다.

김상환(2015)은 KOSPI 200 지수수익률을 역사적 분산, 지수 가중 이동평균(EWMA), 한국거래소의 변동성 지수(VKOSPI), HAR-RV와 GARCH 계열 모형의 예측성과를 분석하였다. EGARCH의 예측력이 가장 높은 것으로 분석되었으나, 통계적인 유의성에서는 VKOSPI, GARCH 모형 역시 우수한 것으로 분석하였다.

축산물 관련 연구에서는 Apergis and Rezitis(2003), 이병기(2001), 강태훈(2007), 윤병삼(2009), 유한수(2010), 이춘수·양승룡(2013), 서대교·신종협(2014) 등 가격 변동성에 대해 변동성 사이의 관계, 가격 변동에 미치는 요인 분석 등을 중심으로 ARCH 모형, GARCH 모형과 VECM, Granger 인과관계, 충격반응함수 등 다양한 모형을 이용하여 연구가 이루어졌다. 그러나 축산물에 대한 가격 변동성 예측에 관한 연구는 다른 분야와 달리 미미하게 이루어졌다.

제2절 인공신경망

인공신경망은 McCulloch and Pitts(1943)에 의해 인공신경망 초기 모형이 제안되었으며, Hebb(1949)에 의해 연결 가중치를 조정하기 위한 학습 규칙을 최초로 시도하였다. 그러나 초기의 인공신경망이 논의될 당시, 컴퓨터의 성능 및 여러 제한 조건에 의해 인공신경망에 관한 연구가 중단되었다.

한편, 딥러닝(Deep-learning), 머신 러닝(Machine Learning)과 같은 인공지능을 이용한 연구가 주목을 받게 되고, 분석 자료의 제약에 의한 기존 시계열 분석에 한계를 보이면서, 인공지능을 이용한 여러 시계열 자료를 분석하는 연구가 많이 이루어졌다. Hopfield(1986)는 인공신경망의 오차를 역으로 수정하여 오차를 줄여가는 방법인 역전파 알고리즘(back-propagation)을 제안하여, 인공신경망의 정확도가 크게 향상되었다. 이후 Ormoneit and Neuneier(1996)의 역전파 인공신경망을 이용하여 독일의 주가지수인 DAX를 예측한 연구 이후 꾸준히 이루어지고 있다. 대표적으로 Gonzalez Miranda and Burgess(1997), Donaldson and Kamstra, (1997), Hamid and Iqbal(2004) 등이 인공신경망을 이용하여 연구를 진행하였다. Gonzalez Miranda and Burgess(1997)는 스페인의 Ibex35 지수의 변동성을 다층 인공신경망(multilayer perception neural network)을 이용하여, 분석이 가능함을 입증하였으며, Donaldson and Kamstra(1997)는 런던, 뉴욕, 도쿄, 토론토 등의 주식 수익률 변동성을 인공신경망을 기반으로 GARCH 모형을 이용하여 분석하여 단일 모형인 GARCH 모형과 EGARCH 모형보다 높은 예측력을 보였다. Hamid and Iqbal(2004)는 역전파 인공신경망과 Barone-Adesi and Whaley(BAW) 미국 선물 옵션 가격 모형을 이용한 S&P 500 지수 선물 옵션의 변동성 예측을 비교하였다.

최근 인공신경망을 이용한 시계열 분석이 발전함에 따라 기존 시계열 분석 모형과 인공신경망을 결합한 모형을 개발하여, 개별 모형의 예측 정확도보다 높은 결합모형을 이용하여 분석하는 연구가 진행되고 있다.(Meissner and Kawano, 2001; Roh, 2007; 노태협 외, 2005). Meissner and Kawano(2001)는 GARCH 모형으로 추정된 변동성을 인공신경망의 입력 변

수로 사용하여 인공신경망을 통한 변동성을 추정하여, 시계열 모형인 블랙-숄츠 모형보다 높은 예측력을 보여주었다. Roh(2007)은 순방향 인공신경망과 시계열 분석 방법(EWMA, GARCH, EGARCH)을 이용하여 KOSPI200 지수의 변동성을 분석하였다. Roh(2007)는 단일 모형 분석과 더불어 시계열 분석 방법과 인공신경망을 결합한 모형을 통해 변동성을 예측하였다.

국내 연구로는 노태협 외(2005)가 KOSPI 200 지수와 KOSDAQ100의 자료를 이용하여 시계열 모형인 EWMA 모형, GARCH 계열 모형과 인공신경망 모형을 이용한 단일 모형 추정하였으며, 금융 시계열 모형과 인공신경망 모형의 통합모형을 비교·분석하였다. 해당 연구의 단일 모형에서는 인공신경망 단일 모형이 가장 높은 예측력을 보였으며, 인공신경망 모형보다 인공신경망과 EGARCH 통합모형, 인공신경망과 GARCH 통합모형에서 높은 예측력을 보여주었다.

인공신경망 역시 시간을 거듭할수록 발전된 인공신경망을 구현하였다. 최근 순환신경망(RNN)에서 발생하는 단점인 기울기(gardient)가 비정상적으로 감소하는 문제(vanishing gradient problem)를 해결하기 위해 Hochreiter and Schmidhuber(1997)에 의해 Long Short - Term Memory(LSTM) 모형을 제안되어, 이를 이용한 변동성 예측에 관한 연구가 이루어지고 있다.

LSTM 모형은 기존의 인공신경망과 같이 시계열 모형과 결합한 통합모형을 이용하여 변동성을 예측하였다. Kim and Won(2018)은 LSTM 단일 모형과 EWMA 모형, GARCH 계열 모형을 분석하고, LSTM 모형과 금융 시계열 모형을 하나, 둘, 혹은 세 개의 모형을 결합한 통합모형을 통해 예측력을 분석하였다. 단일 모형에서는 LSTM 모형이 가장 높은 예측력을 보였다. LSTM과 하나의 금융 시계열 모형이 결합한 형태에서는 LSTM과 EGARCH 모형(E-LSTM)이 가장 높은 정확도를 보였으며, LSTM과 두 개의 금융 시계열 모형이 결합한 형태에서는 LSTM 모형과 GARCH, EGARCH 결합 모형(GE-LSTM)이 가장 높은 것으로 나타났다. 결과적으로 LSTM 모형과 세 개의 모형이 결합한 LSTM 모형과 EWMA, GARCH, EGARCH 결합 모형(GEW-LSTM)이 가장 적은 오차를 보였다.

그러나 축산물 가격을 인공신경망 모형 통해 분석한 연구는 극히 드물게 이루어지고 있다. 국외로는 Kohzadi et al.(1996)과 Hamm and Brorsen(1997)이 있으며, 국내로는 양승룡·박유신(1999)이 있으며, 특히 축산물 가격 변동

성을 인공신경망을 통해 분석한 연구는 전무한 실정이다. Kohzadi et al.(1996)은 ARIMA 모형과 순방향 인공신경망의 가격 예측 능력을 미국의 생우와 밀의 월별 가격을 이용하여 검증하여 인공신경망 모형의 가격 예측 능력이 ARIMA 모형의 가격 예측보다 우수함을 증명하였으며, Hamm and Brorsen(1997)은 Kohzadi et al.(1996)와 동일하게 ARIMA 모형과 순방향 인공신경망의 가격 예측 능력을 산지 돼지가격을 월별, 분기별 자료를 이용하여 인공신경망의 가격 예측 능력의 정확도가 더 우수함을 보였다.

국내의 양승룡·박유신(1999)는 역전과 알고리즘의 인공신경망 모형과 ARIMA 모형, GARCH 모형을 이용하여 한우, 양돈, 육계 가격을 대상으로 산지 가격에 대한 예측력을 분석하였다. 양돈의 가격 예측력에서는 역전과 인공신경망의 예측이 ARIMA 모형과 GARCH 모형보다 예측력이 높은 것으로 나타났으나, 한우와 육계의 경우 ARIMA 모형과 GARCH 모형의 예측력이 더 높은 것으로 나타났다.


따라서 가격 변동성 예측의 중요성, 인공신경망을 이용한 연구의 중요성을 바탕으로 본 연구는 수입 축산물 가격 변동성을 인공신경망, 특히 LSTM 모형을 이용하여 예측하고자 한다.

제3절 수입 축산물 현황

국민 소득의 증가와 이에 따른 식생활의 변화 등 육류를 중심으로 한 축산물의 수요가 증가하였다. 특히 1인 가구의 증가 등으로 인한 사회적 변화로 인해 가정 간편식 등 레토르트 식품, 도시락 등의 수요가 증가하였다. 이러한 상황에서 비용 절감을 위해 가정 간편식(HMR)에 사용되는 원료로 수입 축산물이 사용되고, 수입 축산물을 전문적으로 취급하는 수입육 전문점이 생김에 따라 수입육 시장이 증가하였다. 이와 더불어 1994년 우루과이라운드 농산물 협정 타결, 2002년 한·칠레의 자유무역협정(FTA) 이후로 여러 무역 협정들로 인해, 무역장벽이 낮아졌다. 이에 따라 수입에 대한 수요 역시 증가하여, 수입량 증가, 자급률 하락 등으로 이어졌다.

국내의 축산물 1인당 소비량은 2003년부터 2016년까지 꾸준히 증가하는 것으로 나타났다. <그림 2-1>의 연도별 1인당 축산물 소비량은 2018년 쇠고기 12.7kg, 돼지고기 27.0kg, 닭고기 14.2kg으로 2010년에 비해 쇠고기는 연평균 2.68%, 돼지고기는 연평균 2.65%, 닭고기는 연평균 35.1% 증가한 것으로 나타났다. 이는 한국의 식생활에서 육류가 차지하는 비중이 증가하였고, 중요한 식품 자원으로 인식되고 있음을 의미한다.


<그림 2-1> 연도별 축산물 1인당 소비량



자료 : 농림축산식품부

한편 축산물에 대한 한국의 자급률은 꾸준히 감소하였다. 이는 생산량의 증가에도 불구하고, 미국, EU, 호주와 같은 축산 선진국과의 자유무역협정(FTA) 체결에 따른 축산물 시장 개방으로 축산물의 수입량이 증가함에 따른 영향으로 보인다. 2018년 현재 축산물의 자급률은 63.0%로 2012년 68.2%에 비해 5.2%p 감소한 것으로 나타났다. <그림 2-2>에 따르면 2011년 쇠고기의 경우 28만 9천 톤을 수입하였으나 2018년 41만 7천 톤을 수입하여 연평균 3.26%가 증가하였다. 돼지고기의 경우 2018년 46만 3천 톤을 수입하여 2012년 37만 톤에 비해 연평균 5.38% 꾸준히 증가한 것으로 나타났다. 닭고기 역시 2018년 16만 3천 톤으로 2012년 13만 1천 톤에 비해 연평균 3.17%씩 증가한 것으로 나타났다.

<그림 2-2> 연도별 축산물 수입량



자료 : 농림축산식품부

우리나라로 수입되는 축산물은 냉동 상태와 냉장 상태. 수입 쇠고기는 <표 2-1>과 같이 냉동 상태로 수입되는 쇠고기가 냉장 상태로 수입되는 쇠고기보다 많은 것으로 나타났다. 2019년 총 42만 6,600톤 중 79.5%에 해당하는 33만 9,200톤을 냉동 상태로 수입하였으며, 20.5%에 해당하는 8만 7,400

톤을 냉장 상태로 수입하였다. 2009년부터 2019년까지의 냉동과 냉장의 비율은 평균 81.7%와 18.3%로 국내에 수입되는 쇠고기는 냉동 상태가 많은 것으로 집계되었다.

<표 2-1> 연도별 수입 유형별 쇠고기 수입량

단위 : 천 톤

	2009	2010	2011	2012	2013	2014	2015	2016	2017	2018	2019
냉동	163.8	203.0	242.3	212.5	216.3	234.2	246.0	301.2	265.7	326.5	339.2
냉장	34.1	42.1	47.1	40.2	40.3	46.3	51.3	60.3	78.6	89.2	87.4
총량	197.9	245.1	289.4	252.7	256.6	280.5	297.3	361.5	344.3	415.7	426.6

자료 : 한국육류유통수출협회

한편 냉동 상태로 수입되는 쇠고기는 미국, 호주, 캐나다 등 여러 국가로부터 수입된다. <표 2-2>는 연도별 원산지별 수입 냉동 쇠고기 수입량을 나타낸 것이다. 2019년 기준 미국산과 호주산 쇠고기가 전체 수입량에 92.56%를 차지하였다. 미국으로부터 수입된 쇠고기는 2009년 4만 5,027톤에서 2019년 18만 2,936톤으로 연평균 15.23%씩 증가하였으며, 동기간 호주산 쇠고기는 각각 11만 6,174톤과 13만 1,074톤으로 연평균 3.09%씩 증가하였다. 한편 2017년 이전까지는 호주산 쇠고기가 가장 많이 수입된 반면, 2017년 이후 미국산 쇠고기가 가장 많이 수입되었다. 이러한 미국산 쇠고기 수입량의 급격한 증가는 관세율과 미국산 쇠고기에 대한 소비자 인식의 개선으로 인한 것으로 판단된다. 미국의 관세율은 한·미 FTA 이후 꾸준히 낮아지고 있으며, 2019년 18.6%의 세율로 호주보다 맞게 유지되고 있다. 또한 과거 미국의 광우병 발생으로 인해 미국산 쇠고기에 대한 소비자의 부정적인 시각을 개선하기 위한 수출업체들의 마케팅과 검역 관리로 미국산 쇠고기에 대한 수요가 증가하는 것으로 판단된다.

<표 2-2> 연도별 원산지별 냉동 쇠고기 수입량

단위 : 톤

합계	미국	호주	캐나다	뉴질랜드	멕시코	기타
2009	49,973	116,714	-	30,162	1,007	-
2010	90,569	121,790	-	30,947	1,780	-
2011	107,202	145,170	-	33,121	3,893	-
2012	99,929	123,964	1,832	25,554	1,283	162
2013	89,239	142,797	1,492	22,297	109	682
2014	104,953	150,882	2,739	20,964	118	856
2015	112,431	164,063	800	18,169	247	1,555
2016	153,181	177,530	5,556	20,294	1,355	3,615
2017	168,502	149,935	4,511	17,669	1,395	2,259
2018	219,769	167,454	3,821	18,264	4,301	2,076
2019	237,624	163,158	5,772	12,760	6,192	1,120

자료 : 한국육류유통수출협회

한편 연도별 부위별 쇠고기 수입량은 <표 2-3>과 같다. 수입 쇠고기는 갈비, 등심, 목심, 사태, 설도, 안심, 앞다리, 양지, 우둔, 채끝 등으로 구분되어 수입되며, 2009년부터 갈비가 가장 많은 양을 수입하였다. 2009년 기준 갈비가 6만 5,672톤으로 가장 많이 차지하였으며, 그 뒤로 등심, 앞다리, 양지 등의 순으로 많은 수입량을 보였으나, 2019년 기준 역시 갈비가 13만 8,861톤으로 가장 많이 차지하였으며, 그 뒤로 양지, 등심, 앞다리 등의 순서로 수입량이 많은 것으로 파악되었다.

<표 2-3> 연도별 부위별 쇠고기 수입량

단위 : 톤

구분	2009	2010	2011	2012	2013	2014	2015	2016	2017	2018	2019
갈비	65,672	87,250	96,407	96,806	89,694	102,657	99,991	114,671	119,188	126,372	138,861
등심	23,529	30,217	35,833	31,168	40,444	40,287	36,220	42,827	29,288	43,208	37,499
목심	8,217	14,265	20,224	11,701	11,108	13,984	11,780	23,386	13,780	22,566	21,916
사태	5,513	4,992	5,221	3,609	2,863	3,890	2,463	4,048	5,689	5,532	3,557
설도	3,575	3,609	5,396	3,250	3,406	3,210	4,808	6,435	5,427	8,035	8,211
안심	395	726	545	413	393	335	195	485	118	260	272
앞다리	18,639	20,355	22,446	15,030	18,748	21,355	23,315	35,920	28,306	36,903	37,034
양지	17,072	19,671	25,241	25,433	20,053	16,905	35,511	31,156	33,044	48,817	52,839
우둔	10,127	9,450	13,053	8,268	9,946	11,120	9,595	16,479	8,900	14,529	13,141
채끝	622	573	496	376	399	439	584	908	595	1,027	958
기타	10,368	11,898	17,435	15,468	19,162	20,057	21,629	24,904	21,330	19,282	24,952

자료 : 한국육류유통수출협회

한편, 수입 돼지고기의 경우에는 수입 쇠고기와 같이 우리나라로 수입되는 냉동과 냉장 중 냉동이 더 많이 수입되는 것으로 확인되었다(표 2-4). 2019년 기준 냉동 돼지고기로 수입되는 양이 40만 100톤, 냉장 돼지고기는 2만 1,200톤으로 나타나 각각 94.96%, 5.04%로 냉동 형태로 수입된 양이 더 많은 것으로 나타났다.

<표 2-4> 연도별 수입 유형별 돼지고기 수입량

단위 : 천 톤

	2009	2010	2011	2012	2013	2014	2015	2016	2017	2018	2019
냉동	198.6	167.3	344.7	255.8	173.2	259.8	340.7	298.4	347.0	439.7	400.1
냉장	11.3	12.2	25.6	20.3	11.8	14.1	17.2	20.1	22.3	23.8	21.2
총량	209.8	179.5	370.3	276.2	185.0	273.9	357.9	318.5	369.2	463.5	421.3

자료 : 한국육류유통수출협회

또한 <표2-5>의 연도별 부위별 돼지고기 수입량을 살펴봤을 때, 수입량의 대부분 삼겹살과 앞다리가 차지하고 있는 것으로 나타났다. 2019년 기준 15만

2,100톤으로 앞다리가 가장 많이 수입되었으며, 삼겹살, 목심, 등심 등의 순으로 많이 수입되었다. 그러나 2009년부터 수입된 부위별 돼지고기 수입량의 총량은 삼겹살, 앞다리, 갈비, 등심, 뒷다리 등의 순으로 많이 수입된 것으로 확인되었다.

<표 2-5> 연도별 부위별 돼지고기 수입량

단위 : 천 톤


구분	2009	2010	2011	2012	2013	2014	2015	2016	2017	2018	2019
삼겹살	98.6	99.7	139.4	122.1	90.0	132.5	137.2	135.7	157.3	168.6	150.6
앞다리	63.5	38.0	118.5	98.2	64.1	88.2	146.1	122.0	147.3	197.0	152.1
목심	27.2	22.4	44.1	25.2	14.0	27.9	30.8	28.5	30.4	42.7	59.3
갈비	4.9	4.7	10.6	5.8	3.5	7.1	7.1	4.4	6.4	10.1	10.8
뒷다리	1.0	0.9	15.8	1.7	0.2	2.2	9.5	0.3	2.0	5.6	9.6
등심	1.0	1.2	9.6	2.5	1.2	1.1	6.9	5.4	2.0	13.9	15.9
기타	2.4	0.3	6.7	0.4	0.1	0.8	3.1	2.0	1.6	1.8	1.9

자료 : 한국육류유통수출협회

월별 국내산 쇠고기와 돼지고기의 가격의 추이는 <그림 2-3>과 <그림 2-4>와 같다. 한우의 소비자 가격은 2012년부터 2019년까지 변동이 있지만, 꾸준히 상승하는 추이를 보였다. 2012년 02월 100g당 4,009원에서 2019년 9월 5,639원으로 연평균 4.99% 상승한 것으로 나타났다. 반면 <그림 2-4>의 국내산 삼겹살 소비자 가격은 상대적으로 변동이 심한 것으로 나타났다. 2013년 03월 가장 낮은 가격 1,298원, 2017년 08월 2,333원으로 가장 높은 가격을 기록하였다. 국내산 삼겹살의 가격은 여름철에 상대적으로 가격이 상승하고, 겨울철에는 상대적으로 가격이 하락하는 것으로 보인다. 돼지고기는 일반적으로 공급 측면에서 계절성을 갖기 때문으로 판단된다²⁾.


2) 정민국 외(2011)에 따르면 돼지는 7~8월의 여름철 더위로 인하여 수태율이 크게 하락하여, 다음 해 5~6월 산지 가격을 상승시키며, 겨울철 수태율 상승은 다음 해 10월~11월 출하물량의 증가로 연중 산지 가격의 최저치를 형성한다. 산지 가격이 소매의 가격에 영향을 미치므로 소비자 가격에도 계절성을 보이는 경향이 있다.

〈그림 2-3〉 월별 한우 갈비 소비자 가격 추이



자료 : 농협


〈그림 2-4〉 월별 국내산 삼겹살 소비자 가격 추이



자료 : 농협


<그림 2-5>와 <그림 2-6>은 월별 수입 축산물의 가격 추이이다. <그림 2-5>는 수입 쇠고기 중 미국산 갈비의 소비자 가격의 가격 추이를 나타낸 것으로, 수입량의 증가에도 불구하고 2012년 1월 1,655원에서 2019년 12월 2,515원으로 미국산 갈비의 소비가 가격이 연평균 6.16%씩 상승한 것으로 나타났다. <그림 2-6>의 수입 삼겹살의 소비자 가격 추이 역시 상향하는 것으로 나타났으며, 2012년 1월 917원에서 2019년 12월 1,601원으로 연평균 8.29%씩 상승한 것으로 나타났다.

<그림 2-5> 월별 미국산 갈비 소비자 가격 추이



자료 : 농협

<그림 2-6> 월별 수입 삼겹살 소비자 가격 추이



자료 : 농협

한우 갈비에 대비 미국산 갈비의 가격은 평균 47.12% 정도 수준이었으며, 국내산 삼겹살에 대비 수입 삼겹살의 가격은 평균 54.61% 정도 수준으로 나타났다. 이렇듯 국내산 가격에 대비 수입 축산물의 가격이 낮고 변동성이 낮으므로, 수입 축산물에 대한 식품업체, 특히 HMR(간편식) 시장의 수요가 증가하고 있다.

제3장 분석 모형

본 연구는 크게 단변량적 접근 방법과 다변량 접근 방법으로 나누어 분석을 진행하였다. 단변량 모형의 경우 가격 변동성만을 이용하여 GARCH 모형과 LSTM 모형으로 가격 변동성을 예측하였다. 다변량 모형의 경우, 수입 축산물의 가격 변화에 미치는 요인을 반영하여 Multivariate GARCH 모형과 LSTM 모형, GARCH-LSTM 결합모형을 통해 수입 축산물의 가격 변동성을 예측·분석하였다.

제1절 수입수요함수

수입 수요에 대한 전통적인 접근 방법은 소득과 수입가격을 중심으로 추정하였다(식(1)). 그러나 다양한 연구를 통해 수입 수요를 단순히 수입국의 소득과 수입가격을 통해 분석할 경우, 수입 수요에 대한 소득 탄력성이 상승 편향이 있다는 연구들이 발표되면서 다양한 시장의 상황을 반영하여 수입 수요를 추정하는 모형이 제안되었다.

$$Q_I = f(P_I, Y) \quad (1)$$

대표적으로 Helpman and Krugman(1985)와 Krugman(1989)에서 제안한 신 무역이론(new trade theory)이 있다. 신 무역이론에 따르면 국가는 교역 조건의 역효과 없이 신제품을 수출함에 따라 성장함을 언급하였다. 더불어 수입 수요에 새로운 상품에 대한 변화를 포함해야 함을 증명하였다. 그러나 이러한 접근 방법에는 기본 가정인 새로운 상품에 대한 국내 재화의 영향은 제외하였으며, 상품의 다양성은 국가 단위의 수준에서 정의해야 한다는 점에서 한계를 보여주었다.

이후 여러 연구에서는 신 무역이론의 두 조건으로 인해 수입 수요에 대한 소득 탄력성이 역시 편향되어 있음을 증명하였다. 대표적으로 Feenstra(1994)는 기존의 대체 탄력성에 새로운 수입가격을 포함하여 분석

하였으며, Mann and Pluck(2007)과 Chinn(2010)은 제품의 다양성을 반영하지 않고 수입 수요를 추정하였을 때, 편향이 발생할 수 있음을 증명하였다.

따라서 본 연구에서는 연구의 목적과 수입 수요함수에 관한 선행 연구³⁾를 고려하여, 수입 수요에 미치는 요인을 선정하였다(식(2)). 수입 수요량을 수입 축산물의 소비자 가격, 국내산 돼지고기 소비자 가격, 경기종합지수, 원·달러 환율을 통해 판단하였으며, 본 연구의 목적에 맞게 역으로 가격의 변동성을 추정하고자 한다(식(3)).

$$Q_I = f(P_I, P_D, Y, exch) \quad (2)$$

$$P_I = f(Q_I, P_D, Y, exch) \quad (3)$$

식(2)의 Q_I 는 수입 축산물(미국산 갈비/수입 삼겹살)의 수입량을 의미하며, P_I 는 수입 축산물의 소비자 가격을 의미한다. 또한 P_D 는 수입 축산물의 대체재 가격을 의미하며, Y 는 소득을 의미한다. 마지막으로 $exch$ 는 환율을 의미한다. 식(3)은 위의 식(2)의 가격 변수를 종속변수로 하는 역수요 체계(Inverse Demand System)의 형태로 변환하였다.

3) 김양중·김원년(2013)은 중국 축산물과 수산물의 수입 수요에 대한 분석을 분석 대상(수산물/축산물)의 수입량, 수입 가격, 경기 종합지수, 원/달러 원·달러 환율(종가평균) 등을 이용하여 분석한 바 있다. 또한 강현수(2011)은 국내의 쌀 수입량을 국내 실질 소득, 국내 쌀 가격, 대체재(밀, 옥수수)의 가격, 국내 총생산, 인플레이션(%), 인구 증가율(%) 등을 고려하여 분석한 바 있다.

제2절 GARCH Model

1. GARCH Model

GARCH 모형은 Engle(1982)이 제안한 ARCH 모형을 Bollerslev(1986)가 일반화한 모형이다. ARCH 모형 이전의 시계열 모형에서는 시간에 따라 분산이 일정함을 가정하고 분석하였다. 그러나 시계열 자료는 분산이 크게 변동한 후 커진 분산 값이 유지되거나, 분산 값이 작아진 후, 작아진 분산 값이 유지되는 변동성 군집 현상(volatility clustering)이 발생하면서 기존 시계열 모형을 통해 정확한 분석을 하지 못하는 경우가 발생하였다.

Engle(1982)가 분산 값이 자신의 과거값에 조건부로 의존하는 ‘이분산 현상(heteroskedasticity)’을 모형화하여 ARCH 모형을 고안하였다. 이는 분산이 시점 t 에 의존하므로, $t-1$ 기까지의 정보를 이용하여 변동성을 예측함에 따라 예측 오차를 줄일 수 있는 장점이 있다. Engle(1982)가 고안한 시차 p 까지 추정하는 ARCH(p) 모형은 아래와 같은 식(4)~(6)으로 구성되어 있다.

$$y_t = \mu_t + \sigma_t \eta_t, \quad \eta_t \sim N(0,1) \quad (4)$$

$$\epsilon_t = \sigma_t \eta_t, \quad \epsilon_t | \chi_{t-1} \sim N(0, \sigma_t^2) \quad (5)$$

$$\begin{aligned} \sigma_t^2 &= \alpha_0 + \alpha_1 \epsilon_{t-1}^2 + \dots + \alpha_p \epsilon_{t-p}^2 \\ &= \alpha_0 + \sum_{i=1}^p \alpha_i \epsilon_{t-i}^2 \end{aligned} \quad (6)$$

식(4)은 시계열 y_t 의 평균 방정식을 통해 예측할 수 있는 μ_t 와 예측할 수 없는 오차 ϵ_t 로 구성되어 있다. 식(5)의 ϵ_t 는 시점 $t-1$ 에서 모든 정보가 알려진 조건에서 정규분포를 따름을 의미한다. 마지막 식(6)은 시점 t 에서의 조건부 분산(σ_t^2)은 과거 시점 오차의 제곱에 영향을 받는다.

그러나 ARCH(p) 모형을 추정하는 과정에서 시차 p 가 길어짐에 따라 추정 계수가 많아지는 문제가 발생하여, Bollerslev(1986)는 ARCH(p)을 일반화한 GARCH 모형을 고안하였다. GARCH(p, q) 모형은 다음의 식(7)~(9)와 같다.

$$y_t = \mu_t + \sigma_t \eta_t, \quad \eta_t \sim N(0,1) \quad (7)$$

$$\epsilon_t = \sigma_t \eta_t, \quad \epsilon_t | \chi_{t-1} \sim N(0, \sigma_t^2) \quad (8)$$

$$\begin{aligned} \sigma_t^2 &= \alpha_0 + \alpha_1 \epsilon_{t-1}^2 + \dots + \alpha_p \epsilon_{t-p}^2 + \beta_1 \sigma_{t-1}^2 + \dots + \beta_q \sigma_{t-q}^2 \\ &= \alpha_0 + \sum_{i=1}^p \alpha_i \epsilon_{t-i}^2 + \sum_{j=1}^q \beta_j \sigma_{t-j}^2 \end{aligned} \quad (9)$$

GARCH(p, q) 모형은 ARCH(p) 모형을 일반화한 모형이므로, GARCH(p, q) 모형의 식(7)과 식(8)은 ARCH(p) 모형의 식(4)~(5)와 동일하다. 식(9)는 조건부 분산은 과거 오차의 제곱과 조건부 분산으로 구성되어 있다. GARCH 모형의 가장 기본적인 형태인 GARCH(1,1)은 다음 식(10)과 같다.

$$\sigma_t^2 = \alpha_0 + \alpha_1 \epsilon_{t-1}^2 + \beta_1 \sigma_{t-1}^2 \quad (10)$$

식(10)의 방정식에서 오른쪽 항의 시차를 둔 오차항을 연속적으로 대체하면 다음 식(11)과 같은 형태의 방정식을 도출할 수 있다.

$$\sigma_t^2 = \frac{\alpha_0}{1-\beta_1} + \alpha_1 (\epsilon_{t-1}^2 + \beta_1 \epsilon_{t-2}^2 + \beta_1^2 \epsilon_{t-3}^2 + \beta_1^3 \epsilon_{t-4}^2 + \dots) \quad (11)$$

식(11)과 같은 변형을 통해 시점 t 의 분산은 모든 과거 오차의 제곱에 따라 달라짐을 알 수 있다. 따라서 GARCH 모형은 적은 수의 계수를 사용하여 긴 시차의 ARCH 모형을 추정할 수 있다.

ARCH 모형과 GARCH 모형은 공통적인 2가지 제약 조건을 존재한다. 두 모형은 모든 계수가 비음(non-negative) 조건이 존재한다. 이는 분산이 제곱의 합으로 구성되어 있기 때문이다. 오차항의 약정상성(weakly stationary)을 만족하기 위하여 ' $\alpha + \beta < 1$ '을 만족하여야 한다. 이 두 조건을 만족시키지 못하면 모형의 적합도가 감소한다.

2. Multivariate GARCH Model

Multivariate GARCH(이하 MGARCH) 모형은 동적 상관관계에 있는 변수들의 조건부 이분산을 고려한 다변량 모형이다. 자기 회귀 조건부 이분산 모형인 Engle(1982)의 ARCH 모형과 ARCH 모형을 일반화한 Bollerslev(1986)의 GARCH 모형은 개별 시장의 분산을 각 시장의 오차항과 조건부 이분산으로 설명한다. 변동성을 예측하는 연구에는 ARCH 모형과 GARCH 모형을 이용하는 것이 일반적이다. 그러나 ARCH 모형과 GARCH 모형은 하나의 변수를 이용하여 분석함에 따라 시장의 변화를 파악하기에 부적합할 수 있다. 따라서 다양한 시장 변수를 이용하여 변수 간의 상호관계를 반영하여 정확한 시장 변화를 파악하기 위하여 시장의 상황을 모형 내에 반영할 수 있는 다변량적 접근이 필요하다.

Bollerslev et al.(1988)의 MGARCH 모형에서 종속변수의 조건부 공분산 행렬(Conditional Covariance matrix)은 동태적 구조를, 조건부 평균(Conditional Mean)은 VAR(Vector Autoregressive) 구조를 나타내며, MGARCH의 일반적인 형태는 다음과 같다.

$$p_t = \bar{p}_t + e_t \quad (12)$$

$$e_t = H_t^{1/2} v_t \quad (13)$$

식(12)는 p_t 의 평균 방정식을 의미하며, p_t 는 k 개의 가격 벡터 $p_t = (p_{1t}, \dots, p_{kt})^T$ 를 의미한다. p_t 는 \bar{p}_t 와 e_t 로 구성되어 있으며, $\bar{p}_t = E(p_t | F_{t-1})$ 는 주어진 F_{t-1} 에 대한 조건부 평균이며, F_{t-1} 는 t 이전의 정보를 의미한다. e_t 는 오차항을 의미하며, 이는 식(13)과 같이 나타낼 수 있다. 오차항 e_t 는 H_t 와 v_t 로 구성되어 있으며, H_t 는 조건부 분산인 변동성(Volatility)을 의미하며, $H_t = COV(e_t | F_{t-1}) = COV(p_t | F_{t-1})$ 인 $k \times k$ 조건부 양치 공분산 행렬(Positive Definite Covariance Matrix)이다. v_t 는 i.i.d(Independently and Identically Distribution)인 확률 변수이다. 즉 v_t 에 대한 $E(v_t) = 0$, $Var(v_t) = I_N$ 이며, I_N 은 N 차 항등 행렬을 의미한다.

$$H_t = D_t R_t D_t \quad (14)$$

$$D_t = \begin{pmatrix} \sigma_{1,t}^{1/2} & 0 & \dots & 0 \\ 0 & \sigma_{2,t}^{1/2} & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \sigma_{m,t}^{1/2} \end{pmatrix} \quad (15)$$

$$R_t = \begin{pmatrix} 1 & \rho_{12} & \dots & \rho_{1m} \\ \rho_{21} & 1 & \dots & \rho_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{m1} & \rho_{m2} & \dots & 1 \end{pmatrix} \quad (16)$$

H_t 는 식(14)과 같이 D_t 와 R_t 로 이루어져 있으며, D_t 는 식(15)와 같이 t 시점에 k 개의 변수의 조건부 표준편차($\sigma_{m,t}^{1/2}$)의 대각행렬로 이루어져 있다. 또한 R_t 는 변수 사이의 상관관계수 행렬로 식(16)과 같이 이루어져 있다.

Bollerslev et al.(1988)의 MGARCH 모형은 벡터의 차원에 의해 추정해야 할 모수가 결정된다. k 가 증가할수록 추정해야 하는 모수가 급격하게 증가하며, 그로 인해 추정된 계수들에 의한 의미 해석이 쉽지 않다는 단점을 가지고 있다.

Bollerslev et al.(1988)의 MGARCH의 변수가 증가할수록 추정해야 하는 모수가 많아진다는 단점을 보완하기 위하여, Bollerslev(1990)는 CCC(Constant Conditional Correlation) MGARCH 모형을 제안하였다. CCC-MGARCH 모형은 k 개의 조건부 상관관계수(ρ_{ij})를 상수를 고정하므로 추정할 모수의 수를 감소시켰다.

$$R = (\rho_{ij}), \forall t \quad (17)$$

$$H_t = D_t R_t D_t = (\rho_{ij,t} \sqrt{\sigma_{ii,t} \sigma_{jj,t}}) \quad (18)$$

MGARCH와 달리 CCC-MGARCH 모형에서는 식(17)의 R 을 시간에 영향을 받지 않는 조건부 상관관계수 ρ_{ij} 로 정의했다. R 이 고정된 조건부 상관관계수이기 때문에 H_t 역시 식(18)과 같이 나타낼 수 있다. 식(18)의 H_t 에서 $\sigma_{ii,t}$ 는 시점 t 에서의 변수 i 의 조건부 분산을 의미하며, 단변량 GARCH 모형을 통해 추정할 수 있다. GARCH(1,1) 모형을 따르는 CCC 모형의 경우, 개별 D_t

의 조건부 분산은 다음의 식(19)과 같다.

$$\sigma_{ii} = \omega_i + \alpha_i e_{i,i-1}^2 + \beta_i \sigma_{ii,t-1}, \quad i = 1, 2, \dots, k \quad (19)$$

식(19)에서 w_i , α_i 와 β_i 는 비음(nonnegative) 조건을 충족시켜야 하며, $\alpha_i + \beta_i < 1$ 의 조건을 충족해야 한다. MGARCH 모형에서 σ_{ii} 와 공분산 σ_{ij} 를 모두 추정하기 때문에 $2k^2$ 개의 모수를 추정하는 반면, CCC-GARCH 모형은 k 개의 GARCH 모형의 모수 $2k$ 개와 $k(k-1)/2$ 의 조건부 상관계수를 추정하여 총 $k(k+3)/2$ 개를 추정함으로써 다수의 모수를 추정해야 하는 MGARCH 모형의 단점을 보완하였다.

CCC-GARCH 모형은 위에서 언급한 바와 같이 조건부 상관계수를 고정하여 추정이 복잡한 MGARCH 모형을 단순화시킬 수 있었다. 그러나 이는 상관계수의 동태성을 고려하지 못한다는 단점을 야기하였고, 이를 보완하기 위해 Engle(2002)와 Tse and Tsui(2002)는 DCC(Dynamic Conditional Correlation)-GARCH 모형을 제안하였다.

Engle(2002)이 제안한 DCC-GARCH 모형은 CCC-GARCH 모형의 단점으로 제시된 시간의 흐름에 따라 변수 간의 상관계수를 고려할 수 있도록 변화시켰다. DCC-GARCH 모형은 식(20)~(22)로 정리할 수 있다.

$$H_t = D_t^{1/2} R_t D_t^{1/2} \quad (20)$$

$$R_t = \text{diag}(Q_t)^{-1/2} Q_t \text{diag}(Q_t)^{-1/2} \quad (21)$$

$$Q_t = (1 - \lambda_1 - \lambda_2)R + \lambda_1 \widetilde{e_{t-1}} \widetilde{e_{t-1}'} + \lambda_2 Q_{t-1} \quad (22)$$

식(21)은 변동성을 표현한 식(20)의 R_t 를 구조화한 식이며, R_t 은 동태적 조건부 상관관계를 나타내는 행렬이다. 여기서 Q_t 는 식(22)로 표현할 수 있다. Q_t 는 조건부 상관관계의 움직임을 표현한 방정식이며, R 은 표준 잔차의 비조건부 분산공분산 행렬을 나타내며, 이 역시 λ_1 과 λ_2 는 비음(non-negative) 조건을 충족시켜야 하며, $\lambda_1 + \lambda_2 \leq 1$ 을 만족해야 한다.

Engle(2002)와 Tse and Tsui(2002)는 모수의 수를 크게 줄이면서 시변하

는 조건부 공분산을 추정할 수 있는 DCC-GARCH 모형은 시계열 변동성과 상관관계에 관한 연구에서 널리 사용되었다. 해당 모형은 모형 내 조건부 상관관계수의 모수가 동일한 동적 움직임을 따라야 하는 조건이 있음에도 추정의 편리함에 의해 다수의 연구가 이루어졌다(Creti et al., 2013; Daumas et al., 2017, 박관희 외, 2011; 김상환, 2013; 주영찬, 제상영, 2013; 박세린, 백창룡, 2014). 본 연구에서는 Engle(2002)의 DCC-GARCH 모형을 통해 수입 축산물 가격의 변동성을 추정하여 인공신경망과 변동성 예측력을 비교하고자 한다.

제3절 인공신경망 모형

인공신경망(artificial neural network, ANN)은 인공지능 계열의 결정 트리(decision tree), 서포트 벡터 머신(support vector machine, SVM)과 같은 기계 학습(machine learning)기법 중 하나이다. 인공신경망의 구조는 인간의 뇌 구조에서 착안하여, 수학적으로 구현된 통계학적 알고리즘이다. 인공신경망은 생물학적 메커니즘을 모방한 것으로, 인간의 뇌에 일부인 뉴런과 같은 역할을 하는 노드(node)를 가지고 있다. 이 노드를 가중치를 통해 연결하는데, 가중치는 생명체의 시냅스 연결 강도와 동일한 역할을 한다.

초기의 인공신경망 모형은 McCulloch and Pitts(1943)에 의해 최초로 시도 되었으며, Hebb(1949)의 연구에서 연결 가중치 조정을 위한 학습 규칙을 최초로 시도하였다. 초기의 인공신경망은 제안된 당시 여러 연구가 진행되었으나, 당시의 컴퓨터 성능 및 여러 제한 조건으로 인하여 이후 연구가 진행되지 않았다. 최근 컴퓨터의 성능 향상 및 인공지능의 발전, 여러 알고리즘의 개발로 인하여 인공신경망을 이용한 분석이 증가하고 있다. 특히 Hopfield(1986)의 역전파 알고리즘(Back-propagation algorithm)의 제안을 통하여 다시 주목받고 있다. 이러한 인공신경망은 시계열 자료 분석뿐만 아니라 로봇 제어, 컴퓨터 수치 제어, 필터링 등의 데이터 처리, 이미지 분류 및 분석, 음성어 처리, 자연어 분석 등 다양한 분야에서 사용되고 있다.(King and Hwang, 1989; Jiang et al., 2010; Eski et al., 2011; He et al., 2015; 이건일·이종혁, 2015; 김학수 외, 2017)

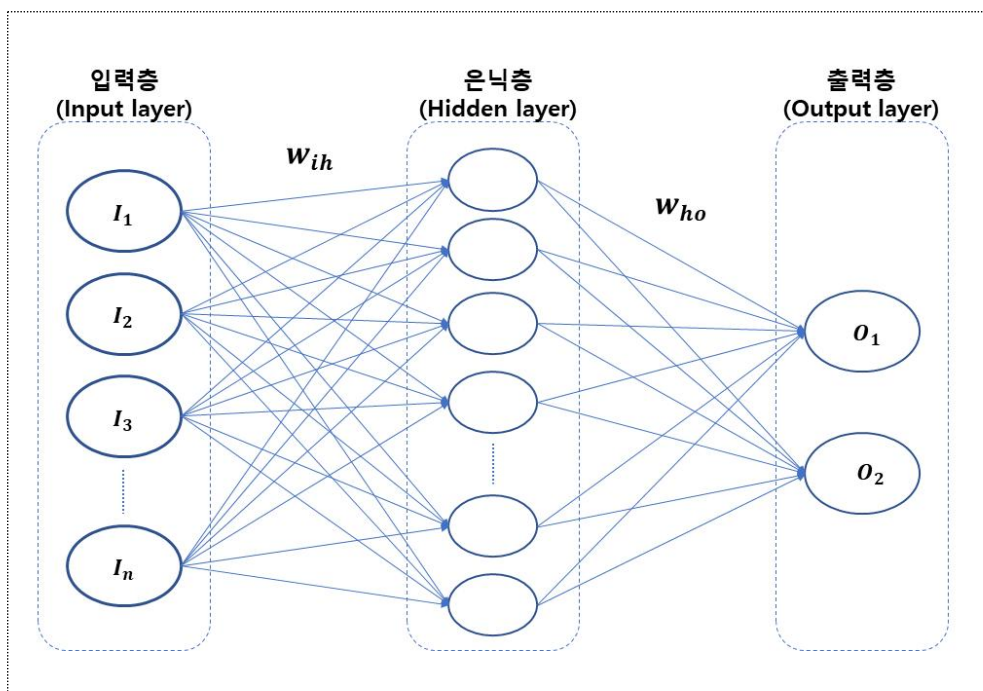
인공신경망 알고리즘의 한계를 극복하는 다양한 모형의 개발로 많은 연구가 진행되고 있으며, 이러한 흐름에 따라 본 연구에서는 시계열 분석에서 많이 사용되는 순환신경망, 특히 Hochreiter and Schmidhuber(1997)에 의해 제안된 LSTM 모형을 이용하여 연구하고자 한다.

1. 다층 퍼셉트론 인공신경망(Multi-Perceptron Neural Network)

<그림 3-1>은 인공신경망의 기본적인 구조인 다층 퍼셉트론 인공신경망(Multi-Perceptron Neural Network)이며, 입력층(input layer), 은닉층(hidden

layer), 출력층(output layer)으로 구성되어 있으며, 입력층은 시스템 외부로부터 입력 자료(input data)를 받아들여, 시스템 내부로 전달하는 역할을 하며, 은닉층에서 전달받은 자료를 이용하여 분석한 뒤, 출력층을 통해 결과를 도출하는 형식을 가지고 있다.

<그림 3-1> 인공신경망의 기본 구조



다층 퍼셉트론 인공신경망은 진행 방향에 따라 순전파 인공신경망과 역전파 인공신경망으로 구분한다. 순전파 인공신경망(feed-forward propagation)은 <그림 3-1>의 설명과 같이 입력층에서 은닉층을 거쳐 출력층 방향으로 순차적으로 연산하는 방식을 의미한다. 이러한 순전파 인공신경망은 다음 나오는 역전파 인공신경망(back propagation)과 대조되는 인공신경망이다. 순전파 인공신경망은 최적화 가중치를 찾기 어려운 단점이 있으며, 이에 따라 역전파 인공신경망이 제안되었다.

역전파 인공신경망은 Hopfield(1986)에 의해 인공신경망에 역전파 알고리즘을 접목하여 오차를 감소시킨 방법이다. 역전파 알고리즘은 인공신경망

의 순전과 인공신경망을 통해 도출된 결과와 실제 값을 비교하여 발생한 오차를 미분의 연쇄법칙을 통해 진행방향의 역방향인 출력층에서 은닉층, 은닉층에서 입력층으로 발생 오차에 대한 가중치를 추정한다. 이를 통해 다시 가중치를 수정하여 정방향(입력층→출력층)으로 결과 값을 나타낸다. 역전과 인공신경망은 이러한 일련의 과정을 반복함으로 인공신경망의 정확도를 높인다.

2. 순환신경망(Recurrent Neural Network, RNN)

시계열 자료에서 인접한 시점의 값은 서로 밀접한 연관이 있다. 각 시점의 값을 독립적인 특징으로 분석하게 되면, 자료의 중요한 특성을 분석할 수 없게 된다. 인공신경망의 방법론으로 이러한 특징을 포착할 수 있는 가장 일반적인 방법이 순환 신경망(recurrent neural network)이다.

순환신경망(Recurrent Neural network, RNN)은 대표적인 역전과 알고리즘을 사용하는 인공신경망이다. 순환신경망은 입력된 자료(Input)와 출력되는 자료(Output) 사이의 신경망이 재귀하는 구조를 갖는다. 반복을 통하여 출력된 값과 실제 값 사이의 오차를 기울기 하강법(Gradient Descent)을 이용하여 계산한다. 오차로부터 역전과 과정을 통해 학습 변수에 오차를 반영한 변수의 가중치를 수정하여 다시 추정한다. 이와 같은 일련의 과정을 반복하여, 오차를 감소시켜 정확도를 높이게 된다. 따라서 입력하는 자료의 횟수, 출력되는 자료의 횟수, 재귀하는 횟수에 따라 다양한 형태의 모형으로 변형이 가능하다(Karpathy, 2015; 이기창, 2017).


<그림 3-2>는 순환신경망의 일부를 모식화한 그림이다. 또한 식(25)과 (26)은 순환신경망 내부에서 계산되는 방법을 나타낸다. x_t 는 시점 t 의 신경망에 입력되는 자료(input data)를 의미하며, y_t 는 시점 t 의 신경망에서 출력되는 결과 (output data)를 의미한다. h_t 는 시점 t 에서의 은닉상태(hidden state)를 의미하며, 학습 변수로써 시점 $t+1$ 로 전달되는 정보이다. 식(25)은 시점 t 에서 출력 결과인 y_t 를 도출하는 방법으로써, W_{hy} 는 가중치를, b_y 은 편향(bias)⁴⁾을 의미한다. 식(26)은 시점 t 에서 은닉상태 h_t 를 도출하는 방법으로써, 이전 시점 $t-1$ 에서의 전달받은 은닉상태 h_{t-1} 와 시점 t 의 입력 자료 x_t

를 각각의 가중치(W_{hh} , W_{xh})를 이용하여 하이퍼볼릭 탄젠트 함수(hyperbolic tangent, \tanh)⁵⁾로 변환하여 시점 t 의 은닉상태 h_t 를 계산한다.

$$y_t = W_{hy}h_t + b_y \quad (25)$$

$$h_t = \tanh(W_{hh}h_{t-1} + W_{xh}x_t + b_h) \quad (26)$$

<그림 3-2> 순환신경망(RNN) 모식도



이러한 과정은 출력 결과와 실제 값 사이의 오차인 기울기를 기울기 하강법을 이용하여 계산하여 학습 결과에 역전파 과정을 거쳐 학습 변수에 오차를 반영하도록 한다.

이러한 과정에서 추정해야 할 데이터의 길이가 길어질 경우, 현재 시점(t) 결과를 출력하기 위해 반영해야 할 이전 시점($t-n$)이 증가하게 됨에 따라 기울기가 사라지는 현상이 발생한다. 순환신경망의 특성에 따라 가중치를 계속 곱하기

4) b_y , 편향(bias)는 인공신경망 모델을 추정하는 과정에서 과적합(overfit)을 방지하는 도구로써 사용된다.

5) $\tanh x = \frac{\sinh x}{\cosh x} = \frac{e^x - e^{x-1}}{e^x + e^{x-1}}$

때문에 불안정성이 발생한다. 이를 장기 의존성(long-term dependency) 문제라고 한다. 이러한 문제를 해결하기 위해 장기 기억을 활용하는 갱신 공식을 추가하여 은닉 벡터를 갱신하는 방법으로 Hochreiter and Schmidhuber(1997)는 LSTM(Long Short Term Memory) 모델을 제안하였다.

3. LSTM(Long Short Term Memory)

Long Short Term Memory(LSTM) 모델은 순환신경망의 하나로서, 기존 순환신경망의 단점인 장기 의존성 문제를 해결하고자 고안되었다(Hochreiter and Schmidhuber, 1997). LSTM 모델은 순환신경망과 같이 반복을 통하여 이전 정보를 반영한다. 그러나 순환신경망의 장기 의존성을 해결하기 위하여 LSTM 모델은 이전 정보 중 탈락시킬 부분과 유지할 부분을 수학적으로 결정하여, 새로운 정보와 결합한다. 즉, LSTM 모델의 연산은 장기 기억에 기록되는 자료를 세밀하게 제어하도록 고안되었다.

<그림 3-3>은 LSTM 모델의 일부를 모식화한 것이며, 식(27)~(32)는 LSTM 모델에 사용되는 식을 나타낸다. LSTM 모델과 다른 순환신경망의 가장 큰 차이점은 세포 상태(C_t)의 유무이며, LSTM 모델은 세포 상태(C_t)가 존재하므로 과거의 정보를 유지할 수 있으므로 순환신경망의 문제점인 장기 의존성 문제를 해결하였다.

LSTM 모델은 크게 네 부분으로 나눌 수 있다. 한 시점 이전($t-1$)으로부터 추정된 정보⁶⁾를 현재의 시점(t)에 얼마나 반영할 것인지 결정하는 부분, 현재 시점(t)에 새로운 정보를 얼마나 반영할 것인지 결정하는 부분, 과거의 정보와 현재의 정보를 결합하는 부분, 그리고 다음 시점($t+1$) 혹은 결과를 출력할 것인지 결정하는 부분으로 구분할 수 있다.

LSTM 모델은 가장 먼저 이전 시점($t-1$)의 은닉층에서 출력된 정보(h_{t-1})를 현재 시점(t)에 얼마나 반영시킬지 결정한다. 식(27)은 ‘망각 게이트 레이어(forget gate layer, f_t)’이며, 이전 시점 은닉층의 정보(h_{t-1})와 현재 시점(t)의 정보를 얼마나 망각시킬지 활성화 함수(σ)에 따라 결정한다.

6) LSTM 모델이 시작할 시점에서의 이전 정보는 입력 자료(input data)를 이용한다.

이때의 값은 0과 1 사이의 값을 갖는데, 0일 경우 모든 정보를 반영하지 않으며, 1일 경우 모든 정보를 반영함을 의미한다.

다음 단계는 새로운 정보를 세포 상태에 얼마나 반영될지를 결정하는 단계이다. 이 단계는 다시 두 단계로 이루어져 있다. 식(28) ‘입력 게이트 레이어(input gate layer, i_t)’에 따라 활성화 함수(σ)에 따라 새로운 정보를 얼마나 수용할지를 결정하며, 두 번째로 식(30)의 ‘하이퍼볼릭 탄젠트 레이어(hyperbolic tangent layer, \tilde{C}_t)’는 새로운 세포 상태에 추가할 값을 준비를 한다.

세 번째 단계는 위에서 얻어진 지난 시점의 세포 상태(C_{t-1})를 새로운 세포 상태(C_t)로 갱신한다. 이는 식(27)의 망각 게이트 레이어 값(f_t)과 지난 시점의 세포 상태(C_{t-1})를 곱한 값과 식(28)의 입력 게이트 레이어 값(i_t)과 식(30)의 하이퍼볼릭 탄젠트 레이어 값(\tilde{C}_t)을 곱한 값을 더한 것으로 세포의 상태(C_t)를 갱신한다(식(31)).

LSTM 모형의 마지막 단계는 다음 시점($t+1$)의 세포 상태(C_{t+1})를 위해 갱신된 세포 상태(C_t)를 출력하는 단계이다. 우선 식(32)과 같이 갱신된 세포 상태(C_t)를 하이퍼볼릭 탄젠트를 통해 -1과 1 사이의 값으로 변환한 후, 출력 게이트 레이어(output layer, o_t)와 곱하여 모형에서 다음 세포로 전달한 정보를 결정한다.

$$f_t = \sigma(W_f[h_{t-1}, x_t] + b_f) \quad (27)$$

$$i_t = \sigma(W_i[h_{t-1}, x_t] + b_i) \quad (28)$$

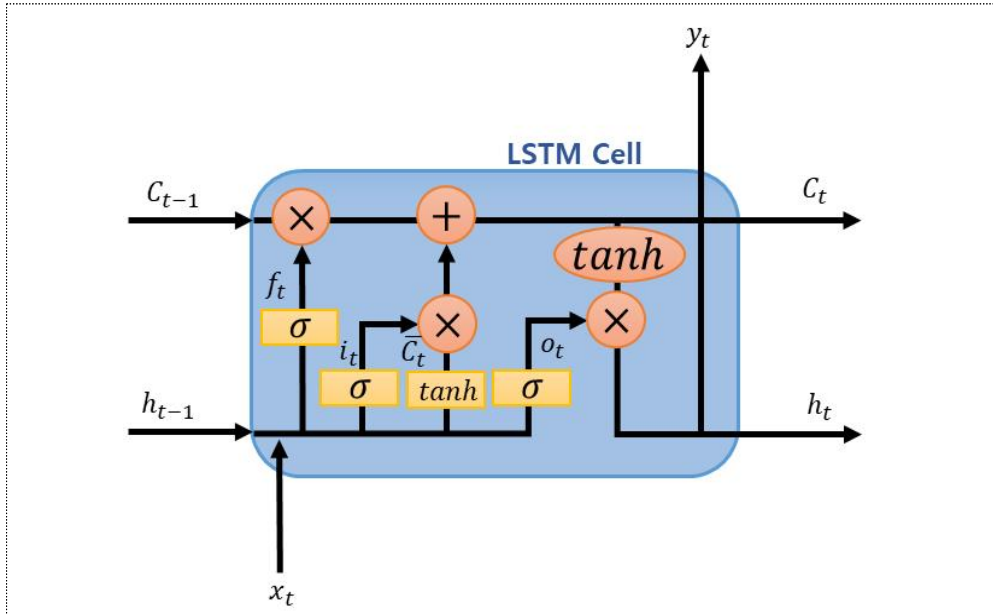
$$o_t = \sigma(W_o[h_{t-1}, x_t] + b_o) \quad (29)$$

$$\tilde{C}_t = \tanh(W_c[h_{t-1}, x_t] + b_c) \quad (30)$$

$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t \quad (31)$$

$$h_t = o_t * \tanh(C_t) \quad (32)$$

<그림 3-3> Long Short Term Memory(LSTM)의 모식도



4. GARCH-LSTM 결합 모형

Rho(2007), 노태협 외(2005) 등에서 GARCH 계열 모형과 순방향 인공신경망, 역전파 인공신경망 등을 결합하여 시계열 자료를 분석하였다. 각 시계열 분석을 통해 얻어진 계수를 입력 변수로 사용하여 분석하였다. 위의 선행 연구에서는 GARCH 계열 모형과 인공신경망을 결합하였을 때, 단일 모형보다 예측력이 높다는 결과를 도출하였다.

Kim and Won(2018)은 LSTM 모형과 GARCH 계열 모형을 이용하여 KOSPI 200 자료를 분석하였다. 해당 연구에서는 GARCH 계열 모형을 통해 추정한 변동성 계수를 LSTM 모형의 입력 자료(input data)로 사용하였으며, GARCH 계열 모형과 LSTM 모형을 결합하여 분석하였을 때, 단일 모형을 통해 분석한 예측력보다 높은 정확도를 보여주었다.

GARCH 계열 모형을 통해 추정한 계수를 입력 변수로써 LSTM의 추정에 반영이 가능하다. LSTM 모형에 반영하는 GARCH 모형의 계수는 식(10)에서 볼 수 있는 변동성을 의미하는 α_1 과 과거 전반의 변동성 효과를 의미하는 β_1 를 사용한다.

5. 인공신경망 구성

본 연구에서는 사용한 인공신경망은 단변량 모형 4개, 다변량 모형 4개로 구성되어 있다. 일반적으로 인공신경망은 어떻게 구성하느냐에 따라 결과의 정확도에서 차이를 보인다. 따라서 분석 조건을 조정하여 최적의 모형을 찾는 방법을 일반적으로 사용한다.

우선 단변량 모형에서 사용된 모형은 총 4개로, 미국산 갈비와 수입 삼겹살의 일별 자료와 월별 자료를 이용하여 분석하였다. 단변량 모형 4개의 공통적인 구성으로는 학습 자료(training set)와 검증 자료(validation set)를 8:2로 구성하였다. 인공신경망의 최적화 함수는 Adam⁷⁾을 사용하였으며, 학습률은 0.0001로 하였다. 반복 횟수를 의미하는 가중치 조정주기(epochs)⁸⁾는 100으로 하였다. 인공신경망 모형을 5개의 은닉층으로 구성하였으며, 은닉층 중 3개의 LSTM 모형과 나머지 2개의 완전하게 연결된 층인 전결합 층(fully-connected layer)를 사용하였다. LSTM의 3개의 층에는 과적합(over-fitting)을 방지하기 위하여 손실 비트(dropout)를 추가하였으며, 각각 0.8, 0.3, 0.3 순으로 하였다.

미국산 갈비의 일별 가격 변동성을 분석하기 위해 LSTM 노드는 층별로 12개, 12개, 6개로 하였다. 전결합 층의 노드는 각각 5개와 1개로 구성하였다. 수입 삼겹살의 일별 가격 변동성을 분석하기 위한 LSTM 모형은 LSTM 층의 노드는 층별로 12개, 36개, 24개로 구성하였으며, 전결합 층의 노드는 각각 5개, 1개로 구성하였다.

미국산 갈비의 월별 가격 자료의 변동성을 분석하기 위한 인공신경망은 3개의 LSTM 층은 각각 12개, 10개, 7개의 노드를 가지고 있으며 전결합 층은 5개와 1개의 노드로 구성하였다. 수입 삼겹살의 월별 가격 자료의 변동성을 분석하기 위하여 인공신경망은 3개의 LSTM 층의 노드는 12개, 24개, 12개로 설정하였으며, 전결합 층은 3개와 1개의 노드로 구성하였다.

7) Adam은 확률적 경사 하강법(Stochastic Gradient Descent, SGD)의 발전된 모형으로, 기울기 방향으로 힘을 받아 물체가 가속하는 물리 법칙을 응용한 Momentum 모형과 학습을 진행하면서 학습률을 줄여가는 AdaGard 모형이 결합한 모형으로, 기울기의 방향과 학습률을 동시에 조정하는 최적화 방법이다.

8) 가중치 조정주기(epochs)는 단위 데이터 집합 기준 가중치 학습 횟수로 하나의 집단 내에 있는 모든 분석 단위를 1회 모형에 적용하는 동안 모형의 가중치가 반복 횟수만큼 학습되는 것을 의미함.

수입 축산물의 가격에 영향을 미치는 변수를 추가한 다변량 모형은 총 4개로, 미국산 갈비, 수입 삼겹살의 LSTM 모형, GARCH-LSTM 통합 모형으로 구성하였다. 수입 축산물 가격 변동성 예측을 위한 다변량적 접근 인공신경망은 단변량 인공신경망과 같이 학습 자료(training set)와 검증 검증(validation set)을 분리하였는데, 학습 데이터와 검증 데이터를 8:2로 구성하였다. 총 5개의 은닉층으로 구성하였으며, 3개의 LSTM 층과 2개의 전결합 층으로 구성하였다. 손실 비트 역시 LSTM 층에 각각 0.8, 0.3, 0.3 순으로 하였다.

다변량을 통한 월별 미국산 갈비 가격 변동성을 예측하기 위해 인공신경망은 LSTM 층의 노드를 각각 13개, 20개, 25개로 구성하였으며, 전결합 층의 노드를 5개 1개로 구성하였다. 다변량을 통한 수입 삼겹살의 월별 가격 변동성을 예측하기 위한 LSTM 모형은 LSTM 층의 노드를 15개, 30개, 25개, 전결합 층의 노드를 5개, 1개로 구성하였다.

미국산 갈비 월별 가격 변동성을 GARCH의 계수를 추가한 LSTM 모형의 인공신경망은 LSTM 층의 노드를 각각 17개, 64개, 15개로 구성하였으며, 전결합 층의 노드를 5개, 1개로 구성하였다. 수입 삼겹살 월별 가격 변동성을 GARCH의 계수를 추가하여 분석한 LSTM 모형은 LSTM 층의 노드를 15개, 23개, 20개로 구성하였고, 전결합 층의 노드를 5개와 1개로 구성하였다.

제4절 검증 방법

1. 손실 함수(Loss Function)

손실 함수는 신경망 모형이 학습할 수 있도록 하는 지표인 동시에, 출력값과 실제 값의 오차를 이야기한다. 신경망의 학습 시, 손실 함수를 최소화하도록 가중치와 편향을 수정한다. 모형의 예측력을 검증할 경우, 손실 함수가 작을수록 예측력이 높다.

손실 함수로는 가장 많이 사용되는 MAE, RMAE와 MSE, RMSE등이 있다.

$$RMAE = \sqrt{\frac{1}{T} \sum |\hat{v}_t - v_t|} = \sqrt{MAE} \quad (33)$$

$$RMSE = \sqrt{\frac{1}{T} \sum (\hat{v}_t - v_t)^2} = \sqrt{MSE} \quad (34)$$

식(33)는 RMAE를, 식(34)은 RMSE를 의미한다. 각 식에서 \hat{v}_t 는 모형에서 예측된 변동률을 의미하며, v_t 는 시점 t 의 실제 변동률을 의미하며, T 는 총 예측수를 의미한다. RMAE와 RMSE는 예측 모형이 실제값을 예측에 발생하는 오차를 평균적으로 표시한 것으로 평균에서 크게 벗어난 커다란 오차에 가중치를 주어 벌점을 부과하는 방식이다. RMAE와 RMSE 통계량은 0에 가까운 값을 갖는 모형이 실제 값을 잘 예측한다고 할 수 있다.

한편 RMSE가 측정 단위에 따라 값이 달라지는 문제점을 갖고 있다. 이를 보완하기 위하여 상호 비교가 가능하도록 백분율 단위로 전환한 RMSPE(Root Mean Square Percent Error)는 다음의 식(35)과 같다. RMSPE는 오차를 백분율로 표현한 값으로 RMSE와 같이 0에 가까운 값을 갖는 모형이 예측력이 높다고 할 수 있다.

$$RMSPE = \sqrt{\frac{1}{T} \sum \left(\frac{\hat{v}_t - v_t}{v_t} \right)^2} \quad (35)$$

2. Diebold & Mariano 검정

모형의 예측력을 비교하기 위해서 위의 손실 함수인 RMAE, RMSE, RMPSE를 사용할 수 있으나, 모형 간의 예측력 비교를 위한 통계적 검정으로는 부족하다. 통계적인 검정을 통하여 모형 간의 예측력을 비교하기 위하여 Diebold & Mariano(1995)는 DM 검정을 제안하였다.

서로 다른 두 모형의 예측 오차를 손실 함수를 이용하여 가설 검정을 위하여 다음과 같은 귀무가설을 설정한다. DM 검정에서는 비교 모형의 예측 오차의 차이가 통계적으로 유의미한 것인지 검정한다. 식(36)은 DM 검정의 귀무가설로, 귀무가설을 기각할 때, 통계적으로 유의미한 오차의 차이를 의미한다.

$$H_0 : \bar{d}_t = E[d_t] = 0 \quad (36)$$

$$d_t = g(e_{1t}) - g(e_{2t}), t = 1, 2, \dots, n \quad (37)$$

$$\bar{d}_t = \frac{1}{n} \sum_{t=1}^n d_t \quad (38)$$

식(37)의 d_t 는 모형 간 손실 함수의 차이를 의미하며, 식(38)의 \bar{d}_t 는 d_t 의 평균을 의미한다. 모형 사이의 손실 함수 차이(\bar{d})의 분산($\hat{V}(\bar{d})$)은 다음의 식(39)로 나타낼 수 있으며, 식(39)의 분산에서 추정된 DM 통계량은 식(40)과 같이 나타낸다(Mariano, 2000).

$$\hat{V}(\bar{d}) = \frac{1}{t} [\gamma_0 + \left(\frac{2}{t}\right) \sum_{k=1}^{h-1} (t-k) \hat{\gamma}(k)] \quad (39)$$

$$DM = \left[\frac{1}{\hat{V}(\bar{d})} \right]^{\frac{1}{2}} \times \bar{d} \quad (40)$$

식(39)의 γ_k 는 모형의 손실 함수의 차이 d_t 의 k 기 시차 간의 자기공분산을 나타내며, 추정된 $\hat{V}(\bar{d})$ 를 이용하여 식(40)의 DM검정의 통계량을 추정할 수 있다. DM 검정의 경우 표본의 크기가 충분하지 않을 경우, 정확한 추정이 불가능하므로, Harvey et al.(1997)은 식(41)과 같은 MDM(modified DM) 검정을 제안하였다.

$$MDM = DM / \left[[t+1-2h+h(h-1)/T] / t \right]^{\frac{1}{2}} \quad (41)$$

MDM 통계량은 자유도가 $t-1$ 인 t 분포를 따르기 때문에, t 분포의 임계치를 이용하여 기각 여부를 결정한다.

제4장 실증 분석

제1절 분석 자료

수입 축산물의 소매가격은 aT센터에서 주중에 조사한 후 농산물 유통정보(KAMIS)에 공개하는 가격을 사용하였다. 수입 쇠고기의 경우, 원산지별(미국, 호주), 부위별(갈비, 등심, 불고기 등), 등급별(냉동, 냉장)로 구분되어 가격을 발표하고 있다. 한국육류유통수출협회와 관세청에 따르면, 분석 기간 중 쇠고기의 경우 미국에서 가장 많이 수입되고 있으며, 부위는 갈비가 가장 많이 수입되고 있고, 냉동 형태로 가장 많이 수입되고 있는 것으로 조사되었다. 따라서 수입 쇠고기는 미국산 냉동 갈비의 소비자 가격을 분석 대상으로 하였다. 수입 돼지고기 소비자 가격은 별도의 국가 표기 없이 냉동 삼겹살 가격만을 제공하고 있기 때문에 해당 자료를 사용하였다.

수입 축산물의 가격 변동성을 파악하기 위해 본 연구는 가격 자료만을 이용하여 변동성을 분석하는 방법과 시장 상황을 반영하여 변동성을 예측하는 방법의 정확성을 비교·분석하기 위하여 단변량적 접근 방법과 다변량적 접근 방법으로 나누어 분석하였다. 또한 일별 자료와 월별 자료를 나누어 분석하였으며, 이는 인공신경망의 변동성 예측이 활발한 금융 시계열 분석 자료의 형태가 시간별 혹은 일별 자료를 이용하여 분석한 연구가 주를 이룬다. 그러나 축산물 특히 수입 축산물은 일별 자료와 월별 자료가 일반적이기 때문에, 이를 고려하여 일별 자료와 월별 자료로 나누어 분석하여, 정확도를 비교하고자 한다.

단변량 모형은 2012년 1월 1일부터 2019년 12월 31일까지의 미국산 갈비 소비자 가격과 수입 돼지고기 삼겹살의 일별 소비자 가격을 이용하여, 총 1,966개의 자료를 분석에 사용하였다. 단변량 모형 분석에 사용된 자료 중 2012년 1월 1일부터 2018년 12월 31일까지 총 1,720개의 자료를 이용하여 변동성을 분석하였다. 분석된 변동성을 이용하여 2019년 1월 1일부터 2019년 12월 31일까지 총 246개의 변동성을 추정하여 동일한 기간의 실제 가격의 변동성과 비교하였다.

제2절 기초 통계

<표 4-1>은 미국산 갈비와 수입 삼겹살의 일별 소비자 가격에 대한 기초 통계량이다. 미국산 갈비와 수입 삼겹살의 평균은 2231.22와 1027.74로 나타났으며, 표준편차는 253.86과 53.16으로 나타났다. 변이 계수로 보았을 때, 미국산 갈비가 수입 삼겹살과 비교하였을 때 가격의 변동이 큰 것으로 나타났다. 왜도와 첨도 모두 정규분포와 다른 값을 가졌으며, 미국산 갈비의 경우 Ljung-Box 검정 결과는 AR(1), AR(3), AR(6) 모두에서 자기상관이 있는 것으로 나타났으며, 수입 삼겹살 역시 AR(1)부터 AR(6)까지 모두 자기 상관이 있는 것으로 나타났다.

<표 4-1> 일별 분석 자료의 기초 통계량

	미국산 갈비	수입 삼겹살
평균	2231.22	1027.74
표준편차	253.86	54.16
변이 계수	0.11	0.05
왜도 ¹⁾	-1.11	-0.25
첨도 ²⁾	3.01	2.63
Ljung-Box Q(1) ³⁾	1959.77 (0.00)	1929.15 (0.00)
Ljung-Box Q(3) ³⁾	5852.58 (0.00)	5674.05 (0.00)
Ljung-Box Q(6) ³⁾	11629.88 (0.00)	11042.44 (0.00)

1) 왜도(Skewness) : 분포의 치우침 정도를 측정하는 통계치로 정규분포의 경우 0임.

2) 첨도(Kurtosis) : 분포의 중심점에 지나치게 몰리는 정도를 측정하는 통계치. 정규분포의 경우 3임.

3) Ljung-Box's Q : 시계열의 자기 상관 여부를 검정하는 통계량으로 Q(1)은 자유도가 1인 카이제곱분포를 따르며, 귀무가설은 시계열의 자기 상관이 없다는 것임. ()는 p -value를 의미함.

자료 : 농협, 관세청, 통계청

본 연구에서는 단변량적 접근 방법과 다변량적 접근 방법으로 구분하여 변동성의 예측력을 비교하고자 한다. 인공지능망은 가격 변동성의 주기에 따라 정확도 측면에서 차이를 보이는 동시에, 다변량적 접근 방법에 사용된 자료의 특성상 일별 자료에 한계가 있어 월별 자료를 이용하여 예측력을 비

교하였다. 월별 단변량 모형과 월별 다변량 모형에서는 수입 쇠고기 갈비와 수입돼지고기 삼겹살의 2012년 01월부터 2019년 12월까지의 월별 소비자 가격 자료를 연구에 이용하였다. 이 중 2012년 01월부터 2018년 12월까지의 자료는 예측을 위한 분석 자료로 사용하며, 2019년 01월부터 2019년 12월까지의 가격 변동성을 예측하여, 실제 가격 변동과 비교한다.

설명변수로는 국내산 돼지고기 소비자 가격, 경기종합지수, 원·달러 환율을 추가로 이용하였다. 김원태(2017)에 따르면 수입산 돼지고기와 국내산 돼지고기, 수입 쇠고기와 국내산 돼지고기 사이의 대체 관계를 증명하였다. 소득변수로 국가 GDP를 이용하는 것이 일반적이지만, 국가 GDPsms 월별 자료가 제공되지 않기 때문에, 대리변수로 선행(경기) 종합지수(2015=100)⁹⁾를 사용하였다.

각 자료에 대한 기초 통계량은 다음 <표4-2>와 같다. 미국산 갈비와 수입 삼겹살의 가격은 각각 2238.78과 1029.16로 나타났으며, 변이 계수가 0.11과 0.05로 나타났다. 이는 수입 삼겹살의 가격이 미국산 갈비의 가격보다 변동이 적은 것을 의미한다. 정규분포를 판단하는 Jarque-Beta 검정을 실시한 결과, 미국산 갈비는 귀무가설을 기각하여, 정규분포가 아닌 것으로 판단되었으나, 수입 삼겹살의 경우 귀무가설을 기각하지 못하여 정규분포인 것으로 판단되었다. 미국산 갈비와 같이 정규분포를 따르지 않는 현상은 과거의 분산이 현재의 분산에 영향을 미치고 있음을 의미하며, 이를 조건부 이분산 문제라고 한다. 이런 경우 본 연구에서 사용하는 ARCH 계열의 분석 방법을 활용하여 조건부 이분산 문제를 해결할 수 있다. 또한 두 변수 모두 Ljung-Box 검정 결과, AR(1)부터 AR(6)까지 귀무가설을 기각하여 자기 상관이 있는 것으로 나타났다.

국내산 삼겹살의 소비자 가격의 경우 평균 1883.22, 표준편차 221.47로 나타났으며, 변이 계수는 0.12로 나타났다. 왜도와 첨도는 각각 -0.12와 2.78로 왼쪽으로 치우치고 꼬리는 얇은 형태로 나오지만, Jarque-Bera 검정 결과 귀무가설을 기각하지 못하여 정규성을 띄는 것으로 나타났다. 국내산 삼겹살의 소비자 가격을 대상을 Ljung-Box 검정 결과 AR(1)에서 AR(6)까지 귀무가설을 기각하여, 자기 상관이 있는 것으로 나타났다.

미국산 갈비의 수입량과 수입 삼겹살의 수입량 평균은 각각 5126.42와

9) 이현주·김희철(2010)은 가계소득액과 선행(경기)종합지수 사이에 1% 유의적 정(+)의 관계를 증명함.

9841.18로 나타났으며 표준편차는 1823.81과 2469.81로 나타났다. 변이 계수는 각각 0.12와 0.36으로 수입 삼겹살의 수입량 변동성이 더 큰 것으로 나타났다. 한편 미국산 갈비의 수입량의 Jarque-Bera 통계량은 7.96으로 귀무가설을 기각한 반면, 수입 삼겹살은 1.57로 귀무가설을 기각하지 못하였다. 이는 미국산 갈비는 정규성을 띄지 못한 반면, 수입 삼겹살은 정규성을 띄는 것을 의미한다. 수입량에 대한 Ljung-Box 검정 결과 미국산 갈비와 수입 삼겹살 수입량 모두 AR(1)부터 AR(6)까지의 귀무가설을 기각하여 자기 상관관이 있는 것으로 나타났다.

<표 4-2> 월별 분석 자료의 기초 통계량

	미국산 갈비 가격	수입 삼겹살 가격	국내산 삼겹살 소비자 가격	미국산 갈비 수입량	수입 삼겹살 수입량	선행중 합지수 (2015= 100)	원·달러 환율
평균	2238.79	1029.16	1883.22	5126.42	9841.18	102.09	1118.82
표준편차	247.94	52.28	221.47	1823.81	2469.81	9.83	46.04
변이 계수	0.11	0.05	0.12	0.36	0.25	0.1	0.04
왜도 ¹⁾	-1.16	-0.25	-0.21	0.73	0.29	-0.03	-0.02
첨도 ²⁾	3.16	2.60	2.78	3.45	2.94	1.62	2.83
Jarque-Bera ³⁾	14.03 (0.00)	1.68 (0.43)	0.81 (0.67)	7.96 (0.02)	1.57 (0.46)	54.14 (0.00)	0.02 (0.99)
Ljung-Box Q(1) ⁴⁾	90.69 (0.00)	82.73 (0.00)	71.298 (0.00)	10.627 (0.00)	20.585 (0.00)	92.473 (0.00)	69.630 (0.00)
Ljung-Box Q(3)	248.07 (0.00)	201.70 (0.00)	133.632 (0.00)	48.428 (0.00)	49.331 (0.00)	264.775 (0.00)	153.428 (0.00)
Ljung-Box Q(6)	422.03 (0.00)	306.02 (0.00)	144.848 (0.00)	87.648 (0.00)	84.093 (0.00)	493.395 (0.00)	211.291 (0.00)

1) 왜도(Skewness) : 분포의 치우침 정도를 측정하는 통계치로 정규분포의 경우 0임.

2) 첨도(Kurtosis) : 분포의 중심점에 지나치게 몰리는 정도를 측정하는 통계치. 정규분포의 경우 3임.

3) Jarque-Bera : 분포의 정규성을 검정하는 것으로 귀무가설(H_0)은 정규분포한다는 것임. ()는 p -value를 의미함.

4) Ljung-Box's Q : 시계열의 자기 상관 여부를 검정하는 통계량으로 Q(1)은 자유도가 1인 카이제곱분포를 따르며, 귀무가설은 시계열의 자기 상관관이 없다는 것임. ()는 p -value를 의미함.

자료 : 농협, 관세청, 통계청

수입 축산물과 수입 축산물 시장에 미치는 변수 사이의 피어슨 상관관계 분석(Pearson's correlation analysis)의 결과는 다음과 같다. <표 4-3>의 미국

산 갈비, <표 4-4>의 수입 삼겹살과 설명 변수 간의 상관관계를 분석한 결과 미국산 갈비의 가격은 국내산 삼겹살 가격과 미국산 갈비 수입량, 선행종합지수(2015=100)는 5% 유의 수준에서 귀무가설을 기각하여 통계적으로 유의한 상관관계를 나타냈기 때문에, 설명변수로 사용이 적합하다고 판단된다.

원·달러 환율은 미국산 갈비, 수입 삼겹살과의 상관관계가 통계적으로 유의하지 않는 것으로 판단되었다. 김혜영·김태균(2003), 허덕 외(2010)에 따르면 원·달러 환율에 따라 수입 축산물에 대한 소비에 영향을 미치고, 가격에 영향을 미치는 것으로 분석하였으며, 수입에 환율이 영향을 미친다는 다수의 연구를 바탕으로 설명변수로써 사용하였다.

<표 4-3> 미국산 갈비와 설명 변수 간의 상관관계

	미국산 갈비 가격	국내산 삼겹살 가격	미국산 갈비 수입량	선행지수	원·달러 환율
미국산 갈비 가격	1.000				
국내산 삼겹살 가격	0.497*** (0.000)	1.000			
미국산 갈비 수입량	0.485*** (0.000)	0.268*** (0.009)	1.000		
선행 종합지수	0.835*** (0.000)	0.444*** (0.000)	0.647*** (0.000)	1.000	
원·달러 환율	0.082 (0.429)	0.165 (0.000)	0.321*** (0.002)	0.339*** (0.001)	1.000

주1 : ***, **, *는 각각 1%, 5%, 10% 유의 수준에서 통계적으로 유의함을 의미

주2 : 귀무가설(H_0)은 ‘두 변수 사이의 선형 관계가 없음’임. ()는 *p-value*를 의미함.

<표 4-4> 수입 삼겹살과 설명 변수 간의 상관관계

	수입 삼겹살 가격	국내산 삼겹살 가격	미국산 갈비 수입량	선행지수	원·달러 환율
수입 삼겹살 가격	1.000				
국내산 삼겹살 가격	0.590*** (0.000)	1.000			
미국산 갈비 수입량	0.295*** (0.04)	0.2680*** (0.009)	1.000		
선행지수	0.592*** (0.000)	0.444*** (0.000)	0.647*** (0.000)	1.000	
원·달러 환율	0.105 (0.313)	0.165 (0.111)	0.321*** (0.002)	0.339*** (0.001)	1.000

주1 : ***, **, *는 각각 1%, 5%, 10% 유의 수준에서 통계적으로 유의함을 의미

주2 : 귀무가설(H_0)은 ‘두 변수 사이의 선형 관계가 없음’임. ()는 p -value를 의미함.

1. 단위근 검정

한편 금융 시계열 및 축산물 가격과 같은 경제 시계열은 일반적으로 시계열의 불안정성이란 특징을 갖고 있다. 이를 해결하기 위해 1차 차분에 의해 시계열을 안정화할 수 있었다. 이러한 시계열의 안정성을 확보하는 동시에, 본 연구의 목적인 가격 변동성 예측과 부합할 수 있도록 가격 자료를 다음과 같이 가공하여 분석하였다(식(36)).

$$R_t = \ln(P_t/P_{t-1}) \times 100 \quad (36)$$

수입육 가격 자료의 안정성을 검정하기 위하여 Augmented Dickey-Fuller(ADF) 단위근 검정과 Phillips-Perron(PP) 단위근 검정을 실시하였다. 일반적으로 시계열 자료의 특성상 불안정성(Non-stationary)을 내포할 가능성이 높다. 시계열의 불안정하게 되면 변수 사이의 아무런 상관관계가 없음에도 불구하고 통계적으로 유의미한 관계가 있는 것처럼 분석되는 허구적 회귀 현상이 발생하여 분석의 신뢰도가 낮아질 수 있다. 따라서 시계열의 안정성을 확인하기 위하여 단위근 검정(Unit Root Test)를 실시하였다.

ADF 검정과 PP 검정의 시차는 AIC(Akaike Information Criterion),

HQIC(Hannan-Quinn Information Criterion)과 SBIC(Schwarz -Bayesian Information Criterion)를 고려하여 선정하였으며 식(37)은 ADF 검정을 나타낸 식이며, 식(38)은 PP 검정을 나타낸 식이다.

$$\Delta y_t = \alpha + \beta y_{t-1} + \sum_{i=1}^{k_i} \gamma_i TRIANGLE y_{t-i} + e_t \quad (37)$$

$$y_t = \rho y_{t-1} + e_t \quad (38)$$

일별 가격 변동성을 이용한 단위근 검정을 실시한 결과는 <표4-5>에서 볼 수 있듯, ADF 검정과 PP 검정 모두에서 단위근이 없는 안정적인 시계열로 나타났다. ADF 검정의 경우, 일별 미국산 냉동 쇠고기 갈비의 소비자 가격과 수입 냉동 삼겹살 소비자 가격 변동성은 각각 -45.512과 -45.082로 귀무가설(H_0)인 ‘단위근이 존재한다’를 5% 유의 수준에서 기각하여, 시계열이 안정적임을 확인하였다.

<표 4-5> 일별 가격 변동률에 대한 단위근 검정 결과

분류	ADF 검정	PP 검정
미국산 갈비 가격 변동률	-45.512***	-45.898***
수입 삼겹살 가격 변동률	-45.082***	-45.582***

주1 : ***,**,*,는 각각 1%, 5%, 10% 유의 수준에서 통계적으로 유의함을 의미

주2 : Critical Value는 -3.520, -2.896, -2.583임.

월별 가격 정보 및 설명변수에 대한 단위근 검정을 실시한 결과는 <표 4-6>에 나타났다. 가격 변동성에 대한 단위근 검정을 실시한 결과, 미국 갈비의 가격 변동률은 -7.343, 수입 삼겹살 가격 변동률은 -7.840으로 두 변수 모두 5% 유의 수준에서 단위근이 존재한다는 귀무가설을 기각하여 시계열이 안정적임을 확인하였다. 국산 냉장 삼겹살의 단위근 검정은 -2.716으로 5% 유의 수준에서 통계적으로 유의하여 안정적인 시계열로 판정되었다. 수입량 관련한 변수인 미국산 갈비 수입량, 수입 삼겹살 수입량은 각각 -6.184와 -5.833은 1% 유의 수준에서 통계적으로 유의하여 안정적인 시계열로 나타났다.

한편 선행종합지수(2015=100)를 ADF 검정을 실시한 결과, 귀무가설을 기각하지 못하여 불안정한 시계열로 판단되었다. 반면, 1차 차분하여 단위근 검정을 실시한 결과, -6.409로 귀무가설을 기각하여 안정적인 시계열임을 확인하였다. 원·달러 환율의 경우 -2.707로 10% 유의 수준에서 통계적으로 유의하여 단위근이 없는 안정적인 시계열로 나타났다.

본 연구에서는 자료의 정보가 유실됨에도 불구하고, 연구의 통일성을 위하여, 모든 변수를 1차 차분하여 연구를 진행하였다. 그 결과 모든 변수에서 단위근이 없는 안정적인 시계열인 것으로 나타났다. 따라서 본 연구 모형에서 소매가격 변동률을 이용하여 추정할 경우, 허구적 회귀 현상이 발생하지 않을 것이며, 발생하더라도 그 영향은 미미할 것으로 판단하였다.

<표 4-6> 월별 가격변화율에 대한 단위근 검정 결과

분류	ADF 검정		PP 검정	
	level	1차 차분	level	1차 차분
미국산 갈비 가격 변동률	-	-7.343***	-	-7.552***
수입 삼겹살 가격 변동률	-7.840***	-15.063***	-7.883***	-17.175***
국내산 삼겹살 소비자 가격	-2.716**	-7.885***	-3.142**	-7.888***
미국산 갈비 수입량	-6.814***	-17.928***	-7.020***	-26.877***
수입 삼겹살 수입량	-5.833***	-15.194***	-5.826***	-19.176***
선행종합지수(2015=100)	-1.907	-4.835***	0.169	-4.847***
원·달러 환율	-2.708*	-10.185***	-2.681*	-10.279***

주1 : ***, **, *는 각각 1%, 5%, 10% 유의 수준에서 통계적으로 유의함을 의미

주2 : level 변수의 1%, 5%, 10% Critical Value는 각각 -3.518, -2.895, -2.582임. 1차 차분 변수의 Critical Value는 -3.520, -2.896, -2.583임.

2. ARCH-LM 검정

ARCH-LM(Engle's Lagrange Multiplier) 검정을 통하여 ARCH 효과가 존재하는지에 대한 여부를 확인하였다. 이는 현재의 오차항 크기가 과거의 오차항의 크기에 의해 영향을 받는지에 대한 여부를 검정하는 것이며, 다중 회귀식의 OLS의 잔차 제곱을 이용하여 검정한다. 즉, 품목에 대한 가격 변화율(R_t)을 회귀 분석하여 얻은 OLS 잔차항의 제곱을 p 개의 시차(lag)항에

대하여 두 번째 단계 회귀방정식을 추정함으로써 이들 회귀 계수가 동시에 유의적인지를 검정하는 것이다.

수입 축산물 가격 정보를 이용하여 ARCH-LM 검정 결과는 <표 4-7>에서 볼 수 있듯 일별 미국산 갈비와 일별 수입 삼겹살의 소비자 가격 모두 귀무가설인 ‘ARCH 효과가 없음’을 5% 유의 수준에서 기각하였다.

ARCH-LM 검정 결과, 월별 미국산 냉동 쇠고기 갈비의 소비자 가격은 귀무가설(H_0)을 10% 유의 수준에서 기각하였으며, 월별 수입 냉동 삼겹살의 소비자 가격은 귀무가설(H_0)을 5% 유의 수준에서 기각하였다.

<표 4-7> 수입 축산물 가격 변동성의 ARCH-LM 검정

구분	일별 가격	월별 가격
미국산 갈비	6.921*** (0.009)	13.597* (0.059)
수입 삼겹살	9.961** (0.041)	18.289*** (0.003)

주1 : 귀무가설은 “시차 p까지 고려할 때 잔차 항에 ARCH 효과가 없다.” 임. 일별 미국산 갈비는 시차 1, 일별 수입 삼겹살은 시차 4임. 월별 미국산 갈비는 시차 7, 월별 수입 삼겹살은 시차 5 임.

주2 : ***, **, *는 각각 1%, 5%, 10% 유의 수준에서 통계적으로 유의함을 의미

이러한 결과는 국내산 농산물, 축산물 및 수산물¹⁰⁾의 ARCH 효과와 같이 수입 축산물에서도 가격 변화율에 대한 시계열 자료가 통계적으로 유의한 ARCH 효과가 존재하고 있음을 의미한다. 이러한 검정 결과는 통계적 특성들이 본 연구에서 사용하고자 하는 GARCH 모형의 적합성에 근거가 될 수 있다.

10) 강태훈(2007)의 연구에 의하면, 돼지고기 지육 가격을 제외한 축산물(쇠고기, 닭고기, 계란)에서 통계적으로 유의한 ARCH 효과가 존재하는 것으로 나타났으며, 강태훈(2004)의 연구에 의하면, 당근을 제외한 농산물(배추, 무, 고추, 마늘, 양파, 대파)에 대한 통계적으로 유의한 ARCH 효과가 존재하는 것으로 나타났다. 고봉현(2007)에서는 수산물(고등어, 갈치, 오징어, 명태)의 가격 변동성을 검증한 결과, 모든 대상에서 통계적으로 유의한 ARCH 효과가 있는 것으로 나타났다.

제3절 단변량 모형 추정 결과

1. 일별 가격 자료 분석

먼저 수입 축산물 일별 가격 자료를 이용하여 식(10)의 GARCH(1,1) 모형을 추정하였다. 이는 Aradhyula et al.(1988)와 Kesavan et al.(1992)에서 축산물의 소비자 가격의 변동성을 분석하는데, 여러 GARCH 모형 중 GARCH(1,1) 모형의 설명력이 가장 높음을 언급하였으며, 분석 자료를 이용하여 여러 GARCH 모형을 분석한 결과 GARCH(1,1) 모형의 추정된 모수의 유의성이 가장 높음을 고려하였다.

먼저 미국산 갈비와 수입 삼겹살 일일 가격 변동성 예측은 2012년 1월 1일부터 2018년 12월 31일까지의 자료를 이용하였으며 그 결과는 <표 4-8>에 제시하였다. 미국 갈비 가격을 이용하여 GARCH(1,1) 모형을 추정한 결과, ARCH 항은 0.057로 통계적으로 유의하지 않은 것으로 나타났으나, GARCH 항의 경우 0.940으로 5% 유의 수준에서 귀무가설(H_0)을 기각하여 통계적으로 유의한 것으로 나타났다. 이는 전기($t-1$)의 충격이 현재의 변동성에 주는 영향은 유의하지 않으나, 과거 전반의 충격이 지속적으로 현재의 변동성에 영향을 미치고 있는 것으로 해석된다.

수입 삼겹살 역시 ARCH 항은 0.093으로 통계적으로 유의하지 않은 것으로 나타났으나 GARCH 항의 경우 0.898로 5% 유의 수준에서 귀무가설(H_0)을 기각하여 통계적으로 유의한 것으로 나타났다. 수입 삼겹살 역시 GARCH 항은 유의하나 ARCH 항이 유의하지 않음을 통해 전기($t-1$)의 충격이 현재의 변동성에 주는 영향은 유의하지 않으나, 과거 전반의 충격이 지속적으로 현재의 변동성에 영향을 미치고 있는 것으로 해석된다.

미국산 갈비와 수입 삼겹살 가격 변동성에서 ARCH 효과가 없는 것은 수입 축산물이라는 특징으로 판단된다. 정지현 외(2018)에 따르면 수입 축산물은 국내 축산물에 비해 특정 거래¹¹⁾ 방식으로 거래되는 경우가 많으며, 소매단계에서 고정비로 인한 비용구조가 경직적인 것과 안정적인 수요를 확보하여 중·장기적으로 평균 수익을 보장하기 위해 급격한 가격 변동을 최소

11) 소규모 소매업체와 계약을 통해 판매장을 제공하고 수수료를 받는 형태를 의미함.

화하기 위한 전략을 사용하는 것으로 나타났다.

<표 4-8> 일별 가격 변동성의 GARCH(1,1) 모형 추정 결과

		미국산 갈비	수입 삼겹살
평균 방정식	상수항	0.010 (0.839)	0.015 (0.519)
분산 방정식	ARCH(1)	0.057 (0.846)	0.093 (0.132)
	GARCH(1)	0.940*** (0.021)	0.898*** (0.000)
	상수항	0.002 (0.956)	0.014 (0.176)

주1 : ***, **, *는 각각 1%, 5%, 10% 유의 수준에서 통계적으로 유의함을 의미

LSTM 모형은 GARCH 모형과 동일한 2012년 1월 1일부터 2018년 12월 31일까지의 자료를 이용하여, 식(27)~(31)를 이용하여 학습을 시켰다. 미국산 갈비의 일별 가격 변동성을 분석하기 위해 사용된 LSTM 모형은 3개의 층의 LSTM 층과 2개의 전결합 층으로 구성하였으며, LSTM 3개의 층에는 과적합 방지를 위한 손실 비트를 각각 0.8, 0.3, 0.3 순으로 하였다. LSTM 층의 노드는 층별로 12개, 12개, 6개로 하였다. 전결합 층의 노드는 각각 5개와 1개로 구성하였다. 수입 삼겹살의 일별 가격 변동성 분석을 위한 LSTM 모형 LSTM 층 3개와 전결합 층 2개로 구성하였으며, 손실 비트는 0.8, 0.3, 0.3 순으로 하였다. LSTM 층의 노드는 12개, 26개, 24개로 구성하였으며, 전결합 층의 노드는 5개, 1개로 구성하였다.

GARCH(1,1)과 LSTM 모형을 이용한 가격 변동성 예측력을 비교하기 위해 두 모형 결과를 이용하여 2019년 1월 1일부터 2019년 12월 31일까지 총 246일간의 변동성을 예측하였으며¹²⁾, 다음의 <표 4-9>, <표 4-10>과 <그림 4-1>, <그림 4-2>는 변동성 예측의 결과를 정리한 것을 의미한다. <표 4-9>과 <표 4-10>은 미국산 갈비와 수입 삼겹살의 일별 변동성 예측 결과를 평균과 표준편차로 나타낸 것으로, <표 4-9>의 미국산 갈비의 일별 변동성 예측 결과를 살펴본 결과, LSTM 모형이 0.028, GARCH 모형이 0.075

12) Franses and Ghijssels(1999), Klein and Walther(2016), 김배성(2005) 등의 연구는 계수가 유효하지 않은 GARCH 모형을 통해 변동성을 예측하여, 다른 모형(ARIMA 등)보다 높은 예측력을 보였다.

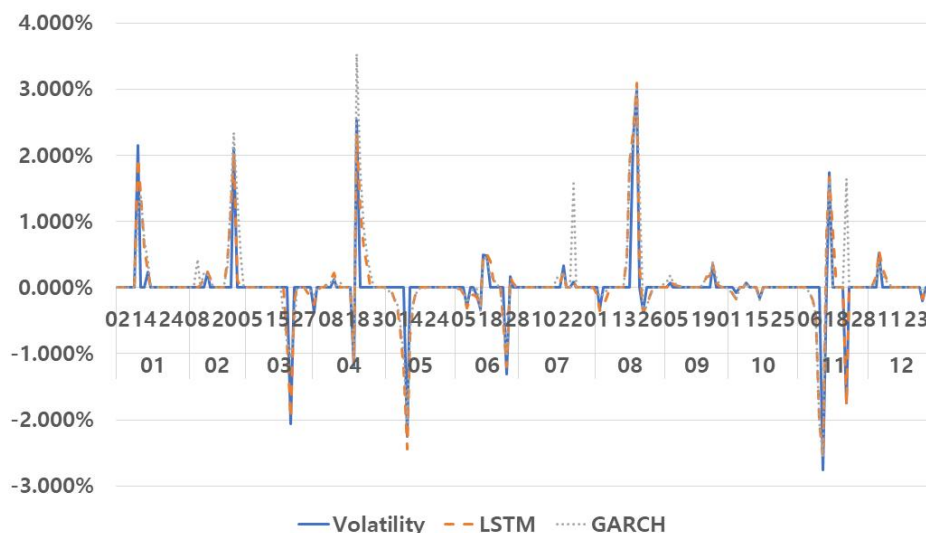
로 나타났다. 이는 실제 변동률의 평균인 0.014보다 변동률을 크게 예측한 것으로 평균 변동률을 통해 LSTM 모형이 예측값에 더 가까운 것을 알 수 있다. 이는 급격히 증가 혹은 감소하는 실제 변동률과 달리 LSTM 모형과 GARCH 모형은 상대적으로 서서히 증가 혹은 감소하기 때문으로 판단된다. 한편 GARCH 모형을 통해 예측한 결과가 LSTM 모형을 통해 예측한 결과보다 넓은 분포를 갖는 것으로 나타났다.

<그림 4-1>을 통해 실제 변동률과 LSTM 모형, GARCH 모형의 예측값을 살펴본 결과 LSTM 모형이 GARCH 모형보다 실제 변동률에 가깝게 움직이는 것을 볼 수 있다.

<표 4-9> 단변량 미국산 갈비 일별 가격 변동성 예측 결과

	실제 변동률	LSTM	GARCH
평균	0.014	0.028	0.075
표준편차	0.0048	0.0055	0.0057

<그림 4-1> 단변량 미국산 갈비 일별 가격 변동성 예측 비교



<표 4-10>은 수입 삼겹살의 일별 가격 변동성 예측 결과를 정리한 표이며, 예측한 평균 변동률이 각각 LSTM 모형 0.040, GARCH 모형이 0.076로


실제 변동률 0.012보다 크게 예측한 것으로 나타났다. 이 역시 미국산 갈비와 같이 실제 변동률과 달리 LSTM 모형과 GARCH 모형은 상대적으로 서서히 증가 혹은 감소하기 때문으로 판단된다. 또한 표준 편차 역시 LSTM 모형보다 GARCH 모형이 더 넓은 폭으로 예측한 것을 확인할 수 있었다.

<그림 4-2>은 수입 삼겹살의 예측 결과와 실제 값을 그래프로 나타낸 것으로 GARCH 모형보다 LSTM 모형이 실제 변동률과 비슷한 형태로 움직이는 것으로 나타났다.

<표 4-10> 단변량 수입 삼겹살 일별 가격 변동성 예측 결과

	실제 변동률	LSTM	GARCH
평균	0.012	0.040	0.076
표준편차	0.0046	0.0050	0.0057

<그림 4-2> 단변량 수입 삼겹살 일별 가격 변동성 예측 비교



<표 4-11>과 <표 4-12>는 RMAE, RMSE와 RMSPE를 이용하여 두 모형의 예측력을 비교하였으며, <표 4-12>의 미국산 갈비의 경우, LSTM 모형이 GARCH 모형보다 예측값과 실제값 사이의 오차가 작은 것으로 나타났다. RMAE 통계량 기준, LSTM 모형에서 0.0428, GARCH 모형에서 0.0582

를 나타냈으며, LSTM 모형이 26.45% 높은 정확도를 보여주었다. RMSE 통계량에서는 LSTM 모형의 경우 0.0049, GARCH 모형의 경우 0.0055로 LSTM 모형이 12.14% 높은 정확도를 보였으며, RMSPE 통계량은 각각 1.0053과 1.5293으로 LSTM 모형이 GARCH 모형보다 34.27% 높은 정확도를 보였다.

<표 4-11> 단변량 미국산 갈비 일별 가격 변동성 예측 비교

	LSTM	GARCH
RMAE	0.0428	0.0582
RMSE	0.0049	0.0055
RMSPE	1.0053	1.5293

<표 4-12>의 수입 삼겹살 일별 가격 변동성 예측성과를 보면, 수입 삼겹살은 미국산 갈비와 동일하게 LSTM 모형이 GARCH 모형보다 더 정확한 변동성을 예측한 것으로 나타났다. RMAE 기준, LSTM 모형은 0.0450, GARCH 모형은 0.0640으로 LSTM 모형이 29.77% 정확한 것으로 나타났다. RMSE 통계량에서 LSTM 모형은 0.0046, GARCH 모형은 0.0061로 나타났으며 LSTM 모형이 24.58% 더 높은 정확성을 보였으며, RMSPE는 1.0659의 LSTM 모형, 1.6748의 GARCH 모형의 통계량을 보여 LSTM 모형이 36.36% 더 정확한 것으로 나타났다.

<표 4-12> 단변량 수입 삼겹살 일별 가격 변동성 예측 비교

	LSTM	GARCH
RMAE	0.0450	0.0640
RMSE	0.0046	0.0061
RMSPE	1.0659	1.6748

따라서 미국산 갈비와 수입 삼겹살 모두에서 단변량 일별 변동성 예측에 있어 GARCH 모형을 이용했을 경우보다 LSTM 모형을 이용했을 때 더 정

확한 예측 결과를 보였다. 이러한 결과는 Hansson(2017), Kim and Won(2018)의 연구와 동일한 것으로 일관성 있게 LSTM 모형의 예측 능력이 기존 시계열 모형보다 정확도가 높은 것을 보여주고 있다.

2. 월별 가격 자료 분석

앞서 언급한 바와 같이 단변량적 접근 방법과 다변량적 접근 방법에 대한 예측력 차이를 비교하기 위하여 월별 가격 자료를 이용하여 비교·분석하였다. 월별 가격 자료를 이용한 단변량 가격 변동성을 예측하기 위하여, GARCH(1,1) 모형을 이용하여 분석하였다. 2012년 1월부터 2018년 12월까지의 가격 변동성을 GARCH(1,1) 모형을 통해 분석한 결과는 다음 <표 4-11>과 같다. 우선 미국산 갈비의 GARCH(1,1) 분석 결과로는 평균 방정식과 분산 방정식의 상수항 계수는 각각 0.173과 0.084로 유의하지 않았으나, ARCH 항과 GARCH 항은 각각 0.167과 0.777로 5% 유의 수준에서 귀무가설(H_0)을 기각하여 통계적으로 유의한 것으로 나타났다. 이는 미국산 갈비의 가격 변동성은 전기($t-1$)의 충격에 의해 가격 변동에 영향을 미치며, 과거 전반의 충격 역시 미국산 갈비의 가격 변동성에 영향을 미침을 의미한다.

한편, 수입 삼겹살의 경우 ARCH 항은 0.225로 통계적으로 유의하지 않은 것으로 나타났으나, GARCH 항은 0.683으로 5% 유의 수준에서 귀무가설(H_0)을 기각하여 통계적으로 유의한 것으로 나타났다. 이는 일별 가격 정보와 동일하게 나타났으며, 전기($t-1$)의 충격의 현재에 대한 가격 변동성의 영향은 유의하지 않으나, 과거 전반의 충격에 의한 가격 변동성의 영향은 통계적으로 유의한 것으로 나타났음을 의미한다.

<표 4-13> 수입 축산물 가격 변동성의 GARCH(1,1) 모형 추정 결과

		미국산 갈비	수입 삼겹살
평균 방정식	상수항	0.173 (0.185)	0.052 (0.791)
분산 방정식	ARCH(1)	0.167*** (0.007)	0.225 (0.385)
	GARCH(1)	0.777*** (0.000)	0.683*** (0.000)
	상수항	0.084 (0.197)	0.290 (0.261)

주1 : ***,**,*,는 각각 1%, 5%, 10% 유의수준에서 통계적으로 유의함을 의미

미국산 갈비와 수입 삼겹살의 월별 가격 변동성에 대한 GARCH 분석을 토대로 변동성을 예측한 결과와 LSTM 모형을 통해 변동성을 예측한 결과를 비교하였다. LSTM 모형은 2012년 1월부터 2018년 12월까지의 데이터를 이용하여 학습 자료로 이용하였으며, GARCH 모형과 LSTM 모형 모두 2019년 1월부터 2019년 12월까지의 가격 변동성을 예측하였다.

미국산 갈비의 월별 가격 자료의 변동성을 분석하기 위한 인공신경망은 3개의 LSTM 층과 2개의 전결합 층으로 구성하였다. 3개의 LSTM 층은 각각 12개, 10개, 7개의 노드를 가지고 있으며, 손실 비트는 0.8, 0.3, 0.3으로 하였다. 전결합 층은 5개와 1개의 노드로 구성하였다.

수입 삼겹살의 월별 가격 자료의 변동성을 분석하기 위하여 인공신경망은 3개의 LSTM 층과 2개의 전결합 층으로 구성하였으며, 3개의 LSTM 층의 노드는 12개, 24개, 12개로 설정하였으며, 손실 비트는 0.8, 0.3, 0.3으로 하였다. 전결합 층은 3개와 1개의 노드로 구성하였다.


<표 4-14>와 <표 4-15>는 월별 가격 변동성을 예측한 결과를 정리한 것이며, <그림 4-3>와 <그림 4-4>은 예측 값과 실제 값을 비교한 그래프이다. <표 4-14>의 단변량 미국산 갈비 월별 가격 변동성의 평균과 표준편차를 나타낸 표이다. 예측 구간의 실제 변동률은 0.226으로 나타났으며, LSTM 모형과 GARCH 모형의 예측 값의 평균은 각각 0.291과 -0.067로 나타나 LSTM 모형이 GARCH 모형보다 실제 값의 평균과 근사한 것으로 나타났다. <그림 4-5>는 월별 가격 변동성 예측 값을 실제값과 비교하기 위하여 그래프로 나타냈으며, GARCH 모형보다 LSTM 모형이 실제 변동과

더 비슷하게 움직이는 것을 확인할 수 있다.

<표 4-14> 단변량 미국산 갈비 월별 가격 변동성 예측 결과

	실제 변동률	LSTM	GARCH
평균	0.266	0.291	-0.067
표준편차	0.0142	0.0108	0.0145

<그림 4-3> 단변량 미국산 갈비 월별 가격 변동성 예측 비교




<표 4-15>는 수입 삼겹살의 월별 가격 실제 변동과 예측 변동의 평균과 표준편차로 표현한 표이며, 수입 삼겹살 월별 가격 변동 역시 LSTM 모형이 GARCH 모형보다 예측 구간의 평균 변동을 더 가깝게 예측한 것을 볼 수 있다. <그림 4-4>는 수입 삼겹살의 월별 가격 변동의 실제값과 예측값을 나타낸 그래프로 LSTM 모형이 실제값과 근사하게 움직이는 것으로 나타났다.

<표 4-15> 단변량 수입 삼겹살 월별 가격 변동성 예측 결과

	실제 변동률	LSTM	GARCH
평균	0.233	0.206	0.346
표준편차	0.0110	0.0106	0.0089

<그림 4-4> 단변량 미국산 갈비 월별 가격 변동성 예측 비교



<표 4-16>와 <표 4-17>는 가격 변동성 단변량적 접근 방법을 이용하여 수입 축산물의 월별 가격 변동성을 예측한 결과를 비교한 표이다. <표 4-16>의 미국산 갈비의 월별 가격 변동성을 예측한 비교한 표에서 LSTM 모형이 GARCH 모형보다 더 정확한 것으로 나타났다. RMSE 통계량에서 LSTM 모형은 0.0142으로, GARCH 모형은 0.0186으로 나타났으며, 이는 LSTM 모형이 GARCH 모형보다 23.69% 더 정확한 예측값을 나타냈음을 의미한다. RMSPE 통계량에서도 2.5048의 LSTM 모형이 16.2622의 GARCH 모형보다 84.60% 더 정확하게 예측하였다.

<표 4-16> 단변량 미국산 갈비 월별 가격 변동성 예측 비교

	LSTM	GARCH
RMAE	0.1129	0.1222
RMSE	0.0142	0.0186
RMSPE	2.5048	16.2622

<표 4-17>는 단변량 수입 삼겹살 월별 가격 변동성의 예측력을 비교한 표이다. RMSE의 경우, LSTM 모형은 0.0114를, GARCH 모형은 0.0184를 나타냈으며, 이는 LSTM 모형이 GARCH 모형보다 38.20% 더 정확하게 예측함을 의미한다. RMSPE의 경우 LSTM 모형은 3.3351을, GARCH 모형은 10.0380을 나타냈다. 이 통계량 역시 LSTM 모형이 GARCH 모형보다 66.78% 더 정확한 예측함을 의미한다. 즉, 단변량적 접근에서 수입 삼겹살의 월별 가격 변동성을 예측한 결과는 LSTM 모형이 GARCH 모형보다 예측력이 높은 것으로 나타났다.

<표 4-17> 단변량 수입 삼겹살 월별 가격 변동성 예측 비교

	LSTM	GARCH
RMAE	0.0928	0.1237
RMSE	0.0114	0.0184
RMSPE	3.3351	10.0380

미국산 갈비와 수입 삼겹살의 월별 가격 변동성을 예측·비교한 결과, LSTM 모형이 GARCH 모형보다 더 정확한 예측을 수행한 것으로 나타났다.

단변량 모형에서는 일별 가격 변동성을 예측이 월별 가격 변동성 예측보다 높은 예측력을 보여주었으며, 일별 가격 변동성 예측과 월별 가격 변동성 예측 모두 GARCH 모형보다 LSTM 모형의 예측력이 높은 것으로 나타났다 또한 일별 가격 변동성과 월별 가격 변동성을 예측한 결과에서는 일별 가격 변동성을 예측할 때, 월별 가격 변동성을 예측한 때보다 정확한 것으로 나타났다. 이는 Pradhan and Kumar(2010), Zhang et al.(2020)과 동일하게 가격 정보의 주기가 짧을수록 정확한 예측을 할 수 있는 것으로 나타났다.

제4절 다변량 모형 추정 결과

본 연구는 다변량적 접근을 고려한 월별 가격 변동성을 예측하기 위하여 앞 절에서 언급한 DCC-GARCH(1,1) 모형을 이용하였다. 본 연구의 DCC-GARCH(1,1) 모형은 국내산 삼겹살 가격, 수입 축산물(미국산 갈비/수입 삼겹살)의 월별 수입량, 원·달러 환율, 소득을 대체하는 선행종합지수(2015=100)를 이용하였다.

2012년 1월부터 2018년 12월까지의 가격 변동성을 DCC-GARCH(1,1) 모형을 통해 분석한 결과는 다음 <표 4-14>와 같다. 우선 미국산 갈비의 가격 변동성을 DCC-GARCH(1,1) 모형을 분석한 결과, 평균 방정식의 국내산 삼겹살 가격, 미국산 갈비의 월별 수입량, 선행종합지수와 관계가 통계적으로 유의한 것으로 나타났다. 분산 방정식의 ARCH 항과 GARCH 항 모두 통계적으로 유의한 것으로 나타났다. ARCH 항과 GARCH 항은 각각 0.147과 0.807로 5% 유의 수준에서 귀무가설(H_0)을 기각하여 통계적으로 유의한 것으로 나타났다. 이는 국내산 삼겹살 가격과 미국산 갈비 월별 수입량, 원·달러 환율, 소득을 반영한 월별 미국산 갈비 가격 변동성은 전기($t-1$)의 충격이 현재(t)의 가격 변동에 영향을 미치며, 과거 전반의 시장 변화가 현재의 가격 변동에 영향을 미치고 있는 것으로 나타났다.

수입 삼겹살 변동성을 추정한 DCC-GARCH(1,1) 모형 추정 결과, 평균 방정식의 국내산 삼겹살 가격, 수입 삼겹살 수입량, 선행종합지수, 원·달러 환율의 계수 모두 통계적으로 유의한 것으로 나타났다. 분산 방정식의 ARCH 항은 0.347로 10% 유의 수준에서 귀무가설(H_0)을 기각하여 통계적으로 유의하였으며, GARCH 항은 0.657로 1% 유의 수준에서 통계적으로 유의한 것으로 나타났다. 수입 삼겹살 월별 가격 변동성 역시 미국산 갈비 가격 변동성과 동일하게, 수입 삼겹살 수요에 미치는 요인들을 반영하여 가격 변동성을 분석한 결과 전기($t-1$)의 충격이 현재(t)의 가격 변동에 영향을 미치며, 과거 전반의 시장 충격이 현재의 가격 변동에 영향을 미치고 있는 것으로 나타났다.

<표 4-18> 수입 축산물 가격 변동성의 DCC-GARCH(1,1) 모형 추정 결과

		미국산 갈비	수입 삼겹살
평균 방정식	국내산 삼겹살 가격	-0.038* (0.093)	-0.001** (0.031)
	수입 축산물 수입량	0.001** (0.041)	0.002** (0.017)
	선행종합지수	-0.005* (0.053)	-0.086** (0.079)
	원·달러 환율	-0.053 (0.441)	0.028** (0.076)
	상수항	0.298 (0.180)	0.083 (0.756)
분산 방정식	ARCH(1)	0.147** (0.033)	0.347* (0.059)
	GARCH(1)	0.807*** (0.000)	0.656*** (0.000)
	상수항	0.000 (0.116)	0.000 (0.173)

주1 : 수입 축산물 수입량은 각각 미국산 갈비의 수입량과 수입 삼겹살 수입량을 이용함.

주2 : ***, **, *는 각각 1%, 5%, 10% 유의 수준에서 통계적으로 유의함을 의미

미국산 갈비와 수입 삼겹살의 월별 가격 변동성에 대한 DCC-GARCH 분석을 토대로 변동성을 예측한 결과와 LSTM 모형을 통해 변동성을 예측한 결과, GARCH - LSTM 결합 모형의 예측 결과를 비교하였다. LSTM 모형과 GARCH-LSTM 모형은 2012년 1월부터 2018년 12월까지의 데이터를 학습 자료로 이용하였으며, 다변량 GARCH 모형, LSTM 모형과 GARCH-LSTM 모형 모두 2019년 1월부터 2019년 12월까지의 가격 변동성을 예측하였다.

LSTM 모형의 입력 변수로는 다변량 GARCH 모형과 같은 국내산 삼겹살 가격, 수입 축산물(미국산 갈비/수입 삼겹살)의 월별 수입량, 원·달러 환율, 소득을 대체하는 선행종합지수(2015=100)를 이용하였다. GARCH 모형과 LSTM 모형을 결합한 GARCH-LSTM 모형은 다변량 LSTM 모형과 동일하게 국내산 삼겹살 가격, 미국산 갈비의 월별 수입량, 원·달러 환율, 선행종합지수(2015=100)에 추가로 DCC-GARCH 모형을 통해 추정된 ARCH 항과 GARCH 항을 변수에 반영하여 추정하였다.

미국산 갈비 가격 변동성을 예측하기 위해 3개의 LSTM 층과 2개의 전결합 층으로 구성하였으며, 손실 비트를 LSTM 층에 각각 0.8, 0.3, 0.3 순으

로 하였다. LSTM 층의 노드는 각각 13개, 20개, 25개로 구성하였으며, 전결합 층의 노드는 5개, 1개로 구성하였다. GARCH-LSTM 모형은 LSTM 층 3개와 전결합 층 2개로 구성하였으며, 손실 비트는 LSTM 모형에 0.8, 0.3, 0.3 순으로 하였으며, LSTM 층의 노드는 각각 17개, 64개, 15개로 구성하였으며, 전결합 층의 노드는 5개와 1개로 구성하였다.


수입 삼겹살의 가격 변동성을 예측하기 위한 LSTM 모형 역시 3개의 LSTM 층과 2개의 전결합 층으로 구성하였으며, 손실 비트를 LSTM 층에 각 0.8, 0.3, 0.3 순으로 하였다. LSTM 층의 노드는 15개, 30개, 25개로 구성하였으며, 전결합 층의 노드는 5개, 1개로 구성하였다. GARCH-LSTM 모형은 LSTM 층 3개와 전결합 층 2개로 구성하였으며, 손실 비트는 LSTM 모형에 0.8, 0.3, 0.3 순으로 하였으며, LSTM 층의 노드는 각각 15개, 23개, 20개로 구성하였으며, 전결합 층의 노드는 5개와 1개로 구성하였다.

위의 조건을 통하여 분석한 결과, <표 4-19>와 <표 4-20>는 실제 변동률과 예측 변동률을 평균으로 나타낸 것이며, <그림 4-5>과 <그림 4-6>은 실제 변동률과 예측 변동률을 그래프로 나타낸 것이다. <표 4-19>의 다변량적 접근 방법을 통해 예측한 미국산 갈비의 월별 가격 변동성 예측 결과를 평균과 표준편차로 나타낸 결과로, 평균 변동은 LSTM 모형이 실제 변동률과 가장 비슷한 것으로 나타났으며, 다음으로 GARCH-LSTM, GARCH 모형으로 나타났다. 그러나 <그림 4-5>을 통해 GARCH-LSTM 모형이 LSTM 모형보다 실제 변동과 비슷하게 움직이는 것을 확인할 수 있다.

<표 4-19> 다변량 미국산 갈비 월별 가격 변동성 예측 결과

	실제 변동률	GARCH-LSTM	LSTM	GARCH
평균	0.266	0.211	0.258	0.366
표준편차	0.0143	0.0126	0.0113	0.0072

<그림 4-5> 다변량 미국산 갈비 월별 가격 변동성 예측 결과




<표 4-20>의 다변량적 접근 방법을 이용하여 수입 삼겹살 월별 가격 변동을 예측한 결과를 예측 구간 동안의 평균으로 나타낸 결과, GARCH-LSTM 모형이 실제 변동과 가장 흡사한 것으로 나타났으며, 다음으로 LSTM 모형, GARCH 모형으로 나타났다. 표준편차 역시 GARCH-LSTM 모형이 가장 비슷한 것으로 나타났다. <그림 4-6>의 실제 값과 예측값의 그래프에서 볼 수 있듯, GARCH-LSTM 모형이 다른 모형 LSTM 모형과 GARCH 모형보다 실제와 비슷하게 움직이는 것을 볼 수 있다.

<표 4-20> 다변량 수입 삼겹살 월별 가격 변동성 예측 결과

	실제 변동률	GARCH-LSTM	LSTM	GARCH
평균	0.0023	0.0011	-0.0009	-0.0020
표준편차	0.0110	0.0106	0.0089	0.0051

<그림 4-6> 다변량 수입 삼겹살 월별 가격 변동성 예측 결과



<표 4-21>과 <표 4-22>는 월별 가격 변동성을 다변량 GARCH 모형과 LSTM 모형을 통해 분석하여 손실 함수를 통해 비교한 결과이다. <표 4-21>는 다변량 수입 갈비의 월별 변동성을 예측한 결과이다. RMSE 통계량에서는 GARCH- LSTM 모형이 0.0136, LSTM 모형의 경우 0.0137, GARCH 모형은 0.0139로 나타났다. 이는 GARCH-LSTM 모형이 LSTM 모형보다 0.67%, LSTM 모형이 GARCH 모형보다 1.27% 더 정확한 예측성을 보였음을 의미한다. RMSPE 통계량을 이용하여 예측력을 비교한 결과로는 GARCH-LSTM 모형은 1.2481, LSTM 모형은 1.5340, GARCH 모형은 1.5779로 나타나, GARCH-LSTM 모형이 LSTM 모형보다 1.864%, LSTM 모형이 GARCH 모형보다 2.78% 정확한 예측력을 보여주었다. 따라서 다변량을 이용한 미국산 갈비의 가격 변동성을 예측·비교한 결과 GARCH-LSTM 모형이 가장 정확한 예측값을 가졌으며, 다음으로 LSTM 모형, GARCH 모형 순으로 정확도가 높은 것으로 나타났다.

<표 4-21> 다변량 수입 갈비 월별 가격 변동성 예측 비교

	GARCH-LSTM	LSTM	GARCH
RMAE	0.1114	0.1115	0.1197
RMSE	0.0136	0.0137	0.0139
RMSPE	1.2481	1.5340	1.5779

<표 4-22>은 수입 삼겹살의 월별 가격 변동성을 다변량적 접근을 통해 분석한 결과이다. RMSE 통계량에서는 GARCH-LSTM 모형이 0.0105, LSTM 모형이 0.0106, GARCH 모형이 0.0107로 나타났다. 이는 큰 차이를 보이지는 않았으나, GARCH-LSTM 모형이 LSTM 모형보다 1.07%, LSTM 모형이 GARCH 모형보다 0.35% 정확한 예측을 한 것으로 나타났다. RMSPE 통계량의 경우 GARCH-LSTM 모형이 1.0017, LSTM 모형이 1.0378, GARCH 모형이 1.0539로 LSTM 모형이 GARCH 모형보다 4.95%, LSTM 모형이 GARCH 모형보다 1.52% 정확하게 예측한 것으로 나타났다. 따라서 다변량 수입 삼겹살 월별 가격의 변동성을 예측할 때, 미국산 갈비와 같이 GARCH-LSTM 통합모형이 가장 높은 정확도를 보였으며, 다음으로 LSTM 모형, GARCH 모형 순으로 정확도가 높은 것으로 나타났다.

<표 4-22> 다변량 수입 삼겹살 월별 가격 변동성 예측 비교

	GARCH-LSTM	LSTM	GARCH
RMAE	0.0893	0.0918	0.0924
RMSE	0.0105	0.0107	0.0107
RMSPE	1.0017	1.0378	1.0539

따라서 다변량 수입 축산물의 월별 가격 변동성을 예측한 결과를 손실 함수를 통해 비교한 결과, GARCH 모형보다 LSTM 모형이, LSTM 모형보다 GARCH-LSTM 모형이 변동성 예측에 적합한 것으로 나타났다.

제5절 모형 간의 예측력 비교

앞에서 비교한 손실 함수를 통해 모형 예측력을 통해 실제 값과 예측 값을 비교하였다. 그러나 손실 함수를 통해 모형 간의 예측력을 완벽하게 비교하기는 어렵기 때문에, Diebold and Mariano(1995)의 DM 검정을 조정하여, 적은 표본으로 모형 간의 예측력을 비교가 가능한 Modified DM 검정을 통해 예측력을 비교하였다. 본 연구에서는 MDM 검정을 MSE를 기준으로 분석하였으며, 예측 개수가 같은 모형 간의 변동성 예측 결과를 비교하였다.

<표4-23>은 수입 축산물의 예측력 비교를 위하여 LSTM 모형을 기준으로 GARCH 모형과 MDM 검정을 실시한 결과이다. 일별 가격 변동성 예측 결과는 미국산 갈비와 수입 삼겹살 모두 LSTM 모형이 GARCH 모형보다 통계적으로 유의한 높은 예측력을 보였다.

<표 4-23> 수입 축산물 가격 변동성 예측력 비교

	미국산 갈비	수입 삼겹살
GARCH	-1.888* (0.084)	-2.882*** (0.005)

<표 4-24>와 <표 4-25>는 미국산 갈비와 수입 삼겹살의 예측 모형 간 비교한 결과를 정리한 표이다. 미국산 갈비 예측력을 비교한 결과, 다변량 모형에서 GARCH-LSTM 모형과 LSTM 모형, GARCH-LSTM 모형과 GARCH 모형의 MDM 검정은 각각 10%, 1% 유의 수준에서 귀무가설을 기각하여, 예측력의 차이가 통계적으로 유의한 것으로 나타났다. 또한, LSTM 모형과 GARCH 모형 사이의 MDM 검정 결과, 1% 유의 수준에서 통계적으로 유의한 예측력 차이를 보였다. 단변량 모형 역시 LSTM 모형이 GARCH 모형이 10% 유의 수준에서 귀무가설을 기각하여 예측력의 차이의 유의미한 것으로 판단되었다. 다변량 모형과 단변량 모형 사이의 차이는 기존의 연구와 같이 다변량 모형과 단변량 모형의 예측력 차이가 통계적으로 유의한 것으로 나타났다. 다변량 LSTM 모형이 단변량 LSTM 모형, 단변량 GARCH 모형과의 예측력이 1% 유의 수준에서 통계적으로 유의한 차이가 있는 것으로 나타났다.

로 나타났으며, 다변량 GARCH 모형이 단변량 GARCH 모형보다 통계적으로 유의한 차이를 보였다. 그러나 다변량 GRACH 모형과 단변량 LSTM 모형의 차이는 통계적으로 유의하지 않은 것으로 나타났다.

<표 4-24> 미국산 갈비 가격 변동성 예측력 비교

		다변량			단변량	
		GARCH-LSTM	LSTM	GARCH	LSTM	GARCH
다변량	GARCH-LSTM					
	LSTM	-2.615* (0.056)				
	GARCH	-3.862*** (0.001)	-3.451*** (0.003)			
단변량	LSTM	-3.997*** (0.001)	-3.471*** (0.003)	-0.484 (0.461)		
	GARCH	-4.670*** (0.000)	-4.090*** (0.000)	-2.891** (0.043)	-2.054* (0.082)	

<표 4-25>의 수입 삼겹살 가격 예측력 비교를 살펴본 결과, GARCH-LSTM 모형이 LSTM 모형과 GARCH 모형보다 예측력이 높은 것으로 나타났으며, 단변량 모형보다 다변량 모형의 예측력이 더 높은 것을 알 수 있다. 다변량 GARCH-LSTM 모형이 LSTM 모형과 GARCH 모형을 10% 유의 수준에서 MDM 검정의 귀무가설을 기각하여, 예측력에 통계적으로 유의한 차이를 보였으며, 단변량 모형과 다변량 모형 모두에서 LSTM 모형이 GARCH 모형보다 높은 예측력을 보였다.

<표 4-25> 수입 삼겹살 가격 변동성 예측력 비교

		다변량			단변량	
		GARCH-LSTM	LSTM	GARCH	LSTM	GARCH
다변량	GARCH-LSTM					
	LSTM	-2.202* (0.070)				
	GARCH	-2.387* (0.08)	-2.049* (0.083)			
단변량	LSTM	-2.459* (0.061)	-2.536* (0.08)	-1.717* (0.091)		
	GARCH	-3.635*** (0.002)	-2.809** (0.040)	-1.894* (0.089)	-3.731*** (0.002)	

종합적으로 인공신경망인 LSTM 모형을 이용한 예측성도가 기존의 시계열 모형인 GARCH 모형을 이용한 예측 결과보다 정확한 결과를 보였다. GARCH 모형, LSTM 모형과 GARCH-LSTM 결합모형의 결과를 비교한 결과, GARCH-LSTM 모형의 결과가 가장 정확한 것으로 나타났다. 이러한 결과는 변동성을 반영하여 LSTM 모형을 이용한 변동성 추정할 때, 보다 정확한 예측이 가능함을 의미하며, Kim and Won(2018), Yu and Li(2018) 등과 같은 연구와 동일한 결과를 같이 하였다.

제5장 요약 및 결론

소득의 증가 및 식생활의 변화 등으로 인해 축산물의 생산 및 소비가 증가하고, 축산물은 중요한 식량 자원으로 인식되어 가고 있다. 국내의 축산물 수요 증가와 더불어 국제 사회 변화, 국내 축산물 가격 심한 가격 변동 등으로 인하여, 수입 축산물에 대한 수요가 증가하고 있고, 이러한 수요에 맞춰 해외로부터 축산물의 수입이 매년 증가하고 있다. 그러나 국내의 수입 축산물 가격에 관한 연구 역시 미비한 실정이다.

최근 4차 산업의 등장 및 빅데이터의 중요성 등의 이유로 인공지능을 활용한 연구가 진행되고 있다. 인공신경망이 그 대표적인 접근 방식이다. 인공신경망은 인간의 두뇌를 수학적으로 풀이하여 변수 간의 관계를 분석하는 것으로, 기존의 시계열 분석 접근 방법의 한계를 극복하였다. 본 연구는 이러한 수입육 수요의 증가와 더불어 인공지능의 발전을 고려하여 인공신경망, 특히 LSTM 모형 이용하여 수입육 가격 변동성을 예측하고자 하였다.

본 연구에서는 국내에 가장 많이 수입되는 미국산 갈비와 수입 삼겹살의 소비자 가격을 이용하여 분석하였다. 일별 가격 자료와 월별 가격 자료를 이용하여 분석하였으며, 단변량과 다변량 모형으로 구분하여 분석하였다. 단변량 모형은 일별과 월별로 GARCH 모형과 LSTM 모형을 비교 분석하였으며, 다변량 모형은 DCC-GARCH 모형과 LSTM 모형, DCC-GARCH 모형에서 도출한 ARCH 효과와 GARCH 효과를 고려한 GARCH-LSTM 결합 모형을 비교 분석하였다.

먼저 단변량 일별 분석 결과는 미국산 갈비와 수입 삼겹살 가격 변동성에는 GARCH 효과만 있는 것으로 나타나, 직전 시점($t-1$)의 충격이 가격 변동성에 미치는 영향은 통계적으로 유의하지 않으나 과거 전반의 충격이 미국산 갈비와 수입 삼겹살 가격 변동성에 영향을 미치는 것으로 나타났다. 이와 더불어 LSTM 모형과 GARCH 모형의 변동성 예측력 비교의 결과는 LSTM 모형이 GARCH 모형보다 오차가 적게 예측한 것으로 나타났다.

단변량 월별 가격 변동성을 분석한 결과 역시 미국산 갈비와 수입 삼겹살 GARCH 효과가 있는 것으로 나타났다. 그러나 미국산 갈비는 ARCH 효

과가 있었던 반면 수입 삼겹살은 ARCH 효과가 없는 것으로 나타났다. 이는 미국산 갈비의 월별 가격 변동성은 직전 시점($t-1$)의 충격이 현재의 가격 변동성에 영향을 미치며, 과거 전반의 가격 변동성에 영향을 미치는 반면, 수입 삼겹살의 월별 가격 변동성은 직전 시점($t-1$)의 충격이 현재의 가격 변동성에 영향이 통계적으로 유효하지 않으며, 과거 전반의 가격 변동성에 영향을 받음을 의미한다. 한편 예측력을 비교한 결과 미국산 갈비와 수입 삼겹살 가격 변동성을 LSTM 모형으로 예측할 때, GARCH 모형으로 예측한 결과보다 정확한 것으로 나타났다.

다변량 월별 가격 변동성은 DCC-GARCH 모형과 LSTM 모형, GARCH-LSTM 결합모형을 이용하여 분석하였다. 미국산 갈비와 수입 삼겹살 모두에서 ARCH 효과와 GARCH 효과가 나타나는 것으로 나타났으며, 이를 통해 분석한 결과 GARCH-LSTM 모형, LSTM 모형, DCC-GARCH 모형 순으로 예측 정확도를 보였다.

종합적으로 단변량적 접근 방법을 통해 가격 변동성을 예측할 때보다 다변량적 접근 방법을 통해 가격 예측한 결과가 더 좋은 것으로 나타났으며 변동성을 반영한 인공신경망을 통해 가격 변동성을 예측할 경우, 그렇지 않은 분석보다 정확한 예측이 가능하였다. 일별 가격 변동성을 예측한 결과가 월별 가격 변동성을 예측한 결과보다 좋은 것으로 나타났다.

본 연구는 인공신경망 중 LSTM 모형과 GARCH 모형, LSTM 모형과 GARCH 모형의 결합한 GARCH-LSTM 모형을 이용하여 수입 축산물 가격의 변동성을 예측하였다. 수입 축산물의 수입량과 수요가 증가함에 따라 수입 축산물의 가격 변동성을 예측함에 따라 여러 의사결정자의 의사결정에 정보를 제공하는 역할을 할 것이다. 최근 주목받고 있는 인공신경망, 특히 LSTM 모형을 이용하여 가격 변동성을 예측하여, 기존 시계열 모형인 GARCH 모형보다 정확한 결과를 도출하였음에 의미가 있다고 볼 수 있다.

참고문헌

- 경영·정책연구』. 34(2) : 369-388
- 강태훈. 2004. 「채소류 가격의 비선형동학적 특성」, 『농업경제연구』. 45(1) : 83-101
- 강현수. 2011. 「수입수요함수를 이용한 쌀 수입에 대한 실증분석 : 주요 쌀 수입국들의 후생변화를 중심으로」, 『무역연구』. 7(3) : 319-337
- 고봉현. 2007. 「GARCH 모형을 이용한 수산물의 가격 변동성에 관한 연구」, 『해양정책연구』. 22(2) : 29-54
- 권용덕. 2008. 「수입개방이 국내 쇠고기 가격의 전이성에 미치는 영향」, 『농업경영·정책연구』. 35(1) : 72-90
- 김민경, 김학수. 2017. 「Convolutional Neural Network에서 공유 계층의 부분 학습에 기반한 화자 의도 분석」, 『정보과학회 논문지』. 44(12) : 1252-1257
- 김상환. 2015. 「KOSPI200 변동성 예측성과 : 주기적 모형추정과 다기간 예측」, 『재무관리연구』. 32(1) : 187-213
- 김상환. 2013. 「다변량 GARCH모형의 개관과 응용」, 『산업과 경영』. 26(2) : 159-179
- 김양중, 김원년. 2013. 「중국 축산물과 수산물의 수입수요 분석」, 『Journal of the Korean Data Analysis Society』. 15(4) : 2179-2188
- 김원태. 2017. 「AIDS 모형을 이용한 육류 수요변화 요인 분석」, 『농업경영·정책연구』. 44(3) : 389-409
- 김혜영, 김태균. 2003. 「육류 수요체계의 내생성과 구조변화」, 『농촌경제』. 26(3) : 39-53
- 노태협, 이택호, 한인구. 2005. 「인공신경망-금융 시계열 모형을 이용한 KOSPI 200 주가지수의 변동성 예측」, 『경영학연구』. 34(3) : 683-713
- 류두진. 2012. 「변동성 예측 모형의 실증성과에 관한 연구 : 미국 시장을 중심으로」, 『금융공학연구』. 11(3) : 59-82

- 명광식. 2005. 「Box - Jenkins 모형을 이용한 육계가격 예측」, 『농촌경제』. 28(2) : 73-83
- 박관희, 최문선, 황선영. 2011. 「금융 시계열 분석을 위한 다변량 -GARCH 모형에서 비대칭-CCC의 도입 및 응용」, 『응용통계연구』. 24(5) : 821-831
- 박병기, 신용재, 이준희, 박훈. 2014. 「GARCH 분산국면전환 (GARCH Variance Regime Switching) 모형을 이용한 한국 주식시장의 변동성 분석」, 『산업경제연구』. 27(2) : 707-731
- 박세린, 백창룡. 2014. 「리스크 관리 측면에서 살펴본 다변량 GARCH 모형 선택」, 『한국데이터정보과학회지』. 25(6) : 1333-1343
- 서대교, 신종협. 2014. 「가축 질병이 축산물 가격에 미친 영향 분석」, 『산업경제연구』. 27(6) : 2431-2450
- 송대식. 2001. 「육계의 가격 예측과 가격 변화에 관한 연구」, 『식품유통연구』. 18(1) : 117-130
- 심재현, 조찬호, 이성호. 2007. 「인공신경망을 이용한 산업용지의 공급가격 산정」, 『국토계획』. 42(5) : 223-232
- 양승룡, 박유신. 1998. 「신경망(Neural Networks)을 이용한 축산물 가격의 예측 모형 개발」, 『농업경제연구』. 40(1) : 105-127
- 유한수. 2010. 「한우 산지 가격 변동성과 한우 도매가격 변동성」, 『기업경영연구』. 17(3) : 61-73
- 윤병삼. 2008. 「육류시장의 가격 변동성, 계절성 및 요일 효과」, 『농업경영·정책연구』. 35(1) : 21-38
- 이건일, 이종혁. 2015. 「순환신경망을 이용한 전이 기반 한국어 의존 구문 분석」, 『정보과학회 컴퓨팅의 실제 논문지』. 21(8) : 567-571
- 이계임, 최지현. 2000. 「육류 수요의 대체성과 분리성 분석」, 『농업경제연구』. 41(1) : 45-60
- 이낙영, 오경주. 2019. 「디노이징 필터와 LSTM을 활용한 KOSPI200 선물지수 예측」, 『한국데이터정보과학회지』. 30(3) : 645-654

- 이병기. 2001. 「축산물 가격의 동태적 조정과 시사점 - 돼지고기 가격의 변동요인 분석」, 『농업경제연구』. 42(1) : 63-84
- 이석일, 김선웅, 윤병삼. 2015. 「육계 가격 예측 모형의 예측력 비교 평가」, 『농업경영·정책연구』. 42(2) : 232-248
- 이춘수, 양승룡. 2013. 「돈육선물시장 분석 : 가격 예측력 인과관계, 효율성을 중심으로」, 『농업경영·정책연구』. 40(2) : 400-429
- 이현주, 김희철. 2010. 「패널 데이터 모형을 적용한 가구당 월평균 가계소득 결정요인 추정에 관한 연구」, 『한국산업기술학회 논문지』. 11(6) : 2038-2045
- 이형우, 강대운, 한석호. 2016. 「한우고기와 수입 쇠고기 시장 차별화에 대한 실증 분석」, 『농촌경제』. 39(3) : 01-21
- 정경수, 김민경, 서한손. 2015. 「회귀 진단을 통한 한우고기와 수입 쇠고기의 대체성 추정」, 『농업경제연구』. 56(4) : 31-50
- 정성호, 초효섭, 김정엽, 이기하. 2018. 「딥러닝 기반 LSTM 모형을 이용한 감조하천 수위 예측」, 『한국수자원학회논문집』. 51(12) : 1207-1216
- 정지현, 문홍성, 장재봉, 김민경. 2018. 「수입 축산물의 비대칭적 가격 전이」, 『농업경영·정책연구』. 45(3) : 376-397
- 조재환, 이정환, 조영득. 2011. 「국내산 쇠고기의 등급별 대체성과 가격 결정」, 『농업경제연구』. 52(3) : 79-92
- 주영찬, 제상영. 2013. 「DECO 모형과 DCC 모형의 비교분석: 금융시장 사례연구」, 『산업경제연구』. 26(6) : 2431-2442
- 최종산. 2016. 「계절 시계열 모형의 육류 소매가격 추정 및 예측 정확도 평가」, 『식품유통연구』. 33(1) : 1-31
- 허덕, 이형우, 이정민. 2010. 「쇠고기 수입 증가에 따른 하반기 한우 가격 영향 분석」, 『한국농촌경제연구원 농정포커스』. 65
- 황성원, 류혁선. 2011. 「국면전환 GARCH 모형을 이용한 변동성 구조 분석 및 예측에 관한 실증연구」, 『한국증권학회지』. 40(1) : 171-194
- Aijun Hou, Sandy Suardi. 2012. 「A nonparametric GARCH model of crude oil price return volatility」, 『Energy Economics』. 34(2) : 618-626
- AnnaCreti, MarcJoëts, ValérieMignon. 2013. 「On the links

- between stock and commodity markets' volatility」, 『Energy Economics』. 37 : 16-28
- Banhi Guha, Gautam Bandyopadhyay. 2016. 「Gold Price Forecasting Using ARIMA Model」, 『Journal of Advanced Management Science』. 4(2) : 117-121
- Catherin Mann, Katharina Pluck. 2007. 「The U.S. Trade Deficit : A Disaggregated Perspective」, 『in Richard Clarida ed., G7 Current Account Imbalances』. Sustainability and Adjustment, University of Chicago Press
- Claudia R. Rodriguez, George J. Anders. 2004. 「Energy Price Forecasting in the Ontario Competitive Power System Market」, 『IEEE』. 19(1) : 366-374
- Claudio Morana. 2001. 「A semiparametric approach to short-term oil price forecasting」, 『Energy Economics』. 23 : 325-338
- Dirk Ormoneit, Ralph Neuneier. 1996. 「Experiments in Predicting the German Stock Index DAX with Density Estimating Neural Networks」, 『In Proceedings of the IEEE/IAEFE 1996 conference on computational intelligence for financial engineering』. 66-71
- Do Hebb. 1949. 「The organization of behavior: a neuropsychological theory」, Mahwah, N.J. : L. Erlbaum Associates.
- Dwight R. Sanders, Mark R. Manfredo. 2003. 「USDA Livestock Price Forecasts: A Comprehensive Evaluation」, 『Journal of Agricultural and Resource Economics』. 28(3) : 316-334
- Elhanan Helpman , Paul Krugman. 1985. 「Market Structure and Foreign Trade : Increasing Returns, Imperfect Competition, and the International Economy」, The MIT Press Cambridge. MA.

- F. Gonzalez Miranda, N. Burgess. 1997. 「Modelling market volatilities: the neural network perspective」, 『The European Journal of Finance』. 3(2) : 137-157
- G. Peter Zhang. 2003. 「Time series forecasting using a hybrid ARIMA and neural network model」, 『Neurocomputing』. 50 : 159-175
- G. Peter Zhang, B.Eddy Patuwo, Micheal Y. Hu. 2001. 「A simulation study of artificial neural networks for nonlinear time-series forecasting」, 『Computers & Operations Research』. 28(4) : 381-396
- Gunter Meissner, Noriko Kawano. 2001. 「Capturing the volatility smile of options on high-tech stocks - A combined GARCH-neural network approach」, 『Journal of Economics and Finance』. 25(3) : 276-292
- H He, J Lin. 2016. 「Pairwise word interaction modeling with deep neural networks for semantic similarity measurement」, 『In Proceedings of NAACL/HLT.』. <http://www.aclweb.org/anthology/N16-1108>.
- HY Kim, CH Won. 2018. 「Forecasting the volatility of stock price index : A hybrid model integrating LSTM with multiple GARCH-type models」, 『Expert Systems with Applications』. 103(1) : 25-37
- Ikbāl Eski, Selcuk Erkaya, Sertaç Savas, Sahin Yildirim. 2011. 「Fault detection on robot manipulators using artificial neural networks」, 『Robotics and Computer-Integrated Manufacturing』. 27(1) : 115-123
- J.J. Hopfield, DW Tank. 1986. 「Computing with neural circuits : a model」, 『Science』. 233 : 625-633
- Jane P.Brown, Haiyan Song, Alan McGillivray. 1997. 「forecasting UK house prices : A time varying coefficient approach」, 『Economic Modelling』. 14(4) : 529-548

- Kai Chen, Yi Zhou, Fangyan Dai. 2015. 「A LSTM-base method for stock returns prediction : A case study of China stock market」, 『2015 IEEE International Conference on Big Data (Big Data)』. 2823-2824
- Krugman. 1989. 「Differnces in Income Elasticities and Trends in Real Exchange Rates」, 『European Economic Review』. 35(5) : 1055-1085
- LD Dumas, FAL Aiube, TKN Baidya. 2017. 「Hedging Stocks Through Commodity Indexes: A DCC-GARCH Approach」, https://impa.br/wp-content/uploads/2017/11/RiO2017-PP_FAiube.pdf..
- Lonnie Hamm, B. Wade Brorsen. 1997. 「Forecasting Hog Prices with a Neural Network」, 『Journal of Agribusiness』. 15(1) : 37-54
- M. Hansson. 2017. 「On stock return prediction with LSTM networks」, Department of Economics Lund University. 2017
- Menzie Chinn. 2010. 「Supply Capacity, Vertical Specialization and Trade Costs : The Implications for Aggregate US Trade Flow Equations」, 『University of Wisconsin, Madison, manuscript』. Madison
- Micheal W Brandt, Chritopher S Jones. 2006. 「Volatility Forecasting With Range-Based EGARCH Model」, 『Journal of Business & Economic Statistics』. 24(4) : 470-486
- Nicholas Apergis, Anthony Rezitis. 2003. 「Agricultural price volatility spillover effects: the case of Greece」, 『European Review of Agricultural Economics』. 30(3) : 389-406
- Olga Isengildina, Scott H. Irwin, Darrel L. Good. 2004. 「Evaluation of USDA Interval Forecasts of Corn and Soybean Prices」, 『American Journal of Agricultural Economics』. 86(4) : 990-1004
- Peter F. Christoffersen. 1998. 「Evaluating Interval Forecasts」, 『Symposium on Forecasting and Empirical Methods in Macroeconomics and Finance』. 39(4) : 841-862

- R. F. Engle. 1982. 「Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation」, 『Econometrica: Journal of the Econometric Society』. 50(4) : 987-1007
- R. F. Engle. 2002. 「Dynamic conditional correlation: A simple class of multivariate generalized autoregressive conditional heteroskedasticity models」, 『Journal of Business and Economic Statistics』. 20(3) : 339-350
- R. Glen Donaldson, Mark Kamstra. 1997. 「An artificial neural network-GARCH model for international stock return volatility」, 『Journal of Empirical Finance』. 4(1) : 17-46
- Richard E. Just, Gordon C. Rausser. 1981. 「Commodity Price Forecasting with Large-Scale Econometric Models and the Futures Market」, 『American Journal of Agricultural Economics』. 63(2) : 197-208
- Robert Feenstra. 1994. 「New Product Varieties and the Measurement of International Prices」, 『The American Economic Review』. 84(1) : 115-145
- Rudra P. Pradhan, Rajesh Kumar. 2010. 「Forecasting Exchange Rate in India : An Application of Artificial Neural Network Model」, 『Journal of Mathematics Research』. 2(4) : 111-117
- S. Y. King, J. N. Hwang. 1989. 「Neural network architectures for robotic applications」, 『IEEE Transactions on Robotics and Automation』. 5(5) : 641-657
- S.V. Aradhyula, M.T. Holt. 1988. 「GARCH time-series models: an application to retail livestock prices」, 『Western Journal of Agricultural Economics』. 13(2) : 365-374
- Sepp Hochreiter, Jurgen Schmidhuber. 1997. 「Long Short-Term Memory」, 『Neural Computation』. 9(8) : 1735-1780
- Shaikh A. Hamid, Zahid Iqbal. 2004. 「Using neural networks for forecasting volatility of S&P 500 Index futures prices」, 『Journal of Business Research』. 57(10) : 1116-1125

- Shuiling Yu, Zhe Li. 2018. 「Forecasting Stock Price Index Volatility with LSTM Deep Neural Network」, 『Recent Developments in Data Science and Business Analytics』. 265-272
- ShuiLing Yu, Zhe Li. 2018. 「Forecasting Stock Price Index Volatility with LSTM Deep Neural Network」, 『Recent Developments in Data Science and Business Analytics』.
- Sima Siami-Namini, Neda Tavakoli, Akbar Siami Namin. 2018. 「A Comparison of ARIMA and LSTM in Forecasting Time Series」, 『2018 17th IEEE International Conference on Machine Learning and Applications (ICMLA)』. 1394-1401
- T. Bollerslev. 1986. 「Generalized autoregressive conditional heteroskedasticity」, 『Journal of Econometricx』. 31 : 307-327
- T. Bollerslev. 1990. 「Modelling the coherence in short-run nominal exchange rates: a multivariate generalized ARCH model」, 『The Review of Economics and Statistics』. 72(3) : 498-505
- T. Bollerslev, R. F. Engle, J. M. Wooldridge. 1988. 「capital asset pricing model with time-varying covariances.」, 『Journale of Political Economy』. 96(1) : 116-131
- T. Kesavan, Satheesh V. Aradhyula, Stanley R. Johnson. 1992. 「Dynamics and Price Volatility in Farm-Retail Livestock Price Relationships」, 『Journal of Agricultural and Resource Economics』. 17(2) : 348-361
- TH Roh. 2007. 「Forecasting the volatility of stock price index」, 『Expert Systems with Application』. 33 : 916-922
- TH Roh. 1996. 「A comparison of artificial neural network and time series models for forecasting commodity prices」, 『Neurocomputing』. 10(2) : 169-181
- Vasilios Plakandaras, Rangan Gupta, Periklis Gogas, Theophilos Papadimitriou. 2015. 「Forecasting the U.S. real house price index」, 『Economic Modelling』. 34(7) : 259-267

- Vasilios Plakandaras, Theophilos Papadimitriou, Periklis Gogas. 2015. 「Forecasting Daily and Monthly Exchange Rates with Machine Learning Techniques」, 『Journal of Forecasting』. 34(7) : 560-573
- Warren S. McCulloch, Walter Pitts. 1943. 「A logical calculus of the ideas immanent in nervous activity」, 『The bulletin of mathematical biophysics』. 5 : 115-133
- Werner Kristjanpoller, Marcel C. Minutolo. 2015. 「Gold price volatility : A forecasting approach using the Artificial Neural Network-GARCH model」, 『Expert Systems with Application』. 42(20) : 7245-7251
- Y. K. Tse, Albert K. C. Tsui. 2002. 「A Multivariate Generalized Autoregressive Conditional Heteroscedasticity Model with Time-Varying Correlations」, 『Journal of Business and Economic Statistics』. 20(3) : 351-362
- Yi-Hsien Wang. 2009. 「Nonlinear neural network forecasting model for stock index option price : Hybrid GJR-GARCH approach」, 『Expert Systems with Application』. 36(1) : 564-570
- Zhen Zhang, Xinliang Pan, Tao Jiang, Baikai Sui, Chenxi Liu, Weifu Sun. 2020. 「Monthly and Quarterly Sea Surface Temperature Prediction Based on Gated Recurrent Unit Neural Network」, 『Journal of Marine Science and Engineering』. 8(4) : 249

ABSTRACT

Analysis of the Predicted Volatility of

Imported Meat Price based on GARCH and LSTM

Kim Kyoung Jin

Department of Livestock Business & Marketing Economics

Graduate School of Konkuk University

In Korea, livestock products have become an important food resource as consumption increases. At the same time, the number of imported livestock products have increased due to increased demand for imported livestock products, and they are rapidly replacing domestic livestock products. As the price change of imported livestock affects the price of domestic livestock products, predicting the price volatility of imported livestock price plays important role in the domestic industry.

This study analyzed the consumer prices of U.S beef ribs and imported pork belly among imported livestock products. They were predicted using GARCH and DCC-GARCH that were the traditional time-series models. In addition, variability was predicted using the artificial neural network, especially the LSTM that suitable for time series analysis, which is drawing attention due to deep learning and machine learning, and the GARCH-LSTM integrated model, which combines the LSTM and GARCH, was used to predict variability and compare the predicted accuracy with the GARCH. Monthly and daily data were used for the same period in the analysis, and the one-variable approach using price variability data, and the multivariate approach by adding explanatory variable affecting import of imported livestock products, domestic

pork belly prices, import volume of imported livestock products, leading comprehensive index, and won-dollar exchange rates.

The results of the analysis are as follows :

First, the results of the GARCH of U.S ribs and Imported pork belly using daily price data showed GARCH effect that affected price volatility.

Second, the LSTM showed higher accuracy than the GARCH as a result of comparing the predictive power of the U.S. ribs and imported pork belly variability model using daily price data.

Third, the analysis of the GARCH of U.S. ribs and imported pork belly using monthly price data showed that the price change had both ARCH effects at the moment just before, and GARCH effects at the time when price changes were affected throughout the past, but only GARCH effects at imported pork belly.

Fourth, the LSTM showed higher accuracy than the GARCH as a result of predicting the price variability of U.S. ribs and imported pork belly using monthly price data through a mono-variate approach.

Fifth, an analysis of the DCC-GARCH of U.S. rib and imported pork belly using monthly price data through multivariate approach showed that U.S. rib and imported pork belly had both ARCH and GARCH effects.

Sixth, the GARCH-LSTM integration model had the highest predictability, followed by the LSTM and the DCC-GARCH, as a result of comparing the predictive power using the DCC-GARCH model and the GARCH-LSTM integration model.

In this study, the LSTM showed higher accuracy than the GARCH, and the GARCH-LSTM integrated model showed higher predictive power than the single model. In addition, the results of the daily price variability forecast showed that the accuracy was higher than that of the monthly price variability forecast, and that the multivariate approach was more accurate than the mono-variate approach.

Keyword : Imported livestock, Artificial neural network, GARCH, LSTM, GARCH- LSTM integrated model