

LSTM 모델 기반 아쿠아포닉스 시스템 EC 예측 및 순환수제어 알고리즘 구현

이 정 호*, 백 정 현°, 양 오 석*

Implementation of LSTM Model-Based Aquaponics System EC Prediction and Hydronic Control Algorithm

Jeong-Ho Lee*, Jeong-Hyun Baek°, Oh-Seok Yang*

요 약

아쿠아포닉스 시스템은 수경재배와 어류 양식을 통합한 시스템으로 어류 양식에 사용된 물을 재사용해서 기존의 농업 대비 물 사용량과 화학비료의 사용량을 줄이고 생산성을 증가시킬 수 있다. 아쿠아포닉스 시스템은 어류 양식과 수경재배 시스템을 결합한 순환형 시스템으로 두 종류의 재배 시스템이 연결되어 있어 정밀한 관리를 필요로 한다. 이러한 관리에는 작물과 어류 생장에 직접적으로 영향을 미치는 EC 값을 조절하기 위한 순환수제어가 포함된다. 본 논문에서는 아쿠아포닉스 시스템의 재배부와 양어부에 설치된 센서의 EC 데이터를 Long-Short Term memory(LSTM)계열 모델인 LSTM, Convolution neural network(CNN)+LSTM, convolutional LSTM(convLSTM) 모델의 학습 데이터로 사용해 EC 값을 예측하고 순환수제어에 적합한 모델을 선정한다. 실험에 사용된 모델의 평가지표는 Mean Square Error(MSE)를 활용하며 최적 모델의 예측 EC 값을 기반으로 순환수 제어 및 아쿠아포닉스 시스템의 이상을 탐지할 수 있는 알고리즘을 설계한다. 본 논문에서 구현된 알고리즘과 환경 데이터 수집 시스템을 접목하면 최적의 생산량을 위한 필요 양분의 체계적인 관리 및 순환수제어에 관련된 인자를 조절할 수 있다.

Key Words : Aquaponics, Artificial intelligence, LSTM, Hydronic control

ABSTRACT

The aquaponics system is system that integrates hydroponics and aquaculture. it reuses the water used for aquaculture to reduce the amount of water and chemical fertilizer used in agriculture and increase productivity. The aquaponics system is a circular system that combines fish farming and hydroponic systems, and requires precise management because the two types of cultivation systems are connected. The management requires circulating water control to control EC values, which directly affect crop and fish growth. In this paper, EC data from sensors installed in the cultivation section and aquaculture section are used as training data for Long-Short-

※ 본 연구는 농촌진흥청 연구사업(과제번호: PJ015796032023)의 지원으로 수행되었습니다.

• First Author : Division of Smart Farm Development, Department of Agricultural Engineering, National Institute of Agricultural Sciences, ljh09150915@korea.kr, 정회원

° Corresponding Author : Division of Smart Farm Development, Department of Agricultural Engineering, National Institute of Agricultural Sciences, butterfly@korea.kr, 정회원

* Division of Smart Farm Development, Department of Agricultural Engineering, National Institute of Agricultural Sciences, dhtjr9596@gmail.com, 학생회원

논문번호 : 202309-087-C-RE, Received September 21, 2023; Revised November 3, 2023; Accepted November 7, 2023

term memory(LSTM), Convolution Neural Network(CNN)+LSTM, and Convolutional LSTM(convLSTM) models to predict EC values and select a model suitable for circulating water control. The evaluation index of the model in experiment use Mean Square Error(MSE), and based on the predicted EC value of optimal model, an algorithm that can control circulation water is designed. By combining the algorithm implemented in this paper with the environmental data collection system, it is possible to systematically manage nutrients required for optimal production and adjust factors related to circulation water control.

I. 서 론

농촌인구의 고령화가 진행되는 과정에 온난화와 기상이변 등 심각한 기후변화가 겹쳐 기존 관행 농업의 한계가 드러나고 있다. 이와 더불어 COVID-19 사태로 인해 농식품 시장에서의 안전한 먹거리에 관한 관심이 증가함에 따라 두 문제에 대한 해법이 될 수 있는 스마트팜 기술이 주목받고 있다^[1,2]. 스마트팜 기술이란 빅데이터, ICT와 같은 기술을 농업에 적용한 기술을 의미하며^[1,3], 근래에는 인공지능 기술을 접목하는 연구가 활발하게 진행되고 있다.

스마트팜의 한 종류인 아쿠아포닉스(Aquaponics)는 어류 양식과 수경재배 시스템을 결합한 순환형 시스템으로 어류 양식에서 발생하는 배설물이 섞인 물을 수경재배에 재활용하고 식물이 성장하는 과정에서 정화된 물을 다시 어류 양식에 사용하는 농법이다. 어류의 배설물에 포함된 질소 성분을 작물 재배에 이용하여 화학비료의 사용을 줄일 수 있어 친환경 농법이라 할 수 있으며 소비자가 작물의 생산 과정에 대한 안전성을 확신하게 할 수 있다^[4,5].

아쿠아포닉스 시스템은 수경재배와 어류 양식이 연결된 시스템이기 때문에 여러 분야에서 연구가 진행되고 있다. 관련된 연구에는 유용 미생물을 사용해 양식용수의 수질 정화하는 바이오플락(Bio-floc) 기술을 적용한 순환수 관리^[6,7], 토양 및 수분 센서, 아두이노, 라즈베리파이 및 자동 급이기와 IoT 기술을 적용해 작물과 물고기의 생육환경 제어^[8], 클라우드 플랫폼에 영상처리를 위한 인스턴스 데이터베이스와 웹 서버 인스턴스를 구성해 아쿠아포닉스 시스템의 양어부와 재배부의 데이터 수집 및 실시간 모니터링 시스템 구축^[9], 다중 임계치 오프(Otsu threshold) 알고리즘을 통한 식물영역 분할 기반 작물 생장 모니터링^[10] 등 다양한 기술을 적용하는 연구가 진행되고 있다. 이러한 연구는 아쿠아포닉스 시스템에 적용되어 전체 시스템의 보조적인 역할을 수행할 수 있으나 어류 양식과 기존의 수경재배 시스템을 결합한 순환형 시스템의 특성을 살릴 수 있는 물의 재활용을 극대화하기 위한 순환수제어에 관한 연

구가 부족한 실정이다.

최근 인공지능 기술이 범용적으로 사용할 수 있게 됨에 따라 관련 기술이 스마트팜에 다양하게 적용되고 있다. 스마트팜에 적용되는 인공지능 기술에는 작물 생육 데이터와 인공지능을 사용해 작물 생산량 예측 모델을 구성하는 연구가 활발하게 진행되고 있다. 특히 기존 인공지능의 순환신경망이 가지는 데이터의 길이가 매우 긴 경우 과거의 정보를 학습하기 어려움을 해결해 농업 데이터와 같은 장시간의 데이터에 적용할 수 있는 Long Short-term memory(LSTM)^[11] 계열의 모델을 적용한 연구가 진행되고 있다^[12].

아쿠아포닉스 시스템에서 수경재배와 어류 양식이 제대로 이루어지기 위해서는 작물과 어류가 성장하는데 필요한 Electrical conductivity(EC) 값을 유지하는 것이 중요하다. 아쿠아포닉스 시스템의 순환수의 EC 값을 적절하게 제어하지 못하면 작물의 경우 영양 결핍, 염분 스트레스로 인한 성장 저하, 어류의 경우 스트레스로 인한 면역력 저하가 발생할 수 있다^[13-15]. 재배부의 EC는 상대적으로 높아야 하며 양어부의 EC는 상대적으로 낮아야 한다. 하지만 순환수제어 알고리즘이 없는 경우 재배부의 EC는 지속적으로 감소하며 양어부의 EC는 지속적으로 증가하여 정상적으로 생육이 되지 않거나 직수로 두 시스템이 연결되어 순환수의 EC 자체 관리가 되지 않는 경우가 발생한다. 이러한 이유로 아쿠아포닉스 시스템의 순환수제어는 어류 양식이 진행되는 양어부와 수경재배가 진행되는 재배부 간의 EC 데이터를 기반으로 공급을 제어하는 방식이 필요하다.

따라서 본 논문에서는 생산량 예측 모델과 같이 과거의 데이터를 기반으로 미래의 값을 예측하는 LSTM 계열 모델인 LSTM, Convolution Neural Network(CNN)+LSTM^[16], convolutional LSTM(convLSTM)^[17] 모델에 양어부, 재배부 EC 데이터를 학습 데이터로 사용해 EC 값을 예측한다. 예측 EC 값은 MSE를 평가 지표로 비교하여 최적의 모델을 선정하고 해당 모델의 예측 EC 값의 차이를 기반으로 재배하는 작물이나 양식하는 어류에 맞춰 순환수 공급 지점을 알려주는 순환수 모터 제어 알고리즘을 구현한다.

이 논문의 구성은 다음과 같다. 제 II장에서는 데이터 수집 및 전처리에 대한 설명, III장 EC 값 예측에 사용되는 모델에 대한 기본적인 정보를 기술하고 제 IV장에서는 모델 학습에 대한 실험 방법 및 결과에 대한 분석을 수행한다. 마지막으로 V장에는 연구에 대한 결론과 차후 연구에 대해 논의한다.

II. 데이터 수집 및 전처리

본 연구에서는 국립농업과학원 농업공학부에 위치한 아쿠아포닉스 시스템의 양어부, 재배부에 설치된 EC 센서 데이터를 사용하였다. EC는 온도에 영향을 받는 인자이지만 센서가 설치된 아쿠아포닉스 시스템은 온도 및 습도가 관리되는 수직형 농장에서 가동되고 있으므로 고려하지 않았다. 아쿠아포닉스 시스템에서 수집된 EC 센서 데이터는 데이터 수집 목적으로 클라우드 컴퓨팅 서버에 자동으로 저장되며 본 실험에서는 2022년 12월 1일부터 2022년 12월 31일까지의 EC 데이터를 사용하였다. 클라우드 컴퓨팅 서버에 저장된 데이터는 15초 단위로 EC 센서값을 저장하고 있으며 결측치와 이상치로 인한 오차를 보완하기 위해 1시간 단위 평균을 하나의 단위값으로 변경 후 MinMaxscaler를 통해 정규화를 진행하였다. 정규화가 완료된 데이터는 20개의 시간 간격을 하나의 시퀀스로 하는 LSTM 계열 모델의 입력형식에 적합한 데이터로 변형하였다. 완성된 데이터는 이미지를 사용하는 CNN과는 다르게 LSTM 계열 모델의 학습에 적합하게 무작위 재배치 작업을 수행하지 않고 시간 단위에서 8:2 비율로 나누고 데이터 수집 기간의 전반부에 해당하는 데이터는 학습, 데이터 수집 기간의 후반부에 해당하는 부분은 검증에 사용하였으며 본 논문에서는 미세조정과 같은 하이퍼 파라미터 조절을 하지 않고 실험에 사용할 모델을 선별하기 위해서 검증 데이터를 테스트 데이터로 사용하였다.




그림 1. 재배부 EC 그래프
Fig. 1. Cultivation section EC graph




그림 2. 양어부 EC 그래프
Fig. 2. Aquaculture section EC graph

Fig. 1, Fig. 2는 각각 학습에 사용된 재배부 EC 데이터와 양어부 EC 데이터의 그래프를 나타내고 있다. 그래프를 통해서 학습에 사용된 재배부 EC 데이터의 경우 변화의 정도가 둔감하지만 양어부 EC 데이터의 경우 재배부 EC 데이터 대비 변화의 정도가 심하며 변화하는 양 또한 재배부 EC 데이터보다 크다는 것을 확인할 수 있다.

III. 학습 모델

실험에는 LSTM, CNN+LSTM, convLSTM 모델을 적용하였다. LSTM 모델은 순환신경망(Recurrent neural network, RNN)이 가지는 문제점인 필요한 정보와 해당 정보를 사용하는 시점 사이의 거리가 멀어질 때 발생하는 기울기 소멸 문제(Gradient vanishing problem)를 해결하기 위한 네트워크 모델이다. cell state에 과거 정보에 대한 전달 정도를 판단하는 forget gate, 현재 정보에 대한 전달 정도를 판단하는 input gate, 최종 출력값을 판단하는 output gate를 도입하여 어느 시점에서 정보를 버리거나 유지하여 선택적으로 흘러갈 수 있게 하였다. CNN+LSTM 모델은 먼저 합성곱 층을 사용해 일차적으로 특징을 추출하고 추출된 데이터를 LSTM 층의 입력으로 사용하는 모델로 cell

Layer (type)	Output Shape
lstm (LSTM)	(None, 20, 64)
lstm_1 (LSTM)	(None, 32)
dense (Dense)	(None, 1)
Total params: 29,345	
Trainable params: 29,345	
Non-trainable params: 0	

그림 3. LSTM 모델 구조
Fig. 3. Architecture of LSTM model

Layer (type)	Output Shape
time_distributed (TimeDistributed)	(None, 2, 10, 64)
time_distributed_1 (TimeDistributed)	(None, 2, 5, 64)
time_distributed_2 (TimeDistributed)	(None, 2, 320)
lstm_2 (LSTM)	(None, 32)
dense_2 (Dense)	(None, 1)

=====
 Total params: 45,345
 Trainable params: 45,345
 Non-trainable params: 0

그림 4. CNN+LSTM 모델 구조

Fig. 4. Architecture of CNN+LSTM model

Layer (type)	Output Shape
conv_lstm1d (ConvLSTM1D)	(None, 1, 20, 64)
conv_lstm1d_1 (ConvLSTM1D)	(None, 20, 32)
flatten (Flatten)	(None, 640)
dense_1 (Dense)	(None, 1)

=====
 Total params: 29,953
 Trainable params: 29,953
 Non-trainable params: 0

그림 5. convLSTM 모델 구조

Fig. 5. Architecture of convLSTM model

state 정보를 은닉층에 전달할 수 있는 모델이다. convLSTM 모델은 CNN+LSTM 모델의 합성곱 층에서 특징을 추출하는 과정 도중에 공간적인 특성을 반영하지 못하는 단점을 보완한 모델로 현재 정보와 은닉층 정보 사이에 원소 곱이 아닌 합성곱을 수행하는 것이 특징이다. Fig. 3, Fig. 4, Fig. 5는 각각 실험에 사용된 LSTM, CNN+LSTM, convLSTM 모델의 네트워크 구조를 보여주고 있다.

IV. 실험

4.1 실험 방법

본 연구는 전처리된 재배부, 양어부의 EC 데이터를 학습 데이터로 사용해서 지정한 시간 뒤 각각의 EC 값을 예측하도록 모델을 학습시켰다. 학습은 Apple silicon M1 MAX 프로세서를 기반으로 언어, 프레임워크, 라이브러리는 파이썬(Python) 3.8, 텐서플로

(Tensorflow) 2.10를 사용하였다. 하이퍼 파라미터인 학습률은 0.001, 옵티마이저는 Adam, 오차함수는 Mean Squared Error(MSE)로 설정한 상태에서 100회 반복해서 학습을 진행하였다. 학습을 진행하는 과정에 검증 오차를 기준으로 하는 early stopping 옵션을 추가하여 모델이 과적합 되는 것을 방지하였으며 반복이 완료된 시점에서 모델의 파라미터를 저장하도록 설정하였다. 실험에 사용된 3가지 모델 성능은 인공지능 평가 지표 중 하나인 MSE값을 사용하여 비교 실험하였다. 구현된 아쿠아포닉스 시스템의 순환수제어 알고리즘은 MSE값을 기반으로 선정된 최적의 모델의 예측값을 사용하였다. 최적의 성장 환경을 유지하기 위해 재배부와 양어부의 EC 값을 예측하고 EC 값의 차이가 유의미하지 않게 되는 경우를 순환수제어 모터를 가동 시점으로 알려주는 알고리즘을 구현하였다.

4.2 실험 결과

Fig. 6, Fig. 7, Fig. 8은 각각 LSTM, CNN+LSTM model, convLSTM의 학습 과정에 대한 정보를 그래프로 나타내고 있다. 그래프를 통해서 학습에 사용된 3가지 모델 모두 재배부와 양어부 EC를 과적합 없이 학습이 진행되었음을 확인할 수 있다.




그림 6. LSTM 모델의 학습 결과

Fig. 6. Training result of LSTM model




그림 7. CNN+LSTM 모델의 학습 결과

Fig. 7. Training result of CNN+LSTM model




그림 8. convLSTM 모델의 학습 결과
Fig. 8. Training result of convLSTM model

Table 1.과 Table 2.는 각각 재배부와 양어부의 학습을 통해 얻은 최적 모델에 대한 학습 오차, 검증 오차, MSE 값을 나타내고 있다. 재배부의 경우 LSTM 모델이 가장 좋은 결과값을 얻었으며 양어부의 경우 convLSTM 모델이 가장 좋은 결과값을 얻었다. 두 표의 지표를 비교해보면 전체적으로 양어부에서 얻은 수치가 재배부에서 얻은 수치 대비 저조함을 알 수 있다.

이러한 결과가 발생하는 이유는 Fig. 9의 재배부와 양어부 EC 데이터 샘플 그래프를 통해서 알 수 있다. 학습에 사용된 재배부 EC 데이터의 경우 각 시간 간격 사이에 변화가 없는 부분이 많고 변화량 자체가 적지만 양어부 EC 데이터의 경우 양식되고 있는 어류의 움직임에 영향을 받아 각 시간 간격 사이에 변화도 자주 일어나며 변화량 자체도 많음을 확인할 수 있다.

Fig. 10과 Fig. 11은 실험에 사용한 3가지 모델의 예측 결과와 검증 데이터를 하나의 그래프로 표시하고 있다. 검증 데이터는 파란색 굵은 선으로 표시되어 있으며 해당 그래프를 통해 이전 표와 데이터 샘플에서 확인

표 1. 재배부 결과
Table 1. Result of cultivation section

	Training loss	Validation loss	MSE
LSTM	0.00089	0.00131	0.00021
CNN+LSTM	0.00105	0.00047	0.18463
convLSTM	0.00169	0.00113	0.00035

표 2. 양어부 결과
Table 2. Result of aquaculture section

	Training loss	Validation loss	MSE
LSTM	0.01584	0.01257	0.00191
CNN+LSTM	0.01671	0.01198	0.00395
convLSTM	0.01538	0.01221	0.00153

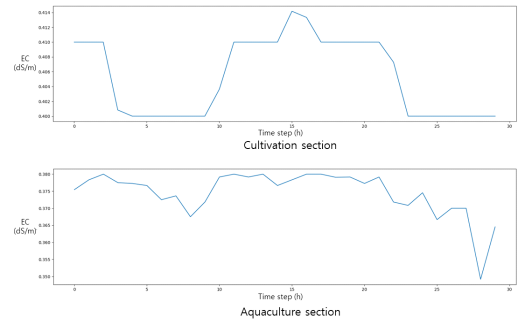


그림 9. 재배부, 양어부 EC 데이터 샘플
Fig. 9. Cultivation section and aquaculture section EC data sample

했던 재배부 EC 데이터를 학습한 모델들의 결과가 양어부 EC 데이터를 학습한 모델들의 결과보다 우수하다는 점을 확인할 수 있다. 하지만 상대적으로 차이가 크게 나는 양어부 EC 예측값 역시 검증 데이터와의 차이가 작으며 전반적으로 EC 데이터의 경향을 따라가는 성질을 보여주기 때문에 순환수치어 알고리즘을 위한 EC 예측값으로 적용할 수 있을 것으로 판단된다.




그림 10. 재배부 EC 예측 결과 그래프
Fig. 10. Result of cultivation section EC prediction graph




그림 11. 양어부 EC 예측 결과 그래프
Fig. 11. Result of aquaculture section EC prediction graph

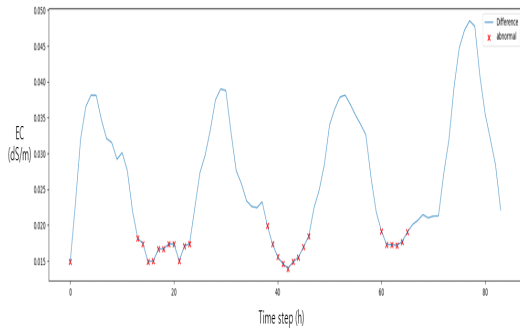


그림 12. 순환수 제어 알고리즘 결과
Fig. 12. Result of hydronic control algorithm

실험을 통해서 얻은 최적 모델이 예측한 재배부와 양어부의 EC 값 차이를 그래프로 표현하고 두 EC 값 사이의 차이가 일정 이하로 떨어지는 경우 Fig. 12와 같이 붉은색 엑스마크로 표시하여 순환수제어를 위한 모터 구동 시점을 사용자에게 알리고 재배부와 양어부 사이의 물을 순환 시킬 수 있도록 구현하였다.

V. 결 론

본 논문에서는 아쿠아포닉스 시스템의 클라우드 컴퓨팅 서버에서 얻은 재배부와 양어부의 EC 데이터와 LSTM 계열의 모델을 사용해서 아쿠아포닉스 시스템 내 순환수제어 알고리즘을 구현하였다. 순환수제어를 위한 모터의 구동 시점을 추정하기 위해서 재배부와 양어부의 EC 값 예측에 적합한 최적의 모델이 필요하고 적합한 모델을 찾기 위해 각각의 EC 데이터를 전처리한 후 시퀀스 형식으로 변환해서 LSTM, CNN+LSTM, convLSTM을 학습시키고 MSE 값으로 성능을 비교하였다. 그 결과 재배부 EC 데이터의 경우 LSTM 모델이 학습 오차 0.00089, 검증 오차 0.00131, MSE 0.00021로 가장 좋은 결과를 얻었으며 양어부 EC 데이터의 경우 convLSTM 모델이 학습 오차 0.01538, 검증 오차 0.01221, MSE 0.00153으로 가장 최적의 결과를 얻었다. 실험에 사용한 모델 중 최적의 결과를 나타낸 두 모델의 예측값 차이를 기반으로 아쿠아포닉스 시스템 순환수제어 알고리즘을 구현하였다. 구현된 알고리즘은 재배부와 양어부의 예측 EC 값 차이를 작물 생장과 어류 양식에 맞춰 적절하게 유지할 수 있도록 설정된 임계치 이하가 되면 표시하는 방식으로 구현하였다.

추후 구현된 알고리즘은 학습 데이터를 추가해 양어부 EC 데이터에 대한 결과값을 재배부 EC 데이터 정도 수준을 달성하도록 하는 과정과 하이퍼 파라미터를 미세조정 하는 과정이 필요하다. 추가로, 일반적인 아쿠아

포닉스 시스템의 경우 본 연구에서 실험한 수직형 농장 환경과는 다르게 온도가 일정하지 못해 EC 데이터가 영향을 받을 수 있는 부분을 다중 입력 단일 출력 형태의 LSTM 모델을 적용해볼 필요가 있다. 또한 아쿠아포닉스 시스템에 솔레노이드 밸브, 순환수펌프, IoT 시스템을 결합해 순환수제어 알고리즘을 검증해보는 실험이 필요하다.

References

- [1] S. H. Lee, Y. S. Park, and O. S. Kwon, "Constructing a tomato smart farm optimization model with estimated growth functions," *J. The Korean Data & Information Sci. Soc.*, vol. 31, no. 4, pp. 619-635, 2020. (<https://dx.doi.org/10.7465/jkdi.2020.31.4.619>)
- [2] S. H. Kim, Y. A. Hong, S. Y. Huh, and J. H. Ji, "Analysis of the influence of agricultural and food consumption on the spread of corona virus 19," Retrieved Jun. 23, 2023, from <http://www.krei.re.kr>
- [3] Y. J. Kim, J. Y. Park, and Y. G. Park, "An analysis of the current status and success factors of smart farms," Korea Rural Econ. Inst. Report, pp. 1-74, 2016.
- [4] G. Y. Jung, "Current status and R&D implications of aquaponics technology," Retrieved Jun. 23, 2023, from <http://www.ipet.re.kr>
- [5] H. S. Lee and J. D. Kim, "A design of growth measurement system considering the cultivation environment of aquaponics," *J. The KIICE*, vol. 27, no. 1, pp. 27-33, Jan. 2023. (<http://dio.org/10.6109/jkiice.2023.27.1.27>)
- [6] S. R. Kim, J. W. Jang, B. J. Kim, I. K. Jang, H. J. Lim, and S. K. Kim, "Urban aquaculture of catfish, *Silurus asotus*, using biofloc and aquaponics systems," *Environ. Organisms*, vol. 37, no. 4, pp. 545-553, Nov. 2019.
- [7] A. K. Buhmann, U. Waller, B. Wecker, and J. Papenbrock, "Optimization of culturing conditions and selection of species for the use of halophytes as biofilter for nutrient-rich saline water," *Agric. Water Manage.*, vol. 149, pp. 102-114, Feb. 2015.

- [8] G. H. Kim and D. W. Han, "Exploratory research : Home aquaponics of tropical fish using IoT," *J. The Korea Contents Soc.*, vol. 21, no. 4, pp. 424-433, Apr. 2021.
- [9] O. S. Yang, H. R. Lee, J. W. Heo, J. S. Lee, T. H. Kim, H. J. Kim, D. H. Im, and J. H. Baek, "Design and implementation of aquaponics monitoring system in cloud-computing," *J. KICS*, vol. 46, no. 11, pp. 2100-2107, Nov. 2021.
- [10] J. H. Kim and G. Y. Heo, "Automatic determination of plant growth level through multilevel threshold image segmentation," *J. KIICE*, vol. 27, no. 4, pp. 511-516, Apr. 2023.
- [11] S. Hochreiter and J. Schmidhuber, "Long short-term memory," *Neural Computation*, vol. 9, no. 8, pp. 1735-1780, 1997.
- [12] S. Y. Lee, H. J. Yang, M. Y. Kim, J. Y. Kim, and A. Y. Son, "A study on prediction of tomato production using BI-LSTM for smart farm utilization," *J. KICS*, vol. 27, no. 04, Apr. 2023.
- [13] Sam E. Wortman, "Crop physiological response to nutrient solution electrical conductivity and pH in an ebb-and-flow hydroponic system," *Scientia Horticulturae*, vol. 194, pp. 34-42, Aug. 2015.
- [14] X. Ding, Y. Jiang, H. Zhao, D. Guo, L. He, F. Liu, Q. Zhou, D. Nandwani, D. Hui, and J. Yu, "Electrical conductivity of nutrient solution influenced photosynthesis, quality, and antioxidant enzyme activity of pakchoi (*Brassica campestris* L. ssp. *Chinensis*) in a hydroponic system," *PLoS One*, vol. 13, no. 8, Aug. 2018.
- [15] L. Tort, "Stress and immune modulation in fish," *Developmental and comparative immunology*, vol. 35, no. 12, pp. 1366-1375, Dec. 2011.
- [16] T. N. Sainath, et al., "Convolutional, long short-term memory, fully connected deep neural network," *IEEE ICASSP*, pp. 4580-4584, 2015.
- [17] D.-Y. Yeoun, et al., "Convolutional LSTM network: A machine learning approach for

precipitation nowcasting," *Advances in NIPS*, pp. 802-810, 2015.

이 정 호 (Jeong-Ho Lee)



2015년 2월 : 성균관대학교 생명공학과 석사
2022년 8월 : 성균관대학교 바이오메카트로닉스 박사
2022년 9월~현재 : 농촌진흥청 국립농업과학원 전문연구원
<관심분야> 영상처리, 인공지능, 스마트팜

[ORCID:0009-0003-4088-7064]

백 정 현 (Jeong-Hyun Baek)



2016년 2월 : 군산대학교 컴퓨터정보공학 박사
2020년 1월 : 농촌진흥청 국립농업과학원 전문연구원
2020년 2월~현재 : 농촌진흥청 국립농업과학원 농업연구사
<관심분야> 스마트팜, 클라우드 컴퓨팅, 데이터분석

[ORCID:0000-0002-5867-2171]

양 오 석 (Oh-Seok Yang)



2018년 2월 : 군산대학교 컴퓨터정보공학과 졸업
2021년 2월 : 군산대학교 컴퓨터정보공학과 석사
2021년 3월~현재 : 군산대학교 컴퓨터정보공학과 박사과정
<관심분야> 객체지향시스템, 빅데이터, 스마트팜

[ORCID:0000-0001-5016-6146]