



## 저작자표시-비영리-변경금지 2.0 대한민국

이용자는 아래의 조건을 따르는 경우에 한하여 자유롭게

- 이 저작물을 복제, 배포, 전송, 전시, 공연 및 방송할 수 있습니다.

다음과 같은 조건을 따라야 합니다:



저작자표시. 귀하는 원저작자를 표시하여야 합니다.



비영리. 귀하는 이 저작물을 영리 목적으로 이용할 수 없습니다.



변경금지. 귀하는 이 저작물을 개작, 변형 또는 가공할 수 없습니다.

- 귀하는, 이 저작물의 재이용이나 배포의 경우, 이 저작물에 적용된 이용허락조건을 명확하게 나타내어야 합니다.
- 저작권자로부터 별도의 허가를 받으면 이러한 조건들은 적용되지 않습니다.

저작권법에 따른 이용자의 권리는 위의 내용에 의하여 영향을 받지 않습니다.

이것은 [이용허락규약\(Legal Code\)](#)을 이해하기 쉽게 요약한 것입니다.

[Disclaimer](#)

전문기관의 원/달러 환율예측력 분석 :  
시계열 모형 및 기계학습 LSTM 모형과의 비교연구



서강대학교 경제대학원

정보기술경제전공

황 승 환

전문기관의 원/달러 환율예측력 분석 :  
시계열 모형 및 기계학습 LSTM 모형과의 비교연구

지도교수 이 한 식

이 논문을 경제학석사 학위논문으로 제출함

2020년 6 월 17 일

서강대학교 경제대학원

정보기술경제전공

황 승 환



## 논문인준서

황승환 의 경제학 석사 학위논문을 인준함.

2020년 6 월 17 일

주심 강재식

부심 이강호

부심 이한식



## 감사의 글

부족한 실력으로 논문을 완성하기까지 도와주시고 배려해주신 모든 분들께 감사드리며 부족하지만 제 논문을 마무리할 수 있게 되어 매우 기쁘고 감사한 마음입니다.

2년 6개월간의 석사 과정 동안 경제학에 대해 많은 가르침을 주신 교수님들께 감사드립니다. 특히 안식년에 특별히 시간을 내주셔서 많은 조언들과 함께 학문적 가르침을 주신 이한식 교수님께 깊이 감사드리며 본 논문의 심사과정에서 부족한 부분에 대해 가르침을 주시고 완성도를 높일 수 있게 도와주신 존경하는 정재식 교수님 그리고 이강오 교수님께도 깊이 감사드립니다.

대학원 생활에서 55기 원우회장직을 수행하는 동안 부족한 저를 많이 도와주신 53기 최창선 회장님, 든든한 오른팔 변진석 총무님, 부동산경제 황경갑 회장님 그리고 작은 일부터 큰일까지 많은 힘이 되어주었던 전영우 왕회장님, 양범술 연구간사님, 김정원 원우님, 신지영 부회장님, 서영현 감사님, 노준영 부회장님 등 격하게 아끼는 경제대학원 선후배 및 동기분들에게 깊이 감사드립니다. 특히 LSTM 알고리즘에 대해 많은 도움을 주신 정보통신대학원 주정현 원우님과 경제학 논문에 대해 많은 조언을 아끼지 않으신 황선희 박사님께도 진심으로 감사드립니다.

마지막으로 늦은 밤까지 공부하는 남편을 위해 많은 배려와 응원을 해준 사랑하는 내 반쪽 승현이에게 감사의 인사 이상의 깊은 사랑과 고마움을 함께 전합니다. 항상 우리를 아껴주시고 사랑해주시는 존경하는 김명숙 여사님, 아빠가 숙제가 많아서 힘들겠다고 걱정하며 무엇보다 함께 많이 놀고 싶었을텐데 잘 이해해준 첫째 황서혁, 고집은 엄청나지만 건강하게 웃어주는 모습만으로도 모든 것이 용서가 되는 세상에서 가장 사랑스럽고 이쁜 우리 둘째 황시현, 그리고 곧 11월에 만나게 될 아름다운 공주님 셋째 복동이까지 아빠가 너무 사랑한다고 꼭 전하고 싶습니다. 그리고 언제나 보이지 않은 곳에서 보살피 주시며 사랑으로 인도해주시는 주님과 짧은 지면의 한계로 혹시나 언급 드리지 못한 모든 분들께 진심으로 감사의 말씀을 전하며 감사의 글의 끝을 맺고자 합니다.

2020년 7월의 어느 화창하고 아름다운 날  
황 승 환 올림



## 목 차

제 1장 서론 .....	1
제 1절 연구의 검토 .....	1
제 2절 선행연구의 검토 .....	2
1. 전문기관의 예측치를 이용한 환율 예측 연구 .....	3
2. 구조적 모형 및 시계열 모형을 이용한 환율 예측 연구 .....	3
3. 인공지능 모형을 이용한 환율 및 지수 예측 연구 .....	4
제 3절 논문의 구성 .....	6
제 2장 연구방법 .....	6
제 1절 연구의 모형 .....	6
제 2절 연구자료의 특징 .....	7
제 3절 평가방법과 예측모형 .....	12
1. 예측 및 비교방법 .....	12
(1) 예측방법 .....	12
1) 시계열 모형 .....	12
2) 기계학습 모형 .....	13
(2) 비교방법 .....	13
1) 평균 제곱근 오차(RMSE) .....	13
2) 평균 절대 오차(MAE) .....	14
2. 시계열 모형 .....	14
(1) 임의보행(Random walk)모형 .....	14
(2) 자기회귀누적이동평균(ARIMA) 모형 .....	15



(3) 차수의 선정 .....	16
(4) 예측값 비교 및 선정 .....	17
3. 기계학습 모형 .....	18
(1) 기계학습 .....	18
(2) 인공신경망 .....	18
1) 순환신경망(RNN) .....	20
2) 장단기메모리(LSTM) .....	21
(3) 모형의 설계 .....	23
(4) 예측값 비교 및 선정 .....	24
<b>제 3장 실증분석 .....</b>	<b>24</b>
제 1절 실증분석 결과 .....	24
1. 예측 정확성 비교분석 .....	24
(1) 모형별 예측력 분석 .....	24
(2) 기간별 예측력 분석 .....	26
2. 구간이동(Rolling Sample)분석 .....	30
<b>제 4장 결론 .....</b>	<b>32</b>
참고 문헌 .....	34
Abstract .....	36



## 표 목차

[표 2-1] 기간별 원/달러 환율의 기초통계량 .....	9
[표 2-2] ADF 단위근 검정 .....	12
[표 2-3] ARIMA 모형의 최적차수 결정 .....	16
[표 2-4] 구간이동방식을 통한 예측방법(예시) .....	17
[표 2-5] 구간이동방식을 이용한 시계열 모형의 예측 결과 .....	18
[표 2-6] 파라미터 목록 및 선정값 .....	24
[표 2-7] LSTM 모형의 예측 결과 .....	24
[표 3-1] 전체 예측기간 예측력 비교 .....	25
[표 3-2] 예측기간 I 의 예측정확도 비교 .....	27
[표 3-3] 예측기간 II 의 예측정확도 비교 .....	27





## 그림 목차

[그림 2-1] 연구모형 .....	6
[그림 2-2] 전문기관 환율 일일전망 사례(20.3.31) .....	8
[그림 2-3] 예측기간 원/달러 환율 추이 (19.1.22~20.3.31) .....	8
[그림 2-4] 예측기간 원/달러 환율 변동 추이 (19.1.22~20.3.31) .....	10
[그림 2-5] 일별 원/달러 환율 원시계열 그래프 (14.4.1~20.3.31) .....	10
[그림 2-6] 인공신경망(ANN) 구성도 .....	19
[그림 2-7] 인공신경망(ANN) 수식도 .....	20
[그림 2-8] 순환신경망(RNN: Recurrent Neural Network) .....	21
[그림 2-9] 표준 RNN과 LSTM 알고리즘 비교 .....	22
[그림 3-1] 전문기관과 ARIMA의 예측 편차 비교 .....	25
[그림 3-2] 전문기관과 LSTM의 예측 편차 비교 .....	25
[그림 3-3] 예측모형의 예측 편차 범위 비교 .....	26
[그림 3-4] 예측기간 I 각 모형별 예측력 비교 .....	28
[그림 3-5] 예측기간 I 각 모형의 예측력 편차 비교 .....	29
[그림 3-6] 예측기간 I 각 모형의 예측값 편차 범위 비교 .....	29
[그림 3-7] RMSE 20일 구간이동분석 분석 .....	31



## 전문기관의 원/달러 환율예측력 분석 : 시계열 모형 및 기계학습 LSTM 모형과의 비교연구

환율은 대외의존도가 높은 한국경제에 중요한 요소이다. 특히 글로벌 경기의 방향성을 좌우하는 달러의 가치에 대한 원화 가치의 변동에 더 많은 관심이 필요하다. 이에 따라 원/달러 환율의 변동을 예측하기 위해 다양한 계량·통계 분석을 토대로 많은 연구가 진행되었다.

이러한 관점에서 본고는 환율의 시계열 자료만을 활용하는 일변량 모형(ARIMA 및 LSTM)의 예측데이터와 전문기관의 예측데이터를 체계적으로 비교/분석하여 환율예측에 대한 각 모형의 활용 가능성을 확인하였다.

실증분석 결과 전문기관의 예측치는 비교적 환율의 변동성이 크지 않는 예측기간 I에서 우수한 결과를 보여주었으며, 특히 RMSE를 20일 단위로 구간 추정(rolling estimation)한 분석에서 시계열 추세의 변화에 따라 불안정한 예측력을 보여준 일변량 모형(ARIMA 및 LSTM)들과는 달리 시계열의 변동성이 커지는 기간에도 그 추세를 추종하지 않고 안정적인 예측력을 보여주었다.

결론적으로 전문기관 예측치는 COVID-19와 같은 영향으로 급격한 변화가 있는 시기를 제외하고는 비교적 안정적인 예측력을 보여준다는 것을 확인하였으며 최근 시계열 데이터를 활용한 예측에서 좋은 성과를 보이는 LSTM 모형이나 전통적인 ARIMA 모형을 활용하더라도 일변량 데이터만으로 변동성이 큰 금융 시계열을 예측하려는 시도는 무의미하다는 것을 확인하였다.

주제어 : 일별 환율, 예측평가, 시계열분석, 기계학습, 자기회귀누적이동평균, 장단기기억



## 제 1 장 서 론

### 제 1 절 연구의 검토

우리나라는 97년 12월 말 외환위기와 IMF의 정책적 권고에 따라 원화의 일일 변동폭을 일정 수준으로 제한하는 시장평균환율제<sup>1)</sup>를 전면 폐지하고 자유변동환율제를 시행하였다. 이와 같은 자유변동환율제는 외환시장의 시장기능이 활성화되는 장점은 있지만 급격한 환율의 변동으로 내수시장이 크지 않고 대외의존도가 높은 한국경제가 충격을 받을 수 있다는 단점도 있다. 이렇게 환율이 경제에 미치는 영향력이 증대되자 다양한 필요에 따라 환율을 예측하고자 하는 시도가 증가하였고 최근에는 구조적 모형과 시계열 모형을 넘어서 인공지능 모형을 통한 예측 연구도 활발하게 진행되고 있다.

하지만 시간의 변화에 따라 환율에 영향을 주는 변수들을 예상하여 적용하기 어렵기 때문에 환율을 예측한다는 것은 매우 어려운 일이다. 대표적인 환율예측 연구<sup>2)</sup>에 따르면 환율예측에 있어서 임의보행(Random Walk)모형을 능가하는 다른 모형을 제시하는 것이 상당히 어려우며 환율에 대한 가장 높은 예측력은 현재의 환율이 가지고 있다고 말하고 있다. 그렇지만 환율을 예측하기 위한 예측기법들은 다양한 분야에서 지속적으로 연구되고 있으며 국내외 기업들과 금융기관들은 환율 변동성에 대한 위험을 최소화하고 환차익을 극대화하기 위해서 달러화에 대한 신뢰성이 높은 예측치를 얻기 위해 노력하고 있다.

19년 4월 12일 자 공공기관 경영정보공개시스템 일반현황 보고서에 따르면 한국 무역보험공사는 “무역이나 그 밖의 거래와 관련한 위험을 담보하기 위해 설립된 무역투자보험기관이며 환변동위험 관리 등 기타 대외거래에서 발생하는 위험을 담보하기 위한 다양한 무역보험 종목을 운영하는 기관이다.” 라고 정의하고 있으며 특히 환율전망과 관련해서는 공사의 홈페이지와 카카오톡 플랫폼을 이용하여 Ksure 환위험관리 서비스를 제공하고 있는 영향력 있는 전문기관이다. 환율전망은 영업일 오전 9:00시 전 금일 원/달러 환율의 전망과 예상범위 등을 포함한 일일리포트<sup>3)</sup>

- 1) 우리나라는 1990년 3월 복수통화 바스켓 제도를 폐지하고 시장평균환율제를 도입하였다.
- 2) Meese and Rogoff(1983)는 다른 어떤 환율결정이론에 근거한 구조적 환율예측모형의 예측력이 임의보행(random walk)모형의 표본외 환율 예측력을 능가하지 못한다는 주장을 했다.
- 3) 한국무역보험공사 환위험관리팀에 문의결과 매일 업데이트 되는 환율전망 자료는 인포맥스 시스템과 연동되어 있으며 여러 은행의 예상범위 평균이 보고서에 기록된다고 한다.



를 제공한다. 본 논문에서는 편의상 한국무역보험공사를 ‘전문기관’이라 지칭한다.

환율에 대한 예측은 환율 결정이론에 근거한 구조적 모형과 환율의 시계열 자료만을 활용하는 시계열 모형으로 크게 나눌 수 있다. 본 연구에서는 후자를 선택<sup>4)</sup>하고 일변량을 기본으로 하는 시계열모형(ARIMA)과 기계학습모형(LSTM)을 구축하여 일변량 모형보다는 우수한 예측치를 제공할 것으로 추측되는 전문기관의 예측치와 일변량 모형들과의 예측력을 평가한다.

이를 통해 전문기관이 제공하는 환율전망이 본래의 의도대로 현실과 가까운지 확인하고 일변량 모형(ARIMA 및 LSTM)이 환율 예측에 있어서 활용 가능성이 있는지 확인한다. 또한 각 모형의 예측력 분석을 위한 기간을 환율 변동성이 다소 일반적인 예측기간 I<sup>5)</sup>과 최근 COVID-19로 인해 변동성이 상대적으로 커진 예측기간 II<sup>6)</sup>로 나누어 각 예측 기간별로 서로 어떤 차이가 있는지도 비교하여 살펴보고자 한다. 특히 전체 자료에 대해 20일 단위의 구간이동(rolling method)을 적용하여 각 모형의 예측력의 차이에 대한 동태적 분석을 체계적으로 시도한다.

## 제 2 절 선행연구의 검토

다양한 환율 예측모형들을 연구하고 예측력을 비교하는 선행연구들은 다수 존재하지만 금융기관과 같은 전문기관의 환율 예측치를 연구하는 자료는 상대적으로 매우 적었다. 이는 금융기관이 예측치 모형 자체에 대해 공개하지 않고 또한 실제 예측자료도 확보가 쉽지 않기 때문이라고 추측된다. 최근에는 인공지능의 발전에 따라 환율, 주가 및 주책지수 등에 대한 예측 인공지능 모형에 대한 연구가 이루어지고 있으며 과거에는 인공신경망의 초기모형인 다층퍼셉트론(MLP: Multi Layer Perceptron)과 같은 단순한 신경망에 대한 연구들이 있었으나 최근에는 순환신경망(RNN: Recurrent Neural Network), 장단기메모리(LSTM: Long Short Term Memory), 게이트 순환 유닛(GRU: Gated Recurrent Unit)<sup>7)</sup>과 같은 인공신경망에 대한 연구가 증가하고 있다.

4) Hamilton(1989)은 지난 환율 자료에는 많은 정보가 있다고 주장하였으며 시계열 자료만을 이용한 분석은 주어진 자료에서 정보를 찾는 노력이라 할 수 있다.

5) 예측기간 I 은 19년 1월 22일 ~ 19년 4월 4일(총 49일) 이다.

6) 예측기간 II 은 20년 1월 21일 ~ 20년 3월 31일(총 49일) 이다.

7) 게이트 순환 유닛(GRU: Gated Recurrent Unit)은 장단기메모리(LSTM: Long Short Term Memory)의 구조를 보다 단순하게 처리한 변형모델이다.



## 1. 전문기관의 예측치를 이용한 환율 예측 연구

정철호(2005)는 국제투자은행들의 엔화 및 유로의 달러환율에 환율예측 서비스를 평가하였다. 이를 위해 기관들의 예측치를 임의보행모형에 의한 예측치와 평균 평방오차(MSE: Mean Squared Error) 및 DOC(Direction of Change) 기준으로 비교하여 기관의 환율예측력이 임의보행모형보다 우수한 경우를 다수 발견하였다.

김창범(2007)은 제이피모건(JP Morgan), 에이치에스비씨(HSBC), 시티은행(CITI)과 같은 전문기관들의 환율 예측치를 몬테카를로 시뮬레이션 방법과 비교하여 우수한 유용성을 검증하였다.

형남원·전형철(2010)은 상업은행에서 제시하는 환율 예측치를 다양한 시계열모형 예측치와 비교하고 검증하였고 상업은행과 시계열 모형의 예측치 결합을 통한 예측력 개선을 위한 연구를 실시하였다. 실증분석결과 은행의 예측치가 다른 시계열모형의 예측치보다 우수하였으며 결합예측치를 만드는 경우 은행의 예측치가 가지고 있던 편의성이 개선되었고 변동 방향의 개선에 대한 우수한 성과를 보였다.

김진일·형남원(2013)은 변동범위 형태의 예측치 평가를 위한 방법을 제시하고 국내 주요 5개 상업은행에서 제공하는 환율 예측치를 분석하였다. 실증분석결과 평균값 형태의 점예측(point forecast) 측면에서는 KB은행의 예측치가 우월하지만 변동범위의 특성을 고려하면 신한은행이 제공한 예측치가 가장 우수한 것으로 나타났다. 은행들의 예측 편의에 대한 경향도 확인되었다.

## 2. 구조적 모형 및 시계열 모형을 이용한 환율 예측 연구

오문석·이상근(2000)은 자산시장접근모형과 시계열 모형들의 원/달러 예측력의 정확성을 비교하였다. 실증분석결과 표본 외 1개월, 3개월 예측력은 Random walk 모형이 가장 우수하였으며 6개월, 12개월 예측력은 실질이자율차모형과 종합모형의 우수함이 확인되었다.

이우리(2002)은 일별 원/달러 환율 예측을 위해 AR 모형, GARCH 모형, AR-GARCH 모형, 개입시계열 모형, 확률보행 모형과 같은 5가지 모형들을 추정하고 각 모형의 예측력 평가 후 결합예측을 진행하였다. 분석결과 제한최소제곱법을 통한 결합방법이 효율적이었으며 실증분석결과 이와 같은 결합예측이 표본내 기간뿐만 아니라 표본외 기간에서도 예측력이 개별예측보다 우수한 것으로 확인되었다.



류시영(2006)은 초단기 예측에서 시계열 자료의 변수만을 활용하여 임의보행모형보다 우수한 모형을 선정하고자 했고 ARIMA모형이나 GARCH류의 모형의 소파동 이론으로 자료를 분해한 후 잡음을 제거한 Wavelet(ARIMA(5,1,8))모형이 설명력을 크게 개선시킨다는 것을 확인하였다.

이윤석(2007)은 외환위기 이후 원/달러 환율의 월별데이터와 환율의 주요 결정 변수를 시계열 모형에 추가한 환율 모형의 표본외 예측력을 임의보행 모형의 예측력과 비교하고 분석하였다. 그 결과 가장 우수한 예측력은 AR모형에 자본수지, 한미 인플레이션율의 차이를 결합한 모형이 보여주었다.

홍성완(2010)은 환율에 대한 예측 정확도와 방향성을 확인하기 위해 구조적 모형, 랜덤워크 모형, ARIMA 모형 등을 이용하였다. 구조적 모형은 1년 이상 장기예측력에서는 좋은 예측력을 보여주었고 랜덤워크 모형은 단기예측에서 우수한 예측력을 보이지만 변동성이 심한 기간과 장기예측에서는 예측력이 크게 줄어드는 모습을 보여주었다. 이를 통해 기존 연구결과들과 같은 단기예측에는 시계열 모형이 장기예측에는 경제구조 모형이 좋은 예측력을 보인다는 결론을 확인할 수 있었다.

김보미·김재희(2012)은 17년간의 일별 원/달러 시계열 데이터에 대해 ARIMA(2,1,2)와 ARIMA(1,1,0)+IGARCH(1,1) 모형을 적합하여 비교하고 예측을 실시하였다. 실증 분석결과 두 모형 모두 과거 데이터에 대한 추정은 잘하는 편이지만 실제 환율의 미래 변동성은 ARIMA(1,1,0)+IGARCH(1,1) 모형이 잘 반영한다는 점을 확인하였다.

강나연(2015)은 실질환율을 추가한 테일러 준칙에 의한 환율 예측정도가 임의보행모형과의 표본외 예측력 비교에서 더 우수한 예측력을 보이는 것을 확인하였고 인플레이션 증가 시 정책금리가 상승한다는 테일러 원칙이 실제 환율 예측의 관계가 있는지 여부에서 한국 인플레이션의 계수가 유의미하게 음수가 나오는 것을 확인하였다.

### 3. 인공지능 모형을 이용한 환율 및 지수 예측 연구

김재현(2002)은 인공신경망 모형과 ARIMA 모형을 구축하여 각 모형의 원/달러 환율예측성과를 시장평균 및 자유변동 환율기간으로 나누어서 비교하였고 환율의 점 예측과 변동 방향 예측력에서 인공신경망 모형이 ARIMA 모형보다 비교적 우수한 예측력을 보이는 것으로 확인하였다.





김수기(2007)은 변동성 예측을 위한 시계열 모형(EWMA, GARCH, EGARCH)과 인공신경망 모형과의 통합모형을 제시하였다. 이 통합모형은 예측 정확도가 단일인공신경망보다 우수하였으며 ANN-GARCH 모형의 정확도가 가장 우수하였다.

한태경(2010)은 시계열 분석기법과 기계학습모형을 합성한 환율예측모형을 제안하였다. 각 모형들의 예측력 비교결과 기계학습 모형인 SVM과 인공신경망을 활용한 모형의 예측력이 기존 통계적 기법인 로지스틱 회귀나 판별분석에 비해 예측력이 향상되었다.

강민영(2016)은 이미지, 음성 인식, 자연어 처리 등의 분야에서 높은 성능을 보여주고 있는 합성곱 신경망(CNN)모형을 구축하여 기존 인경신경망 모형인 다층 퍼셉트론(MLP) 모형과 성능을 비교하였다. 비교결과 기존 인공신경망 모형인 다층 퍼셉트론에 비해 합성곱 신경망모형의 예측력이 13.9% 향상되는 것을 확인하였다.

김호현(2017)은 LSTM/GRU 모형에 Xavier 가중치 초기화 기법과 Dropout 과다학습방지 기법을 적용한 예측모형을 기존의 ARIMA 모형, 전방향신경망 모형, ARIMA+전방향형신경망 혼합모형과 예측력을 비교하였다. 그 결과 기존의 모형들보다 LSTM/GRU 모형이 더 높은 예측력을 보여주는 것을 확인하였다.

배성완·유정석(2018)은 시계열 모형과 기계학습 모형을 통해 부동산 가격지수에 대한 예측력을 비교하고 분석하였다. 그 결과 시장이 비교적 안정적인 경우 두 모형 모두 비교적 안정적인 예측력이 확인되었지만 비선형 형태로 시장이 급변하는 경우 시계열분석 모형은 시장 예측력이 감소하는 반면 비선형 모델링이 가능한 기계학습 모형은 상대적으로 의미있는 예측이 가능하다는 것을 보여주었다.

박혜원(2019)은 LSTM 모형의 예측력을 ARIMA 모형을 따르는 난수를 생성한 모수적 방법과 비교하였다. 분석결과 비교적 정확한 모형의 식별이 가능한 경우 모수적 방법과 LSTM(ADAM)의 예측력이 비슷하였다. 하지만 모형 식별이 어려운 경우에는 LSTM(ADAM)의 예측 성능이 모수적 방법보다 우수하였다는 것을 보여주었다.

이태형(2019)은 아파트 가격지수만을 변수로 하는 일변량과 6개의 거시경제지표를 추가한 다변량으로 나누어 예측력을 비교하였다. 그 결과 일변량 분석의 경우 RNN과 LSTM 모형이 ARIMA 모형보다 우수한 결과를 보여주었고 다변량 분석의 경우도 LSTM의 예측력 다른 계량경제 모형보다 우수하다는 것을 확인시켜주었다. 특히 인공신경망의 예측력은 상대적으로 변동성이 크고 비선형성이 높은 자료에 대해 유용하다는 것을 확인하였다.



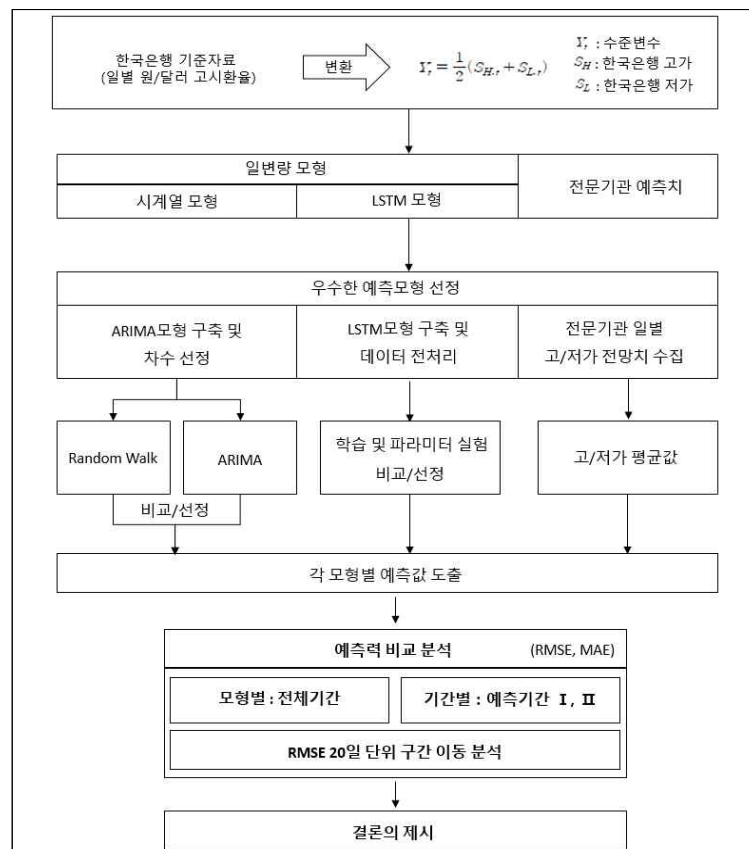
### 제 3 절 논문의 구성

본 연구의 구성은 다음과 같다. 제2장에서는 연구모형에 대해서 개략적으로 살펴보고 연구자료의 특징 및 예측 및 비교 방법에 대해서 설명한 후 시계열 모형과 기계학습 모형의 예측값을 도출한다. 이에 제3장에서는 실증분석을 진행하여 각 모형별 예측 정확성을 비교하고 20일 평균제곱근오차 그래프를 도출하여 모형별 특징을 분석한다. 끝으로 제4장에서 연구의 결론과 시사점, 그리고 연구의 한계를 밝혀 연구의 방향성과 확장성에 대해 논의한다.

## 제 2 장 연구방법

### 제 1 절 연구의 모형

[그림 2-1] 연구모형





[그림 2-1] 전문기관, 시계열 및 LSTM 모형의 일별 원/달러 환율의 예측력을 시험하기 위한 연구모형으로 이를 세 부분으로 나누어 분석과정을 설명할 수 있다.

첫째는 자료의 특성으로 한국은행 고시환율의 일별 고가와 저가의 평균을 환율의 수준변수로 하는데, 이는 벤치마크 모형인 전문기관의 예측자료가 고가와 저가 형태로 제공하기 때문이며, 각 모형 간의 점 예측의 정확성 비교에도 유용하다. 연구자료의 다른 특징들은 차후 제2절 영역에서 자세히 다루도록 한다.

둘째는 구조적 모형이 아닌 환율의 수준변수만을 활용하는 일변량 모형(ARIMA & LSTM)을 통해 예측치를 도출하고 RMSE, MAE를 통해 예측력 비교를 시도한다. 특히 각 모형의 가장 우수한 예측모형을 선정하여 전문기관의 예측력을 비교하는데 시계열 모형은 random walk와 ARIMA 모형을 비교하여 선정하고 LSTM 모형은 초모수의 조정을 통한 최적의 모형을 선정한다.

셋째는 위에서 도출한 각 모형별 예측값들을 환율의 변동성이 크지 않은 예측기간 I 과 COVID-19의 영향으로 환율의 변동성이 비교적 높아진 예측기간 II으로 나누어 기간별 각 모형의 예측치의 정확성을 비교 분석한다. 외환시장의 변동성에 따른 예측력 비교를 위해 전체 자료에 대해 20일 단위의 구간이동(Rolling Method)을 적용하여 각 모형의 예측력의 차이에 대한 동태적 분석을 체계적으로 시도한다.

## 제 2 절 연구자료의 특징

본 연구에서 사용하는 기준자료는 한국은행 경제통계시스템에서 제공하는 일별 원/달러 환율 시계열이며 전체 기간은 14년 4월 1일부터 20년 3월 31일까지 총 1,468일을 이용하였다.

연구 내용이 전문기관이 제공하는 원/달러 환율 예측치와 시계열 및 기계학습 모형들과의 예측력을 비교분석하는 연구이기 때문에 [그림 2-2]과 같이 전문기관 홈페이지에서 오전 8:00경 고가와 저가의 범위로 제공되는 예측치와 동일하게 한국은행의 기준자료에서도 일일 고가와 저가 데이터를 이용하였으며 전문기관에서 환율전망을 발표하지 않은 결측일 5일<sup>8)</sup>과 오류데이터 1일<sup>9)</sup>을 연구 기간에 반영하여 예측력 비교의 정확성을 높이기 위해 노력하였다.

8) 결측치 5일(16/1/15, 19/7/15, 19/8/5, 19/8/6, 19/8/7) 제외

9) 오류데이터 1일(18/8/7) 수정, 한국무역보험공사 환위험관리팀에 문의결과 시스템이 인포맥스시스템과 연동되어 여러 은행의 예상범위 평균이 보고서에 기록되는데 한 은행이 예상범위에서 100원씩 빠져있는 것으로 확인되며 이는 한 은행의 오타로 보여진다고 답변함.



[그림 2-2] 전문기관 환율 일일전망 사례 (20.3.31)



자료: 한국무역보험공사 홈페이지 정보광장 메뉴에 환율동향 일일리포트 게시판의 게시글 1738번 3월 31일 일일리포트. [https://www.ksure.or.kr/info/exchange\\_l.do](https://www.ksure.or.kr/info/exchange_l.do)

전문기관에서 제공하는 환율전망 예상범위(고가~저가)의 평균값을 일별 환율의 수준 예측치로 사용하며, 이와 동일하게 일별 원/달러 환율의 수준변수( $Y_t$ )는 한국은행 일별 원/달러 고시환율의 고가와 저가의 산술평균을 적용하였다.

최저-최고 예상치(range forecast)를 사용하면 더 많은 정보를 분석하는 장점이 있지만 기존의 예측력 평가방법을 이용한 예측력 분석에 적합한 형태로 활용하기 위해 고가와 저가의 산술평균값을 환율의 수준변수로 사용하였다.<sup>10)</sup> 따라서 본 연구에서 수준변수는 다음과 같은 식으로 표현된다.

$$Y_t = \frac{1}{2}(S_{H,t} + S_{L,t}) \quad (1)$$

$Y_t$  : 수준변수  $S_H$  : 한국은행 고가,  $S_L$  : 한국은행 저가

10) 형남원·전형철(2010). p.6 참조



[표 2-1] 기간별 원/달러 환율의 기초통계량

	전체 기간	예측기간(전체)	예측기간 I	예측기간 II
	14.4.1 ~ 20.3.31	19.1.22 ~ 20.3.31	19.1.22 ~ 19.4.4	20.1.21 ~ 20.3.31
Mean	1128.700	1173.470	1127.214	1202.895
Median	1129.700	1177.850	1127.650	1196.000
Maximum	1272.250	1272.250	1137.950	1272.250
Minimum	1009.150	1111.050	1111.050	1163.300
Std. Dev.	49.65115	29.70577	6.377883	25.84187
Skewness	-0.293426	0.072629	-0.374484	0.968830
Kurtosis	2.744168	3.096929	2.485550	3.462236
Jarque-Bera	25.06889	0.368484	1.685622	8.101718
Probability	0.000004	0.831735	0.430499	0.017407
Sum	1656931.0	340306.3	55233.50	58941.85
Sum Sq. Dev.	3616502.0	255023.1	1952.515	32054.51
Observations	1468	290	49	49

한국은행 기준자료의 일별 수준변수로 기간별 환율 데이터의 특성을 확인하기 위한 기초통계량은 [표 2-1]와 같으며 각 예측기간의 표준편차를 통해 각 예측기간의 변동성을 예상할 수 있다.


[그림 2-3] 예측기간 원/달러 환율 추이 (19.1.22~20.3.31)



[그림 2-3]은 원 시계열의 일별 환율 움직임의 특성을 보여주고 있으며 [그림 2-4]은 원 시계열의 차분을 통해 일일 편차의 변동성의 강도와 추이를 보여준다.




[그림 2-4] 예측기간 원/달러 환율 변동 추이 (19.1.22~20.3.31)



두 그림 모두 기간별로 다른 색으로 표시되어 있으며 예측기간 I 과 예측기간 II 의 환율의 움직임을 확인할 수 있다.

[그림 2-5] 일별 원/달러 환율의 원시계열 그래프 (14.4.1~20.3.31)



[그림 2-5] 환율의 원시계열 그래프를 살펴보면 14년 4월부터 20년 3월까지 수 차례의 전환국면을 확인할 수 있다. 14년 9월 추석 연휴에 따른 물량이 유입되며



1,010원 초반으로 출발한 환율은 ECB 통화 완화에 따른 유로화 급락과 미국 경제 지표 호조에 따른 조기 금리 인상 기대로 환율이 지속 상승하여 14년 11월에는 1,110원대 중반까지 상승하였다. 이후 15년 7월에 중국 증시 급락의 불안감과 엘런 의장의 연중 미 금리 인상 확인 발언 및 외국인의 주식과 채권 매도세가 강해지면서 12년 6월 이후 최고치인 1,170원으로 마감하였으며 15년 9월에는 1,200원 선을 돌파하며 통화정책에 대한 불확실성과 안전자산에 대한 선호로 혼조세를 보였다. 16년 1월과 2월에는 북한 핵실험 등 악재와 국제 유가 급락, 금융시장 불안 그리고 글로벌 자산운용사의 지속적 달러 매수로 환율이 최대 1,240원 선까지 급등하기도 하였다. 2018년 6월, 2019년 2분기와 3분기에는 미중 무역분쟁 확대와 이에 따른 불확실성으로 환율의 변동성이 높아지기 시작하였으며 유럽 국가들의 금융 불안과 한일갈등으로 1,200원 이상으로 환율이 급등하였다. 최근 미국과 이란의 중동발 리스크와 더불어 COVID-19의 확산에 따라 환율의 상승폭과 변동성이 확대되었으며 국내확산의 본격화, WTO의 비상사태 선포, 글로벌 확산에 따른 경기 침체 우려로 불확실성은 더욱 증대되고 있다.<sup>11)</sup>

위 [그림 2-5]처럼 환율 그래프의 움직임은 예측할 수 없는 변수들과 복합적인 상황에 따라 급변하는 불안정한 시계열임을 알 수 있다. 전통적 계량분석에서는 사용되는 자료는 대부분 안정적(stationary)이라고 가정하지만, 환율자료를 포함한 시계열 자료들은 대체로 불안정적(nonstationary)이라는 실증분석 결과가 확인되고 있다.<sup>12)</sup> 그래서 일반적인 시계열 자료들에 대해 단위근의 존재 여부를 검정하여 시계열 자료의 안정성 여부를 확인하는데 이에 대해 널리 사용되는 방법으로 ADF(Augmented Dickey-Fuller) 검정이 있다.

$H_0$  : 단위근(unit root)이 존재한다.

안정성 검정에서 귀무가설인 단위근의 존재가 기각되면 해당 시계열 데이터는 안정성을 만족한다고 볼 수 있으며 귀무가설을 기각하지 못하는 경우 시계열 데이터가 안정성을 만족할 수 있도록 차분(differentiation)을 통하여 불안정 시계열을 안정 시계열로 변환한다.

11) 한국무역보험공사 월간리포트 2014년 4월 ~ 2020년 3월 월간 환율전망

12) 남준우·이한식(2010), p.229



본 연구의 수준변수에 대해 ADF-검정 결과를 [표 2-2]에서 확인해보면 환율의 수준변수는 귀무가설( $H_0$ )을 기각할 수 없으며 1차 차분변수는 귀무가설( $H_0$ )을 기각할 수 있다.

[표 2-2] ADF 단위근 검정

수준변수		1차 차분변수	
t-Statistic	Prob.*	t-Statistic	Prob.*
-1.922	0.322	-36.179	0.000

검정 결과에 따라 수준변수를 정상 시계열로 변환하기 위해 수준변수를 1차 차분(differentiation)한다. 본 연구에서는 환율의 수준변수를 1차 차분한 변수( $S_t = y_t - y_{t-1}$ )의 값인 차분변수  $S_t$ 를 시계열 모형의 분석에 사용하였다.

### 제 3 절 평가방법과 예측모형

#### 1. 예측 및 비교방법

##### (1) 예측방법

##### 1) 시계열 모형

시계열 모형에서 예측치를 생성하는 방법으로 샘플기간 설정에 따라서 크게 구간이동방법(Rolling Method)과 확장방법(Expanding Method)이 있다.<sup>13)</sup> 확장방법은 시작지점을 고정하고 예측기간을 한 단위씩 늘리면서 예측치를 생성하지만 구간이동방법은 시작지점을 고정하지 않고 예측치를 생성하는 샘플기간을 고정하여 구간을 일정하게 이동하면서 예측치를 생성한다.

예를 들어 100개의 샘플기간을 가지고 101번째부터 103번째의 예측치를 만들기 위해서는 확장방법은 1에서 100까지의 샘플을 이용해서 101번째 예측치를 만들고, 1에서 101까지의 샘플을 이용해서 102번째 예측치를 만들고, 1에서 102번째 샘플을 이용해서 103번째 예측치를 생성한다. 구간이동방법은 1에서 100까지 샘플을 이용해서 101번째 예측치를 만들고, 2에서 101까지 샘플을 이용해서 102번째 예측치를 만들고 3에서 102번째 샘플을 이용해서 103번째 예측치를 도출한다.

13) 형남원·전형철(2010), p.9





본 연구에서는 장기간의 추세가 분산을 증가시켜 예측력이 저하되는 문제를 완화할 수 있고 금융 분야의 예측 모델링에서 자주 이용되는 구간이동방식을 예측 방식에 적용한다. ARIMA모형의 샘플기간(rolling window)은 3년 정도의 기간에 해당하는 750일로 설정하고, 이에 따른 예측 구간도 3년 정도에 해당하는 718일로 설정하였다. 즉 약 3년간의 일별 데이터인 750개의 샘플을 가지고 앞서 제시한 각 시계열 모형들을 통해 분석을 한 후, 도출된 추정치를 이용하여 이후의 예측 기간인 718일에 대해 원/달러 환율을 예측하는 것이다.

## 2) 기계학습 모형

기계학습 모형에서 예측치를 생성하기 위해서는 특정 모델을 학습시키기 위한 학습세트(training set)와 학습 모델이 제대로 동작하는지에 대한 평가세트(test set)가 필요하다. 즉 전체 데이터세트를 학습세트와 평가세트로 나누어 학습세트에서 학습한 후 평가세트에서 도출된 데이터로 원/달러 환율을 예측하는 것이며 일반적으로 전체데이터 중 80%를 학습세트로 20%를 평가세트로 사용한다.

## (2) 비교방법

각 모형의 예측치들을 환율의 실제값과 비교하여 평균 제곱근 오차(RMSE: root mean square error)와 평균 절대 오차(MAE: mean absolute error)를 산출하고 이를 통해 각 예측값의 정확성의 척도를 파악하여 예측력을 비교한다. 각 모형의 정확도는 평균 제곱근 오차(RMSE)와 평균 절대 오차(MAE)의 오차 값의 수치가 0일 때 예측정확도가 100%라고 할 수 있다. 예측력의 측정은 각 모형이 도출한 예측치로 예측오차를 구하고, 예측오차가 낮은 예측치를 도출한 모형을 예측력이 높은 모형으로 선정한다.

### 1) 평균 제곱근 오차(RMSE: root mean square error)

평균 제곱근 오차(RMSE)의 경우 실제값과 예측값의 오차 값에 제곱하여 오차의 범위를 증폭시킨다. 이는 오차의 크기가 크면 클수록 추가적인 패널티를 얻게 되기 때문에 평균 제곱근 오차(RMSE)는 시계열 자료의 예측정확도를 평가하는 기준으로 많이 사용된다.



$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2} \quad (2)$$

$Y_i$ : 실제 환율의 수준변수값,  $\hat{Y}_i$ : 모형으로부터 생성된 예측값

## 2) 평균 절대 오차(MAE: mean absolute error)

평균 절대 오차(MAE)는 실제값과 예측값의 차이를 절대값의 형식으로 표현한 것이며 환율자료의 분포가 정규분포가 아닌 랩토커틱(leptokurtic) 형태의 분포라면 평균 절대 오차(MAE)가 평균 제곱근 오차(RMSE) 보다 더 나은 기준이 된다.<sup>14)</sup>

$$MAE = \frac{1}{n} \sum_{i=1}^n |Y_i - \hat{Y}_i| \quad (3)$$

$Y_i$ : 실제 환율의 수준변수값,  $\hat{Y}_i$ : 모형으로부터 생성된 예측값

## 2. 시계열 모형

미래의 환율을 예측하기 위해 변수의 과거 변동추이를 분석하는 시계열 모형은 환율의 과거 변동 추이에서 특정 모형을 추출하여 환율을 예측하기 위한 분석 모형이다. 환율의 움직임은 변동폭이 크기 때문에 과거 단순하고 전통적인 예측모형 들으로는 환율의 변화를 추정하는 것이 쉽지 않다. 그래서 많은 선행연구들에서 정교하게 시계열 데이터를 잘 이해하고 예측력이 높은 모형으로 자기회귀누적이동 평균(ARIMA: Autoregressive Integrated Moving Average)과 같은 시계열 모형을 이용하였다.

### (1) 임의보행(Random Walk)모형

Meese and Rogoff(1983)은 환율 결정이론에 근거한 어떠한 모형보다도 임의보행(random walk)에 의한 환율예측력이 더 나은 예측력을 가지고 있다고 밝혔다. 그렇기 때문에 다른 모형들과 예측력을 비교하기 좋은 모형이라고 생각된다.

$$Y_{t+1} = Y_t + \varepsilon_{t+1} \quad (4)$$

$Y_t$ 는 t기의 가격이고  $\varepsilon_{t+1}$ 은 t+1기의 오차항이다.

14) 김재현(2002), p.38





## (2) 자기회귀누적이동평균(ARIMA)모형

비교적 잘 알려진 시계열 모형 중 하나이며, 단일 및 연립방정식 모형을 구축하지 않고 현 시점의 관측값을 자신의 과거 관측값들과 오차로 표현되는 백색잡음들과의 확률적 오차항을 함수관계로 표현한 모형으로 주로 단기예측에 활용되며 AR(Auto Regressive), MA(Moving Average), I(Integrated) 이라는 세 가지 도구를 이용하여 시계열을 분석하고 예측한다.

첫째 도구는 자기회귀(AR: AutoRegressive) 과정으로 현재 시점의 시계열 자료  $Y_t$ 는 자신의 과거 값  $Y_{t-p}$ 의 관측값들과 상관되어 있다는 뜻이며 과거 관측값에 영향을 미치는 부분과 백색잡음의 합으로 구성된다.

$$Y_t = \mu + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \phi_3 Y_{t-3} \cdots \cdots \phi_p Y_{t-p} + \varepsilon_t \quad (5)$$

둘째 도구는 이동평균(MA: Moving Average) 과정으로 미래의 예측값은 과거의 추세뿐만 아니라 백색잡음이라는 오차에도 많은 영향을 받는다. 현재 시점의 시계열 자료  $Y_t$ 는 백색잡음  $\varepsilon_{t-q}$ 의 과거 오차항에 영향을 받는다는 뜻이며 이 오차들은 동일한 분포를 따르는 독립적인 확률 변수들이다.

$$Y_t = \mu + \varepsilon_t - \theta_1 \varepsilon_{t-1} - \theta_2 \varepsilon_{t-2} - \cdots \cdots - \theta_q \varepsilon_{t-q} \quad (6)$$

셋째 도구는 d번의 차분 과정을 통해 시계열의 안정성을 충족시킨 적분(Integrated) 데이터를 분석하기 위한 도구이다. 안정적인 시계열은 시간의 추이와 관계없이 평균, 분산, 공분산이 불변하나 시계열  $Y_t$ 의 경우 위 조건들을 만족시킬 수 없으므로  $Y_t$ 의 차분을 통해 안정적 시계열로 변환한다. I(d)번의 차분을 통해 안정화된 시계열  $S_t = y_t - y_{t-1}$ 는 AR도구와 MA도구를 통해 분석할 수 있다.

$$S_t = \mu + \phi_1 S_{t-1} + \phi_2 S_{t-2} + \cdots \cdots + \phi_p S_{t-p} + \varepsilon_t - \theta_1 \varepsilon_{t-1} - \theta_2 \varepsilon_{t-2} - \cdots \cdots - \theta_q \varepsilon_{t-q} \quad (7)$$



ARIMA(p,d,q)<sup>15)</sup> 모형은 위 세 가지 도구를 모두 활용한 형태로 (식1-3)과 같이 나타낼 수 있으며 차분한 안정적인 시계열 자료에 과거의 값과 오차의 값을 모두 고려하는 모형이라 할 수 있다.

### (3) 차수의 선정

앞서 환율자료의 수준변수는 단위근 검정에서 귀무가설을 기각하지 못하여 불안정 시계열 자료임을 확인하였고 1차 차분을 실행한 1차 차분변수가 단위근을 가지고 있다는 귀무가설을 기각하면서 안정적인 시계열 자료임을 증명하였다. 이제 예측모형을 선정하기 위한 ARIMA(p,1,q)의 차수를 결정해야 한다.

AR(p)와 MA(q)의 차수의 결정은 간단한 예측모형들의 경우 자기상관함수(ACF: Autocorrelation Function)와 편자기상관함수(PACF: Partial Autocorrelation Function)의 형태를 보고 결정하기도 하지만 많은 선행연구들에서 SC(Schwarz Criterion)기준이나 AIC(Akaike Information Criterion)를 참고하여 낮은 기준으로 시계열 모형의 차수를 선택하였다.

본 연구에서는 차수의 선정 기준은 SC를 최소화하는 모형으로 우선하고 AIC는 함께 참고하여 AR(p)와 MA(q)의 차수를 선정하기로 하였다. 위 방법들을 활용하는 것이 절대적인 기준이 아니므로 각 차수의 최대 3까지 입력하여 가능한 모형들에 대해 통계적 유의성을 확인하고 유의한 모형의 SC와 AIC의 값을 비교한 결과를 [표 2-3]에 정리하였다.

[표 2-3] ARIMA 모형의 최적차수 결정

모형 <sup>16)</sup>	SC	AIC
ARIMA(0,1,1)*	<b>6.230</b>	<b>6.223</b>
ARIMA(0,1,2)*	<b>6.231</b>	<b>6.224</b>
ARIMA(1,1,0)*	<b>6.230</b>	<b>6.223</b>
ARIMA(2,1,0)*	<b>6.231</b>	<b>6.224</b>
ARIMA(1,1,2)	6.233	6.222
ARIMA(2,1,1)	6.233	6.222
ARIMA(3,1,3)	6.235	6.229

15) Box와 Jenkins는 어떤 시계열이 AR(p)인지 MA(q)인지 혹은 (ARMA)인지 구분하는 순쉬운 4단계 방법을 제시하였다. 본 연구에서는 이 방법론을 이용하였다.

16) 모든 모형에서 상수항은 유의하지 않아 제외함



[표 2-3]는 전체 연구기간에서 가장 적합한 ARIMA(p,d,q) 모델을 선정하기 위해 분석한 결과이며 ARIMA(0,1,1)과 (1,1,0) 모형이 SC(Schwarz Criterion) 값이 최소화되는 것으로 확인되었다. 따라서 향후 ARIMA(0,1,2), ARIMA(2,1,0) 모형을 추가하여 총 4개의 ARIMA(p,d,q) 모형 예측치와 Random walk 모형을 포함한 총 5개의 시계열 모형 예측치들을 비교해 보고 가장 높은 예측치를 가지는 시계열 모형을 선정하여 전문기관 및 기계학습 모형과 예측력을 비교하고자 한다.

#### (4) 예측값 비교 및 선정

14년 4월1일부터 750개의 자료구간을 일정하게 분할하고, 이에 대한 구간이동방법(Rolling Method)을 적용하여 도출된 각각의 추정 모형들을 통해 17월 4월 18일부터 20년 3월31일까지 총 718개의 예측치를 구하였다. 각 시계열 모형별로 추출된 예측치들을 대상으로 RMSE와 MAE의 기준을 통해 정확도가 가장 높은 모형을 판별하였다. 이에 따라 [표 2-4]와 같이 총 718개의 예측치가 만들어지며, 구간이동방법으로 정해진 샘플기간에 대해 일정하게 한 차수식 증감하며 예측한다. 이때 각 샘플기간마다 SC, AIC 값이 최소화되는 계속 바뀌어 적합한 모형이 다를 수 있으므로 본 연구에서는 ARIMA(p,d,q) 모형에서 총 4가지 모형을 선택하여 예측치를 도출하였다. 샘플기간에서 모형의 유의성이 확인되고 SC, AIC 값을 최소화하는 적합한 차수 모형으로 ARIMA(0,1,1)과 (1,1,0)을 선택하고 ARIMA(0,1,2), ARIMA(2,1,0) 모형을 추가하였다.

[표 2-4] 구간이동방식을 통한 예측방법(예시)

샘플기간 001 : 14/04/01~17/04/17(750일),	예측치 001 : 17/04/18
샘플기간 002 : 14/04/02~17/04/18(750일),	예측치 002 : 17/04/19
⋮	
샘플기간 717 : 17/02/28~20/03/27(750일),	예측치 717 : 18/03/30
샘플기간 718 : 17/03/02~20/03/30(750일),	예측치 718 : 18/03/31

[표 2-5]는 각각의 시계열 모형의 예측결과를 RMSE와 MAE로 비교한 결과이다. RMSE와 MAE 기준 모두 ARIMA(0,1,2)모형이 가장 우수하였으며 Random Walk 모형보다도 예측결과가 미세하게나마 좋았기 때문에 ARIMA(0,1,2)모형을 시계열모형의 대표모형으로 선정하고 전문기관 예측치와 기계학습 모형과 비교하고자 한다.



[표 2-5] 구간이동방식을 이용한 시계열 모형의 예측 결과

RMSE					
구분	Random Walk	ARIMA (0,1,2)	ARIMA (2,1,0)	ARIMA (0,1,1)	ARIMA (1,1,0)
전체 예측기간	5.759	<b>5.719</b>	5.730	5.776	5.779
예측기간 I	3.331	<b>3.292</b>	3.291	3.320	3.329
예측기간 II	10.394	<b>10.281</b>	10.316	10.482	10.491
MAE					
구분	Random Walk	ARIMA (0,1,2)	ARIMA (2,1,0)	ARIMA (0,1,1)	ARIMA (1,1,0)
전체 예측기간	3.964	<b>3.955</b>	3.959	3.976	3.977
예측기간 I	2.788	<b>2.764</b>	2.762	2.789	2.794
예측기간 II	7.562	<b>7.526</b>	7.544	7.649	7.656

## 2. 기계학습

### (1) 기계학습(machine learning)

앞에서 살펴본 시계열 분석을 이용한 예측모형은 시간의 흐름에 따른 과거 관측값과 오차값들을 이용하여 미래값을 예측하는 방법이다. 최근에는 빅데이터와 같은 비정형 데이터들의 증가와 고성능 컴퓨터의 등장과 같은 환경적 변화와 기술적 발전에 따라 인공지능(artificial intelligence)을 활용한 예측방법들이 많이 연구되고 있다.

기계학습(machine learning)은 학습의 형태와 알고리즘의 특성에 따라 다양한 모형으로 나뉜다. 그중에서 순환신경망(RNN: recurrent neuron network)이 시계열 예측에 가장 적합하다고 알려져 있다. 또한 최근 RNN의 단점인 기울기 소멸(vanishing gradient) 문제를 보완한 장단기메모리(LSTM: long short term memory)가 순환신경망(RNN)보다 더 좋은 예측력을 보이는 것으로 평가받고 있다. 그래서 본 연구에서는 장단기메모리(LSTM) 알고리즘을 사용한 인공신경망 모형을 구축하였다.

### (2) 인공신경망(ANN:artificial neural network) 모형 17)

인공신경망은 생물학적 신경망을 모방하여 만들어졌다. 여러 입력이 들어오면 각각 가중치를 곱해서 더해주고 추가적으로 편차도 더해줘서 이렇게 모두 더한 값

17) 이태형(2019). p.53~61.




을 활성화 함수를 통해 변형하여 전달하는 단위를 인공 뉴런이라고 하고 이러한 뉴런들이 모인 네트워크를 인공신경망이라고 한다.<sup>18)</sup> 인공신경망의 큰 장점은 데이터 속에 숨은 패턴들을 분석하여 일정한 규칙을 밝혀내는데 전통적인 방법들에 비해 뛰어나다. 인공신경망은 다양한 분야의 미래 예측을 위해 성공적으로 이용되고 있다.

인공신경망은 [그림 2-6]과 같이 일반적으로 입력층(input layer), 은닉층(hidden layer), 출력층(output layer)과 같이 세 개의 층으로 구성되어 있으며 망이 깊어지는 것을 시각화한 것이다. 입력층의 각 노드는 은닉층의 각 뉴런에 연결되고 이것이 다시 출력층과 연결되어 이어진다. 여기서 입력층을 제외한 은닉층과 출력층은 노드에 비선형 활성화 함수(Non-linear Activation Function)가 사용되는데 그 이유는 데이터를 비선형의 형태로 변경하여 은닉층의 수에 해당하는 망이 깊어지도록 하기 위함이다.

망이 깊어지면 다양한 장점들이 생기는데 그중 하나가 매개변수가 줄어들고 필요한 연산의 수가 줄어들면서도 정확도가 유지되는 결과 등을 낼 수 있다는 점이다. 선형방정식의 회귀분석과 달리 인공신경망을 이용한 회귀분석은 매개변수를 사용하지 않는 구조이다. 이 때문에 아무리 복잡한 데이터 그룹도 그 입력과 출력의 관계를 조사하고 학습 과정에서 이용하지 않은 새로운 샘플까지도 식별할 수 있다.

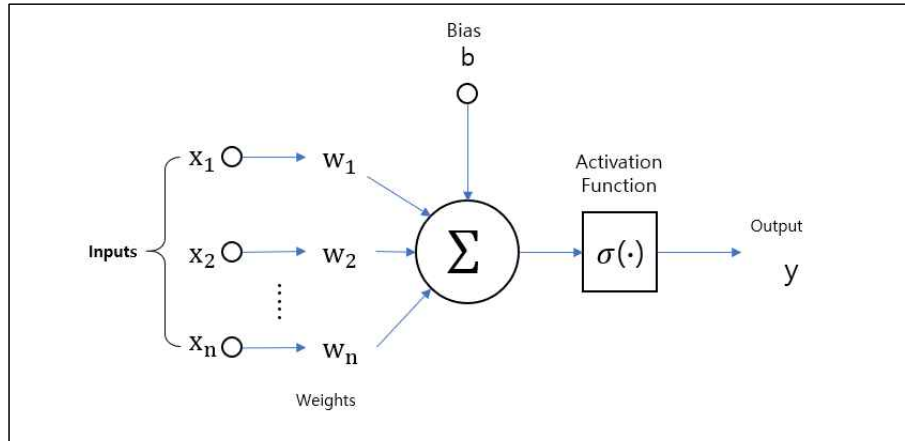
[그림 2-6] 인공신경망(ANN) 구성도



18) 최건호(2019). p.41~42.



[그림 2-7] 인공신경망(ANN) 수식도



[그림 2-7]은 뇌 속의 신경망과 유사하게 데이터가 처리되는 인공신경망의 구조를 보여준다. 입력층(Input layer)의 입력값( $x_i$ )은 가중치( $w_i$ )<sup>19)</sup>와 곱해져 뉴런에 연결되고 이들을 모두 합산한 결과에 편향( $b$ )을 추가하여 새로운 합( $A$ )을 만든다.

$$A = \sum x_i w_i + b \quad (8)$$

다시 말해 입력 벡터  $x = (x_1, x_2, \dots, x_n)$ 가 각 성분에 가중치( $w_i$ )를 곱하고 그 결과를 모두 합산한 후 활성화 함수  $\sigma(\cdot)$ 를 적용하여 출력값  $f(A)$ 을 출력한다고 할 수 있다.

$$f(A) = f(w_i x_i + b) \quad (9)$$

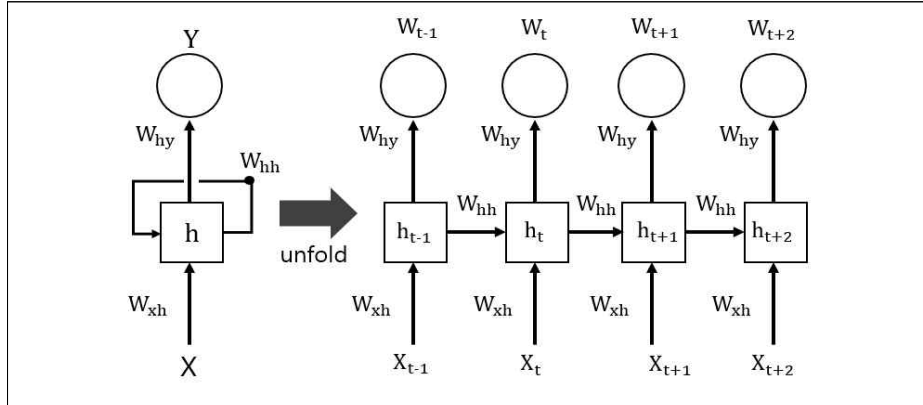
### 1) 순환신경망 (RNN: Recurrent Neural Network)

순환신경망은 시계열 데이터에서 의미를 찾아내기 위해 고안된 인공신경망으로 새로운 입력값과 자신의 과거값을 입력받아 자신의 현재값을 갱신하여 출력값을 만든다. [그림 2-8]은 순환신경망 모형은 다수의 층을 가질 수 있다는 것을 보여주고 있으며 이는 곧 심층신경망(DNN: Deep Neural Network)이라고 할 수 있다.

19) 입력값( $x_i$ )과 가중치( $w_i$ )는 실수로 구성된다.



[그림 2-8] 순환신경망 (RNN: Recurrent Neural Network)



다음은 순환신경망에서 은닉층의 입력값의 방정식이다.

$$h_t = g_n(W_{xh}X_t + W_{hh}h_{t-1} + b_n) \quad (10)$$

$t$ 시점의 은닉층( $h_t$ )은  $t$ 시점의 입력값( $X_t$ )을 은닉층( $W_{xh}$ )으로 보내는 매개변수 ( $W_{xh}X_t$ )와 은닉층( $W_{hh}$ )에서 자신의 과거값( $h_{t-1}$ )을 은닉층( $h_t$ )으로 보내는 매개변수( $W_{hh}h_{t-1}$ ) 그리고 한계값( $b_n$ )인 매개변수들에 활성화 함수( $g_n$ )를 적용하여 입력되며 출력값은 식 (11)과 같이 주어진다.

$$Z_t = g_n(W_{hz}h_t + b_z) \quad (11)$$

$t$ 시점의 출력값( $Z_t$ )는 은닉층에서 출력층으로 보내는 매개변수의 합( $W_{hz}h_t + b_z$ )에 활성화 함수( $g_n$ )를 적용하여 출력된다.

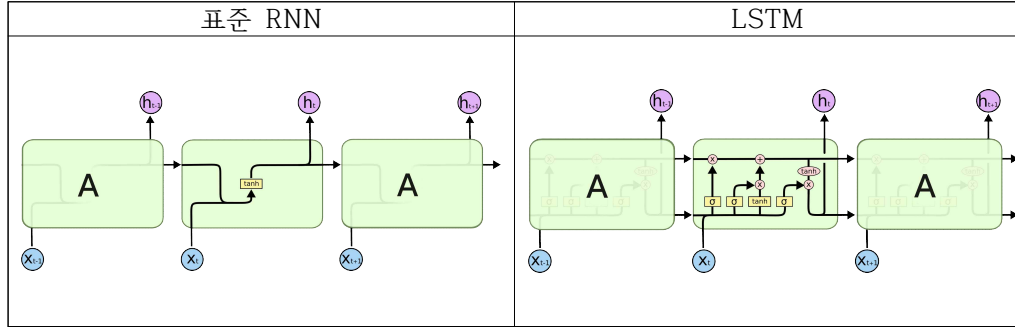
## 2) 장단기메모리 (LSTM: Long Short Term Memory)

장단기메모리(LSTM)는 순환신경망(RNN)이 개선된 형태로 장기종속성의 문제를 해결하기 위해 설계되었으며 일시적 메모리(short term memory)와 장기적 메모리(long term memory)의 활용을 통해 장기적 패턴을 학습할 때 발생할 수 있는 기울기 소멸 문제(vanishing gradient problem)를 극복할 수 있다.





[그림 2-9] 표준 RNN과 LSTM 알고리즘 비교



출처 : Olah. (2015). Understanding LSTM Networks. colah' s blog.<sup>20)</sup>

[그림 2-9]는 순환신경망(RNN)은 피드백 루프가 단순한 단일신경망 층을 가지고 있고 장단기메모리(LSTM)는 순환신경망(RNN)과 다르게 상호 반응하는 네 개의 층을 포함하는 메모리 셀을 가진 순환신경망이라는 것을 보여준다. 장단기메모리(LSTM)는 셀의 상태를 유지하면서 입력게이트(input-gate), 망각게이트(forget-gate), 출력게이트(output-gate)를 이용하여 출력값을 조절한다.

LSTM의 기본 공식은 아래와 같다.

$$f_t = \sigma(W_{if}x_t + b_{if} + W_{hf}h_{t-1} + b_{hf}) \quad (12)$$

$$i_t = \sigma(W_{ii}x_t + b_{ii} + W_{hi}h_{t-1} + b_{hi}) \quad (13)$$

$$\tilde{C}_t = \tanh(W_{ic}x_t + b_{ic} + W_{hc}h_{t-1} + b_{hc}) \quad (14)$$

$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t \quad (15)$$

$$o_t = \sigma(W_{io}x_t + b_{io} + W_{ho}h_{t-1} + b_{ho}) \quad (16)$$

$$h_t = o_t * \tanh(C_t) \quad (17)$$

망각게이트(forget-gate)에서는 과거의 정보를 얼마나 잊을지 정하게 되며 이것은 시그모이드(sigmoid) 함수를 이용한다. 시그모이드 함수는 0에서 1의 값을 출력하는데 0은 과거의 정보를 모두 잊고, 1은 과거 정보를 모두 기억하게 되는 비중을 정한다. 식(12)를 보면 현재 시점의 입력값( $x_t$ )과 직전 과거시점의 은닉값( $h_{t-1}$ )을 시그모이드( $\sigma$ ) 함수를 적용하여 망각게이트( $f_t$ )로 보내지게 된다.

20) <http://colah.github.io/posts/2015-08-Understanding-LSTMs>





입력게이트(input-gate)에서는 현재의 정보를 얼마나 저장할지 정하게 되며 식(13)에서처럼 새로운 입력값( $x_t$ )과 직전 과거시점의 은닉값( $h_{t-1}$ )을 시그모이드( $\sigma$ ) 함수를 적용하고 식(14)와 같이 입력값과 은닉값에 하이퍼볼릭 탄젠트 함수를 적용하고 식(15)와 같이 연산하여 셀 상태를 업데이트 한다. 식(16)은 출력게이트(output-gate)이며 식(17)은 은닉 상태의 업데이트를 나타내는 식이다.

### (3) 모형의 설계

환율을 예측하기 위한 장단기메모리(LSTM)의 실험환경은 Google Colaboratory 플랫폼을 통해 Pytorch의 Deep learning library와 Python version : Python 3.6.9으로 구축하였으며 시스템 환경은 CPU : Intel(R) Xeon(R) CPU @ 2.30GHz, Ubuntu 18.04.3 LTS, GPU(Tesla K80), 메모리 : 13.3352568GB (13335268KB)에서 진행하였다.

데이터는 ARIMA 모형과 같은 14년 4월 1일부터 20년 3월 31일까지의 총 1,468개의 한국은행 기준자료로 구축한 수준변수를 일변량으로 사용하여 데이터 세트(data set)를 구축하였고 이 중 80%를 학습 세트(training set)로 할당하고 나머지 20%를 평가 세트(test set)로 선정하였다. 활성화 함수는 Tanh (Hyperbolic Tangent)함수를 사용하였고 최적화 알고리즘으로는 오차 감소도가 빠른 Adam Optimizer 알고리즘을 이용하였다.

딥러닝에서 학습을 효과적으로 진행하기 위해서는 입출력 데이터의 크기가 작아야 하므로 환율데이터의 전처리는 보편적인 정규화 기법을 통해 모든 데이터의 스케일을 -1과 1구간으로 최소-최대(min-max scaling)하였고 시계열 입력 자료를 지도학습 문제로 변환하였다.

초모수(hyper parameter)는 학습 알고리즘에 영향을 받지 않으며 최적의 모형을 결정하기 위해 자료의 학습 전에 미리 지정하는 상수이다. 예측력의 향상을 위해서 뉴런과 층의 개수 등은 실험을 통해 가장 적합한 값을 선정하였다. 이를 위해 ① learning rate(학습속도), ② epochs(학습 횟수), ③ batch\_size(한 번에 학습할 때 이용하는 데이터의 개수), ④ input\_size(입력 데이터의 시계열 축의 개수), ⑤ hidden\_layers(연결할 신경망의 층수), ⑥ output\_dim(출력 데이터의 차원), ⑦ dropout(과적합의 방지) 등과 같은 주요 7가지 파라미터를 총 80번 이상 시행착오(trial and error) 전략에 따른 실험으로 파라미터를 선정하였다.



[표 2-6] 파라미터 목록 및 선정값

구분	파라미터 실험 구간	선정된 값
learning rate	0.000001 ~ 0.001	0.0008
epochs	50 ~ 200	30
batch_size	1	1
input_size	2 ~ 1000	20
hidden_layers	100 ~ 8000	8000
output_dim	1	1
dropout	0 ~ 0.3	0

#### (4) 예측값 비교 및 선정

기계학습은 적합한 학습 파라미터를 찾은 후 예측 결과를 선택하였으며 결과는 아래 [표 2-7]과 같다.

[표 2-7] LSTM 모형의 예측 결과

구분	전체 예측기간	예측기간 I	예측기간 II
RMSE	6.528	3.997	11.439
MAE	4.685	3.176	8.817

## 제 3 장 실증분석

### 제 1 절 실증분석 결과

본 연구는 환율 결정이론에 근거한 구조적 모형이 아닌 환율의 시계열 자료만을 활용하는 ARIMA 모형과 기계학습 LSTM 모형을 구축하여, 일변량 모형보다는 우월할 것으로 예상되는 전문기관의 환율 예측치와 비교하고, 이에 대한 기간별 예측력 평가를 시도하였다.

#### 1. 예측 정확성 비교 분석

##### (1) 모형별 예측력 분석

[표 3-1]은 전문기관, ARIMA(0,1,2), 장단기메모리(LSTM) 모형의 예측값을 평균 제공근 오차(RMSE)와 평균 절대 오차(MAE)를 이용해 각 모형의 정확도 산출하고 비교하였다.<sup>21)</sup>




[표 3-1] 전체 기간 예측력 비교

구분	RMSE	비율	MAE	비율
전문기관	4.881	1.00	2.425	1.00
ARIMA(0,1,2)	5.719	1.17	3.955	1.63
LSTM	6.528	1.34	4.685	1.93

전문기관의 RMSE 비율이 1.00일 때 ARIMA(0,1,2)은 1.17로 전문기관이 약 15%의 우수한 예측력을 보여주었고 LSTM은 1.34로 약 25%의 더 나은 예측력 보여주었다. MAE 기준으로 전문기관이 모든 모형에 비해 향상된 예측력을 갖는 것으로 분석되었다.

[그림 3-1] 전문기관과 ARIMA의 예측 편차 비교



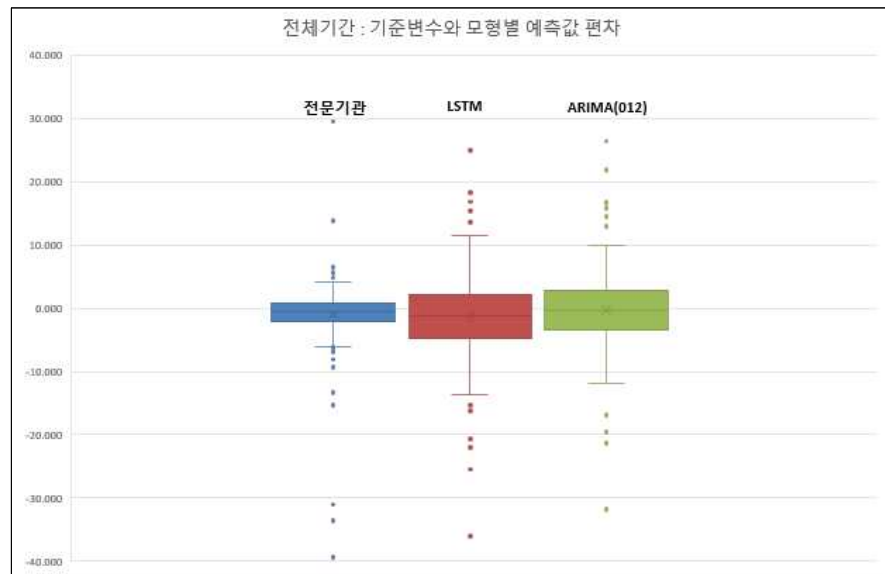
[그림 3-2] 전문기관과 LSTM의 예측 편차 비교



- 21) ARIMA 모형은 750일을 기준으로 한 구간이동방법으로 도출된 총 718일(17.4.18~20.3.31)에 대한 예측치를 LSTM의 평가 세트(test set, 20%)를 통해 도출된 290일(19.1.22~20.3.31)의 날짜 기준에 맞추어 전체기간, 예측기간Ⅰ, 예측기간Ⅱ 등 예측력을 비교한다.

[그림 3-1]과 [그림 3-2]은 각 모형의 예측치가 실제 환율로부터 떨어져 있는 편차를 나타낸 그래프이다. 전문기관 예측치는 파란색 그래프로 다른 두 모형에 비해 비교적 안정적인 예측 편차를 보여주고 있으며 붉은색 그래프로 표현되는 일변량 모형(ARIMA 및 LSTM)은 전문기관에 비해 예측 편차가 크고 예측력이 안정적이지 않음을 알 수 있다. 특히 변동성이 높은 기간에 해당하는 예측기간Ⅱ(COVID-19)에서 모든 모형들에서 큰 예측 편차가 발생한 것을 확인할 수 있다.

[그림 3-3] 예측모형의 예측 편차 범위 비교



[그림 3-3]은 각 모형의 예측 편차 범위를 확인할 수 있는 박스플롯(box plot) 그래프이다. 각 모형의 1사분위수와 3사분위수 정도만 비교해도 전문기관의 예측력이 다른 모형들에 비해 안정적인 것을 알 수 있다.

## (2) 기간별 예측력 분석

20년 1월 21일부터 COVID-19의 급격한 국내외 확산과 WHO의 비상사태(pandemic) 선포로 환율의 상승폭과 변동성이 단기간에 확대되었으며, 글로벌 확산에 따른 경기침체 우려로 시장의 불확실성은 계속 증대되고 있다. 기간별 예측력 분석에서는 변동성 기준에 따른 예측기간을 구분하여 예측력을 비교해보았다.



[표 3-2]과 [표 3-3]은 비교적 환율의 변동성이 크지 않은 시기인 예측기간 I (19.1.22 ~ 19.4.4)과 COVID-19의 영향으로 환율의 변동성이 높아진 예측기간 II (20.1.21~20.3.31)에 각 모형별 예측정확도를 비교하였다.

[표 3-2] 예측기간 I<sup>22)</sup>의 예측정확도 비교

구분	RMSE	비율	MAE	비율
전문기관	1.589	1.00	1.242	1.00
ARIMA(0,1,2)	3.292	2.07	2.764	2.23
LSTM	3.997	2.52	3.176	2.56

[표 3-3] 예측기간 II<sup>23)</sup>의 예측정확도 비교

구분	RMSE	비율	MAE	비율
전문기관	10.880	1.00	6.240	1.00
ARIMA(0,1,2)	10.281	0.94	7.526	1.21
LSTM	11.439	1.05	8.817	1.41

RMSE 기준으로 예측기간 I 에 전문기관 예측치는 ARIMA(0,1,2)에 비해 52%, LSTM 보다 60% 예측력이 우수했으며 예측기간 II에서는 ARIMA(0,1,2)에 비해 -6%, LSTM 에 비해 5% 정도 예측력이 우수한 것으로 확인되었다. 이는 전문기관의 예측치는 비교적 변동성이 크지 않은 예측기간 I 에 예측정확도가 안정적이며, 예측기간 II와 같이 변동성이 급격히 높아진 기간에는 다른 모형들과 같이 예측력이 특별히 우수하지 않은 것으로 확인되었다.

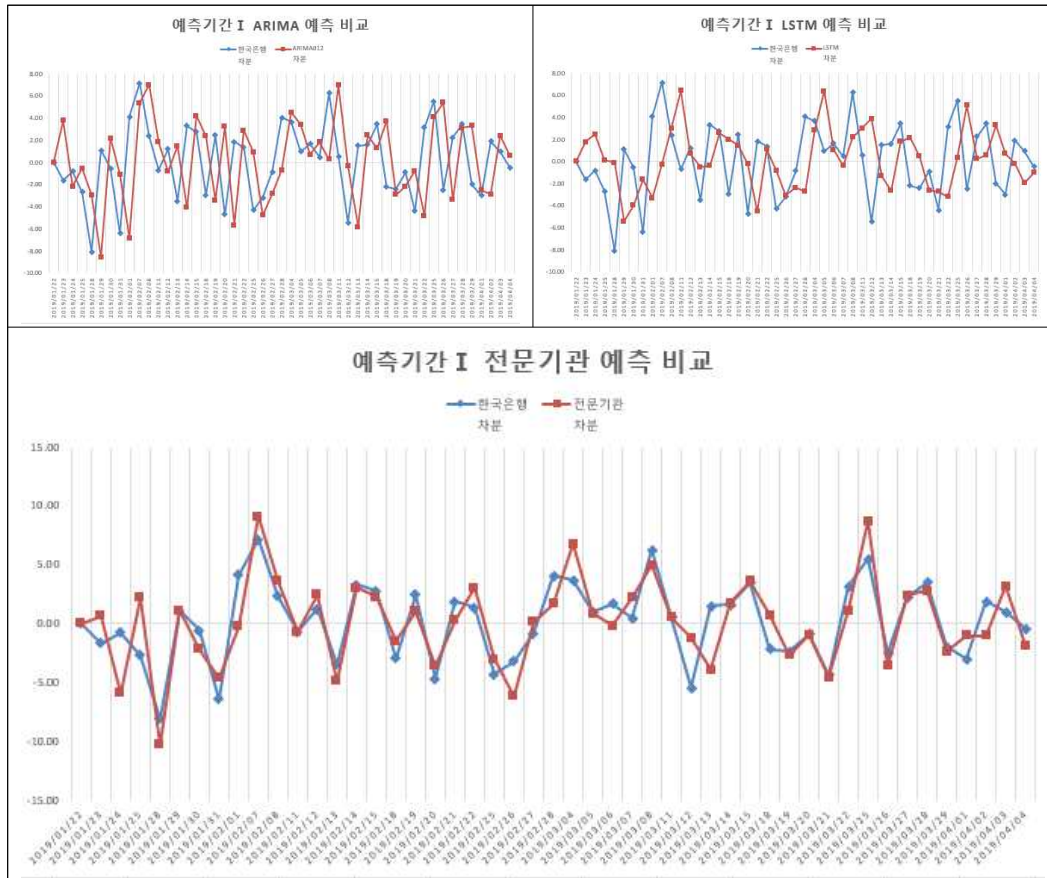
[그림 3-4]은 예측기간 I 의 실제 환율데이터와 각 모형별 예측데이터를 비교하였다. 상단 좌측의 ARIMA 모형의 예측치는 실제 환율데이터에 대한 후행성을 보이고 있다. 이는 실제 환율의 기울기를 따라가며 오차(error)를 최소화했기 때문에 오차(error) 수치가 의미가 있어도 예측모델로서 효용이 낮다고 할 수 있다. 상단 우측의 LSTM의 예측치 또한 ARIMA 모형보다는 후행성이 강하지는 않지만 예측값이 실제값을 추종하지 못하고 과도하게 엇갈리는 현상을 볼 수 있다.

22) 전체 예측기간 290일 중 예측기간 I 49일 이며, 기간은 19.1.22 ~ 19.4.4 이다.

23) 전체 예측기간 290일 중 예측기간 II 49일 이며, 기간은 20.1.21 ~ 20.3.31 이다.




[그림 3-4] 예측기간 I 각 모형별 예측력 비교




하단의 전문기관 예측치는 실제 환율데이터를 후행하지 않으면서 전체적으로 오차(error)도 낮고 주요 예측값들도 일치하는 모습을 보여준다. 이는 전문기관에서 제공하는 환율 예측치의 활용성에 대해 시사하는 바가 크다고 할 수 있다.

[그림 3-5]은 각 모형이 실제 환율과의 편차 그래프를 기준으로 각 모형 간의 예측력을 비교하였으며, 전문기관 예측치가 가장 안정적인 예측 오차를 보여주고 있다. 비록 예측기간II와 같이 변동성이 높은 시기에는 예측력이 불안정하지만, 예측기간 I 과 같이 비교적 안정적인 기간에는 다른 모형들 보다 매우 안정적인 예측력을 제공하는 것을 확인할 수 있다.

[그림 3-5] 예측기간 I 각 모형의 예측력 편차 비교



[그림 3-6] 예측기간 I 각 모형의 예측값 편차 범위 비교



[그림 3-6]은 각 모형의 예측값의 편차 범위를 비교한 박스플롯(box plot)으로 이를 통해 예측기간 I 에 전문기관 예측력의 상대적 정확성과 안정성을 확인할 수 있다.



## 2. 구간이동(Rolling Sample) 분석

앞의 전체 기간 및 구간별 분석에서 전문기관의 예측치는 예측기간 I 에 한해 비교적 안정적이고 정확한 예측력을 가짐을 확인하였으나 COVID-19로 변동성이 높았던 예측기간II에는 다른 모형들에 비해 안정적인 예측력을 보여주지 못하였다.

앞서 진행한 분석방법들은 일정한 기간에 대한 정태적 분석으로 다양한 예측 모형의 비교에 자주 사용되는 접근법이라 할 수 있다. 여기에서는 각 모형의 20일 단위의 평균 제곱근 오차(RMSE)를 구간추정(rolling estimation)하는 방법으로 도출하여 예측기간II처럼 단기간 급격한 변동성이 아닌, 일반적인 환율 변동성이 변화하는 다른 추세 전환기에도 전문기관의 예측력이 다른 모형들에 비해 더 우수한지 알아보하고자 한다. 이를 통해 각 모형이 어떤 기간에 RMSE의 변화가 많이 발생하였는지 확인해본다.

비교모형(z)은 ARIMA, LSTM, 전문기관으로 총 3개이며, 총 290개의 예측모형의 편차제곱( $y_k - z_k$ )<sup>2</sup>을 20개 단위씩 구간이동하여 20일 기준의 총 271개의 RMSE ( $R_n^z$ )를 구한다.

$$R_n^z = \frac{1}{20} \sqrt{\sum_{k=n-20}^{n-1} (y_k - z_k)^2} \quad (18)$$

$y_k$  = 수진변수의 환율 실제값,  $z_k$  = 예측모형에서 도출된 환율 예측값,  $n=21, 32, \dots, 290$

각 모형별 그래프의 비교를 위해 각 모형의 20일 단위 RMSE( $R_n^z$ )에서 평균( $M_z$ )을 구해 뺀 것으로 값( $Z_n$ )으로 정규화하여 비교한다. ARIMA 모형, LSTM 모형, 전문기관의  $Z_n$ 로 구한 내용은 [그림 3-7]과 같다.

$$M_z = \frac{1}{t} \sum_{k=1}^t R_k^z \quad (19)$$

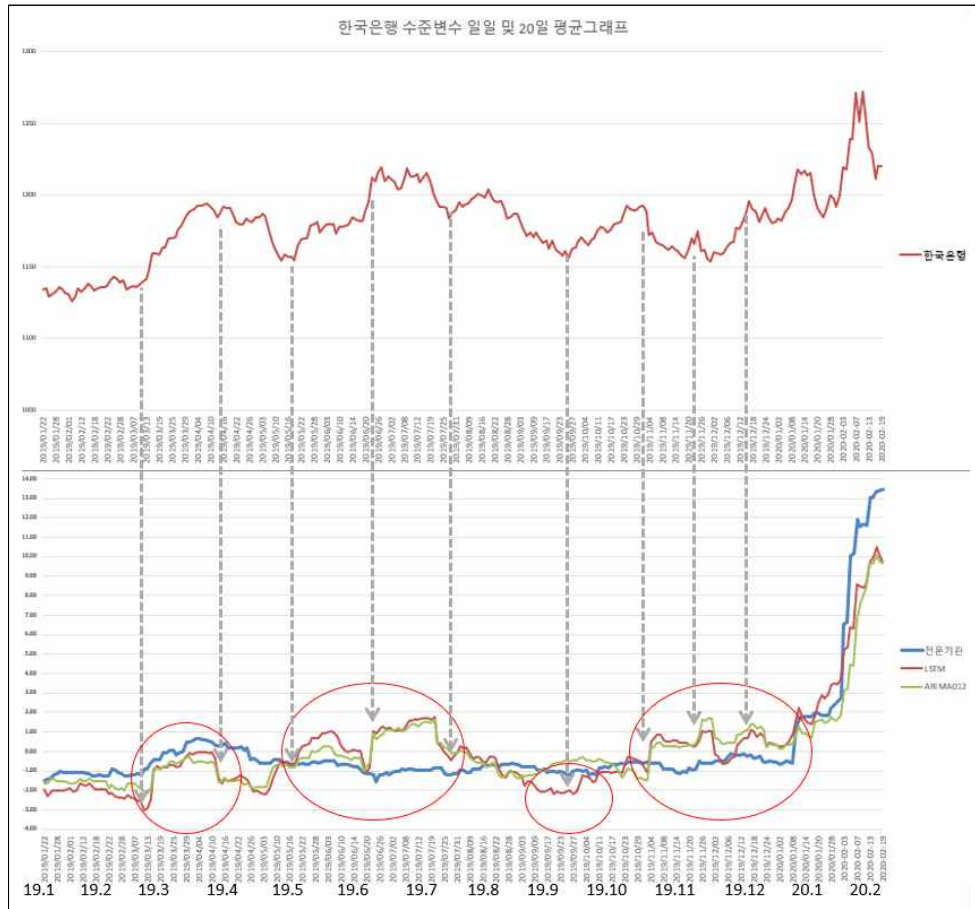
여기에서는  $t=271$

$$Z_n = R_n^z - M_z \quad (20)$$





[그림 3-7] RMSE 20일 구간이동분석 분석



[그림 3-7]은 총 290일에 해당하는 전체 예측기간에 대해 각 모형의 RMSE를 20일 기준으로 구간 추정한 결과를 비교한 것으로, 전문기관 예측치는 COVID-19 처럼 급격한 환율의 변화가 아닌 일반적으로 환율 변동성이 커지는 추세 전환기에서 시계열의 추세를 추종하지 않고 비교적 안정적인 예측력을 보여주는 것을 확인할 수 있었다.

특히 일변량 모형(ARIMA 및 LSTM)은 추세가 상승하고 하락하는 다수의 기간에서 RMSE의 증감이 확인되어 전문기관의 예측력과 비교할 때 매우 불안정한 예측력을 확인할 수 있었다.

## 제 4 장 결론

본 연구는 환율의 시계열 자료만을 활용하는 ARIMA 모형과 LSTM 모형을 구축하고 이를 전문기관의 환율 예측치와 비교하여 전문기관의 환율예측력과 일변량을 이용하는 예측모형들의 환율예측력을 분석하였다.

특히 최근 시계열 데이터 예측 등의 분야에서 좋은 성능을 낸다는 LSTM 모형과 전통적으로 시계열 데이터 예측에 많이 사용된 ARIMA 모형을 일변량으로 구축하여 변동성 기준에 따른 기간 구분 및 20일 단위의 구간이동(rolling method)을 적용하여 각 모형의 특성과 예측력의 차이를 체계적으로 비교/분석하여 해당 모형들이 환율예측에 있어서 활용 가능성이 있는지 확인하였다.

전문기관에서 제공하는 환율예측범위(고가-저가)의 산술평균값을 전문기관의 예측값으로 가정하고, 이에 한국은행이 제공하는 일일환율 고가와 저가의 산술평균값을 수준변수로 사용하였다. 이 수준변수를 대상으로 하는 일변량 분석으로 ARIMA 모형과 LSTM 모형을 구축하여 여기에서 나온 예측값을 전문기관의 예측값과 RMSE와 MAE로 비교하였다.

연구 기간은 17년 4월 1일부터 20년 3월 31일까지의 자료 중 휴일과 결측치를 제외한 총 1,468개의 데이터를 수준변수로 사용하였다. ARIMA 모형의 추정기간(estimation window)은 14년 4월 1일부터 17년 4월 17일까지 총 750개로 하여 17년 4월 18일부터 20년 3월 31일까지 총 718개의 예측치를 도출하였으며, LSTM 모형은 전체 데이터 중 80%를 학습세트(training set)로 20%를 평가세트(test set)로 사용하여 19년 1월 22일부터 20년 3월 31일까지 총 290개의 예측치를 도출하였다.

ARIMA 모형과 LSTM 모형의 예측기간이 겹치는 19년 1월 22일부터 20년 3월 31일까지 총 290개의 기간을 예측력 분석을 위한 예측기간으로 설정하였고 기간에 따른 예측력을 분석하기 위해 비교적 환율의 변동성이 크지 않은 예측기간 I (19년 1월 22일부터 19년 4월 4일, 49개)과 COVID-19의 영향으로 비교적 환율의 변동성이 큰 예측기간 II (20년 1월 21일부터 20년 3월 31일, 49개)로 나누어 기간별로 각 모형별 예측력의 차이가 있는지도 살펴보았다. 마지막으로 시계열 예측자료의 정확성 평가에 많이 사용되는 RMSE를 이용하여, 각 모형을 20일 단위로 구간 추정(rolling estimation)하여 어떤 모형이 기간별로 더 우수한 예측력을 나타내는지에 대한 빈도와 강도를 분석하였다.



본 연구의 결과를 요약하면 다음과 같다. 첫째, 전체 예측기간의 RMSE를 기준으로 전문기관의 예측치가 ARIMA 모형보다 15%, LSTM 모형보다는 25% 향상된 예측력을 나타냈다. 비교적 환율의 변동성이 크지 않은 시기인 예측기간 I에서는 전문기관의 예측치가 ARIMA 모형보다 52%, LSTM 모형보다는 60%로 예측력이 우수한 것으로 확인되었으나 COVID-19의 영향으로 비교적 환율의 변동성이 높아진 예측기간 II에서는 다른 모형들에 비해 특별히 우수한 예측력을 보여주지 못했다.

둘째, 예측기간 I의 실제 환율데이터와 각 모형별 예측데이터를 비교한 결과, ARIMA 모형은 실제 환율의 기울기를 따라가며 오차(error)를 최소화하는 높은 후행성을 나타내 예측모델로서의 낮은 효용성을 나타냈다. LSTM의 예측데이터는 ARIMA 모형보다는 후행성이 개선되었으나, 예측값이 실제값을 추종하지 못하고 과도하게 엇갈리는 모습을 보였다. 그러나 전문기관 예측치는 실제 환율데이터를 후행하지 않으면서도 낮은 오차와 주요 예측값들도 일치하는 안정적인 예측력을 보여주었다.

셋째, 각 모형의 RMSE를 20일 기준으로 구간 추정(rolling estimation)한 결과, 일변량 모형(ARIMA 및 LSTM)은 추세가 상승하고 하락하는 다수의 기간에서 RMSE의 증감을 보이며 불안정한 예측력을 보여주었고, 전문기관의 경우 시계열의 변동성이 커지는 기간에도 그 추세를 추종하지 않고 안정적인 예측력을 보여주었다. 이를 통해 전문기관 예측치는 COVID-19 처럼 급격한 환율의 변화가 아닌 일반적으로 환율 변동성이 커지는 추세 전환기에서 시계열의 추세를 추종하지 않고 비교적 안정적인 예측력을 보여주는 것을 확인할 수 있었다.

결과적으로 본고는 전문기관이 제공하는 환율 예측치의 활용성에 대한 시사점을 제공하였으며 최근 시계열 데이터를 활용한 예측에 성과를 보이는 LSTM 모형이나 전통적인 ARIMA 모형을 활용하더라도 일변량 데이터만으로 변동성이 큰 금융 시계열을 예측하려는 시도는 무의미하다는 것을 확인하였다.

본 연구는 예측치의 변동범위의 평균값을 수준변수로 한 일변량의 한계를 가지며 다양한 예측모형을 도입하지 못했다. 더 정교한 시계열 모형과 인공지능 모형을 도입하고, 모형 간의 결합예측을 시도하여 일변량과 다변량 그리고 결합모형에 대한 예측력, 변동성 등의 분석과 비교로 연구주제를 확장할 수 있을 것이다.



## 참고 문헌

- 강나연 (2015). 금융위기 이후 원/달러 환율예측 실증분석:임의보행 모형과 테일러 준칙을 이용한 환율예측모형 비교. 고려대학교 석사학위 논문
- 강민영 (2016). CNN 기반 원 달러 환율예측 모형 연구. 서강대학교 석사학위 논문
- 김보미·김재희 (2013). 일별 환율데이터에 대한 시계열 모형 적합 및 비교분석. 『응용통계연구』, 26권 1호, 14-27.
- 김수기. (2007). 인공지능경망을 이용한 원 달러 환율 변동성 예측모형의 구축. 서강대학교 석사학위 논문
- 김완섭 (2019). 파이토치 첫걸음:딥러닝 모델 생성에서 애플리케이션 개발까지. 제이펍
- 김재현 (2002). 인공지능경망 모형과 ARIMA 모형의 원/달러 환율예측성과 비교연구. 서강대학교 석사학위 논문
- 김진일·형남원 (2014). 환율의 일일 변동범위 예측에 대한 분석: 국내 시중은행의 일일 전망치를 중심으로. 『금융지식연구』, 12권 1호, 145-175.
- 김창범 (2007). 몬테카를로 시뮬레이션을 이용한 환율예측분석. 『산업경제연구』, 20권 5호, 2075-2093,
- 김호현 (2017). LSTM/GRU 순환신경망을 이용한 시계열데이터 예측. 방송통신대학교 석사학위 논문
- 남준우·이한식 (2010). 「계량경제학:EvIEWS/Excel활용/제3판」. 홍문사
- 류시영 (2006). 시계열 모형을 이용한 환율예측 및 기술적 투자에 관한 연구. 한국과학기술원 석사학위 논문
- 박혜원 (2019). 시계열모형의 예측에서 LSTM 성능에 대한 연구. 계명대학교 석사학위 논문
- 배성완·유정석 (2018). 머신 러닝 방법과 시계열 분석 모형을 이용한 부동산 가격지수 예측. 『주택연구』, 26권 1호, 107-133.
- 이궁희·이한식·장영재 (2015). 「예측방법론」. 한국방송통신대학교출판문화원.



오문석·이상근 (2000). 환율결정모형의 원-달러환율 예측력 비교. 『경영학연구』, 29권 4호, 711-722.

이우리 (2002). 원/달러 환율의 시계열특성 및 예측. 『통계연구』, 15권, 1-30.

이윤석 (2007). 원/달러 환율 예측력 분석에 관한 연구. 『금융조사보고서』, 2권, 1-80.

이태형 (2019). 인공신경망을 활용한 주택가격지수 예측에 관한 연구: 서울 주택가격 지수를 중심으로. 중앙대학교 박사학위 논문

장옥주 (2017). LSTM을 이용한 금융 시계열 예측모델의 후행성 문제 해결에 관한 연구. 가톨릭대학교 석사학위 논문

정동빈 (2015). 「시계열 애널리스트를 위한 Eviews솔루션」. 황소걸음아카데미

정철호 (2005). 국제투자은행들의 환율예측력 비교분석. 『POSRI 경영경제연구』, 5권 1호, 171-192.

최건호 (2019). 「파이토치 첫걸음」. 한빛미디어

한태경 (2010). 환율예측을 위한 합성모형 연구 : 시계열분석방법과 기계학습방법을 이용한 예측모형. 한국과학기술원 석사학위 논문

형남원·전형철 (2010). 국내 시중은행의 원/달러 환율 예측력 분석. 『금융지식연구』, 8권 3호, 3-32.

홍성완 (2010). 원/달러 환율 예측 모형의 비교분석 연구. 한국과학기술원 석사학위 논문

Diebold F.X. (2004). Elements of Forecasting, 3rd ed., South-Western.

Meese. R., A. & Rogoff. K. (1983). Empirical exchange rate models of the seventies: Do they fit out of sample?. Journal of international economics, 14(1), 3-24.

SaK. H., Senior. A. & Beaufays. F. (2014). Long Short-Term Memory Based Recurrent Neural Network Architectures for Large Vocabulary Speech Recognition. working paper



Abstract

**The Forecast of won/dollar Exchange Rates by Specialized Institutions:  
A Comparison Between Time Series Models and Machine Learning Long  
Short-Term Memory (LSTM) Models**

The exchange rate is an element that possesses high significance in the Korean economy, which is known for its high degree of trade dependency. In particular, fluctuations in the value of the won in accordance to that of the dollar should be more heavily assessed, since the dollar determines the orientation of the global market. Naturally, there has been a great amount of econometric and statistic analysis regarding the prediction of the won/dollar exchange rate.

In this sense, this paper seeks to compare and analyze the univariate models (ARTMA and LSTM), which utilize only the time series data of the exchange rate, with forecasting data of specialized institutions and verify the possibilities of each model as an exchange rate forecasting tool.

Empirical analysis shows that the forecasts of specialized institutions for Period I, where the exchange rate showed little variability, coincided with the real values. These forecasts were also effective even in periods that had higher variability, unlike univariate models (ARIMA and LSTM), which utilized rolling estimations of RMSE in 20 days intervals. These univariate models showed unstable forecasts as the trend of the time series data changed.

In conclusion, this paper confirms that the forecasts of specialized institutions can predict the exchange rate with stability, except for periods of extreme variability such as the impact of the recent COVID-19 outbreak. Simultaneously, this paper confirmed that although the LSTM and ARIMA models utilizing time series data recently have shown possibilities in predicting the exchange rate, it is meaningless to predict the highly volatile monetary time series data with a univariate data set.

Key words : Daily exchange rate, Forecast evaluation, Time series analysis, Machine Learning, ARIMA, LSTM

